学校代码: 10286
分 类 号: TP183
密 级: 公开
U D C: 004.8
学 号: 221863



東南大學

硕士学位论文

基于多智能体强化学习的大规模无人机集群博弈对抗研究

研究生姓名: 孙世彬

导 师 姓 名: 王庆领 教授

申请学位类别 工学硕士 学位授予单位 东南大学

一级学科名称 控制科学与工程 论文答辩日期 2025 年 5 月 21 日

二级学科名称 控制理论与控制工程 学位授予日期 2025 年 月 日

答辩委员会主席 翟军勇 评 阅 人 YS008250255

YS008250256

2025 年 5 月 21 日

中国知网 https://www.cnki.net

东南大学

硕士学位论文

基于多智能体强化学习的大规模无人机集群博弈对抗研究

专业名称: 控制科学与工程

研究生姓名: 孙 世 彬

导师姓名: 王庆领 教授

中国知网 https://www.cnki.net

RESEARCH ON LARGE SCALE UAV SWARM GAME CONFRONTATION BASED ON MULTI-AGENT REINFORCEMENT LEARNING

A Thesis Submitted to

Southeast University

For the Academic Degree of Master of Engineering

BY

Shibin Sun

Supervised by:

Prof. Qingling Wang

School of Automation

Southeast University

May 2025

中国知网 https://www.cnki.net

摘　要

随着无人机技术向多任务适应性与集群化作业体系发展，传统单机作业模式在军事对抗等高阶复杂任务中逐渐显露出效能瓶颈。在此背景下，构建具有环境强适应能力的大规模无人机集群自主协同决策体系成为关键突破口。然而，集群博弈对抗面临多维技术约束，涉及动态不确定环境中的态势感知耦合、未知威胁下的实时决策博弈，以及高维状态空间协同控制等复杂挑战。当前，融合多智能体强化学习的策略框架为解决集群自主协同问题提供了新的范式。基于此，本文研究基于多智能体强化学习算法的无人机集群博弈对抗问题，实现在集群空战、大规模集群空域争夺及复杂环境下集群对地支援三类场景下的博弈对抗任务。全文的主要工作及创新点如下：

（1）针对无人机集群空战问题，提出了一种融合优先级采样的改进多智能体深度确定性策略梯度算法。首先，将无人机集群博弈对抗问题转化为马尔可夫决策过程，引入基于时序差分误差的优先经验回放机制，显著提高关键经验样本的利用率。同时，设计了一种新型神经网络结构，通过分别提取无人机状态信息和雷达探测信息，然后进行融合以加速模型训练。其次，通过对比实验证明所提出的算法有效解决了传统算法在策略优化中存在的经验选择的偏差问题。最后，对抗实验结果证明了该算法在解决无人机集群博弈对抗问题时的有效性，并通过泛化性实验验证了该算法在不同环境下的泛化性。

（2）针对大规模无人机集群空域争夺问题，提出了一种融合课程学习训练思想的改进多智能体深度确定性策略梯度算法。首先，将大规模无人机集群空域争夺问题建模为马尔可夫决策过程。并且在设计基于课程学习的渐进式训练范式的同时，在算法框架中引入注意力机制，实现从小规模到大规模无人机集群的平稳过渡。其次，基于所提出的算法在仿真环境中构建训练模型，训练结果表明该算法相较于对比算法能够快速收敛并且具有较高的平均奖励。最后，通过实验验证所提出的算法能够有效解决无人机集群空域争夺问题，同时具有较强的泛化性。

（3）针对复杂环境下的无人机集群对地支援问题，提出了一种融合自博弈训练框架的改进多智能体双延迟深度确定性策略梯度算法。首先，将复杂环境下无人机集群对地支援问题转换为马尔可夫决策过程，在算法框架中引入自博弈训练，使无人机集群的博弈对抗策略更加适应复杂战场环境，同时将注意力机制拓展为多头注意力机制以增强模型对高维输入的特征提取能力。其次，在环境中进行仿真训练，训练结果表明该算法能够更快收敛并且具有更高的平均奖励。最后，在对抗实验中验证了所提出的算法在无人机集群对地支援问题中的有效性，并对该算法进行自博弈训练前后的策略对比，结果表明自博弈训练有效的提升了算法的对抗胜率，具有较强的普适性。

关键词： 多智能体强化学习；无人机集群；博弈对抗；课程学习

中国知网 https://www.cnki.net

Abstract

With the advancement of unmanned aerial vehicle (UAV) technology toward multi-task adaptability and swarm-oriented operational systems, traditional single-agent operational models have gradually revealed efficiency bottlenecks in high-order complex missions such as military confrontations. In this context, constructing a large-scale UAV swarm autonomous collaborative decision-making system with robust environmental adaptability has become a critical breakthrough. However, swarm game-theoretic confrontations face multidimensional technical constraints, including complex challenges such as coupled situational awareness in dynamic uncertain environments, real-time game-theoretic decision-making under unknown threats, and collaborative control in high-dimensional state spaces. Currently, multi-agent reinforcement learning integrated strategy frameworks offer a novel paradigm to address swarm autonomous collaboration challenges. Building on this foundation, this thesis investigates UAV swarm game-theoretic confrontation problems based on MARL algorithms, achieving adversarial tasks in three scenarios: swarm aerial combat, large-scale airspace contention, and complex environment-based ground support operations. The main work and innovations of this thesis are as follows:

(1) Aiming at the problem of UAV swarm aerial combat, an improved Multi-Agent Deep Deterministic Policy Gradient algorithm integrated with prioritized sampling is proposed. Firstly, the UAV swarm adversarial problem is formulated as a markov decision process, incorporating a prioritized experience replay mechanism based on temporal difference error to significantly enhance the utilization efficiency of critical experience samples. Simultaneously, a novel neural network architecture is designed to separately extract UAV state information and radar detection data, followed by feature fusion to accelerate model training. Secondly, comparative experiments demonstrate that the proposed algorithm effectively mitigates the bias in experience selection inherent in traditional algorithms during policy optimization. Finally, adversarial simulation results validate the algorithm's superiority in resolving UAV swarm game confrontations, while generalization tests confirm its robustness across diverse environments.

(2) Aiming at the problem of large-scale UAV swarm airspace contention, an improved Multi-Agent Deep Deterministic Policy Gradient algorithm integrated with curriculum learning-inspired training is proposed. Firstly, the airspace contention problem is modeled as a markov decision process. A curriculum-based progressive training paradigm is designed to enable a smooth transition from small-scale to large-scale UAV swarms, while an attention mechanism is incorporated into the algorithmic framework to enhance collaborative decision-making in

中国知网 https://www.cnki.net

complex scenarios. Secondly, comparative experiments conducted in simulated environments demonstrate that the proposed algorithm achieves a superior convergence rate and higher average rewards compared to baseline methods. Finally, extensive validation experiments confirm the algorithm's effectiveness in resolving large-scale airspace contention tasks, and generalization tests further verify its robust scalability across diverse swarm sizes and environmental conditions.

(3)Aiming at the problem of UAV swarm ground support operations in complex environments, an improved Multi-Agent Twin Delayed Deep Deterministic Policy Gradient algorithm integrated with a self-play training framework is proposed. Firstly, the problem is formulated as a Markov Decision Process, where a self-play mechanism is introduced to enhance the adaptability of swarm adversarial strategies to dynamic battlefield conditions. Simultaneously, the attention mechanism is extended to a multi-head attention architecture to strengthen the model's capability in processing high-dimensional input features. Secondly, simulation-based training results demonstrate that the proposed algorithm achieves faster convergence and higher average rewards compared to baseline approaches. Finally, adversarial experiments validate the algorithm's effectiveness in UAV swarm ground support tasks, while comparative analyses of strategies before and after self-play training reveal a significant improvement in adversarial win rates, confirming its robust generalizability across diverse combat scenarios.

Keywords: Multi-Agent Reinforcement Learning; UAV Swarm; Game Confrontation; Curriculum Learning

中国知网 https://www.cnki.net

目 录

第一章 绪论.....1
1.1 研究背景.....1
1.2 研究现状.....2
1.2.1 无人机集群博弈对抗.....2
1.2.2 多智能体强化学习.....3
1.2.3 基于强化学习的无人机集群博弈对抗.....6
1.3 研究动机与研究内容.....7
1.4 论文组织结构.....8
第二章 多智能体强化学习基本理论.....11
2.1 强化学习算法.....11
2.1.1 强化学习基本概念.....11
2.1.2 基于值函数的强化学习方法.....13
2.1.3 基于值函数和策略梯度结合的强化学习方法.....15
2.2 多智能体强化学习算法.....18
2.2.1 多智能体马尔可夫决策过程.....18
2.2.2 多智能体深度 Q 网络算法.....19
2.2.3 多智能体深度确定性策略梯度算法.....20
2.3 基于多智能体强化学习的无人机集群对抗技术.....21
2.4 本章小结.....22
第三章 基于多智能体强化学习的无人机集群空战博弈对抗.....23
3.1 引言.....23
3.2 问题建模.....23
3.2.1 无人机运动模型.....23
3.2.2 无人机空战博弈对抗模型.....24
3.2.3 无人机集群空战环境模型.....25
3.2.4 无人机集群空战博弈对抗 MDP 模型.....25
3.3 基于 PER-MADDPG 算法的无人机集群博弈对抗算法设计.....27
3.3.1 算法框架结构.....27
3.3.2 优先经验回放机制.....30
3.3.3 神经网络结构.....31
3.4 仿真实验结果.....33
3.4.1 仿真实验环境.....33
3.4.2 训练结果与测试评估.....34
3.5 本章小结.....38

中国知网 https://www.cnki.net

第四章 空域争夺场景下基于强化学习的大规模无人机集群博弈对抗 39
4.1 引言 39
4.2 问题建模 39
4.2.1 无人机集群联合攻击模型 39
4.2.2 大规模无人机集群空域争夺任务模型 40
4.2.3 大规模无人机集群空域争夺博弈对抗 MDP 模型 41
4.3 基于 CLA-MADDPG 的大规模无人机集群空域争夺任务算法设计 44
4.3.1 算法框架结构 44
4.3.2 神经网络结构 46
4.3.3 课程学习思想 48
4.4 仿真实验结果 49
4.4.1 仿真实验环境 49
4.4.2 训练结果与测试评估 50
4.5 本章小结 56
第五章 复杂环境下基于强化学习的无人机集群对地支援博弈对抗 57
5.1 引言 57
5.2 问题建模 57
5.2.1 复杂环境下无人机集群对地支援任务模型 57
5.2.2 高楼障碍物模型 58
5.2.3 复杂环境下无人机集群对地支援任务 MDP 模型 59
5.3 基于 CLA-MATD3-SP 算法的无人机集群博弈对抗算法设计 62
5.3.1 算法框架结构 62
5.3.2 MATD3 算法框架 63
5.3.3 自博弈训练框架 65
5.3.4 神经网络结构 66
5.4 仿真实验结果 66
5.4.1 仿真实验环境 66
5.4.2 训练结果与测试评估 67
5.5 本章小结 74
第六章 总结与展望 75
6.1 工作总结 75
6.2 研究展望 75
参考文献 77

中国知网 https://www.cnki.net

第一章 绪论

1.1 研究背景

随着人工智能、探测制导、材料科学及通信网络等前沿技术的不断发展，现代空战模式正经历深刻变革。战场环境的异构化与强对抗性显著提升了信息域管理的复杂度，特别是在多源数据的非对称分布与虚实信息混杂的情境下，对空战指挥系统的态势认知与实时决策效能提出了严峻挑战。在智能化战争范式加速发展的时代背景下，无人机(Unmanned Aerial Vehicle, UAV) 凭借其高机动性、响应速度快、制造成本低以及无需人员直接参与正面对抗等优势，被广泛应用于替代人类执行危险性高、环境恶劣、纵深大等方面的任务[1-2]，逐步成为现代军事体系中的关键组成部分。相较于有人机平台，无人机以其微型化构型、高机动性以及自主执行性等特点，在复杂电磁环境下的侦察监视、精准打击与动态对抗等任务中展现出显著优势[3]。单一无人机平台能力有限，而无人机集群则具有突防能力强、成本低廉、作战运用方式多样以及整体可靠性强等特点，其作战优势尤为突出[4]。同时，无人机集群具有更强的环境适应能力和控制冗余性，能够在协同工作中完成更复杂的任务和目标[5]。

无人机集群博弈对抗本质上属于动态不完全信息博弈模型。在决策过程中，需要融合多维度态势要素，包括但不限于对敌方状态空间的建模、对环境动态特性的分析以及多目标约束优化等关键环节[6]。该系统通过实时感知-决策-行动闭环，实现策略空间的动态博弈均衡，其核心目标函数涵盖集群生存概率最大化、作战任务完成度优化以及对抗收益非对称提升等多个维度的综合优化。这种基于群体智能的协同机制突破了单平台能力边界，通过分布式自主决策与集中式态势共享的有机融合，显著增强了集群系统的整体作战弹性与任务适应性。

在无人机集群作战的实现过程中，需要攻克一系列关键技术问题，而其中自主控制与决策能力的提升尤为关键。目前，无人机执行作战任务主要依赖预先程序设定或地面站操作员实时操控，然而，这两种方法均存在显著局限性。一方面，预先程序设定方法难以适应实时战场环境的复杂变化。作战前，战场信息往往存在不确定性，目标的位置、数量和能力等关键信息通常难以提前准确获取。在这种情况下，预先规划的作战方案很难达到预期效果，且缺乏灵活性，无法根据战场态势的动态变化进行实时调整。另一方面，地面站操作员实时操控的方法也面临诸多挑战。战场电磁环境复杂多变，通信的稳定性和延时问题成为制约因素。确保信息传输的可靠性面临诸多挑战，特别是在空战格斗等类型的战场环境，其动态特性要求即时的信息回传与指令接收。信息延迟在此类场景下，显著影响战斗决策与执行的有效性，进而对战斗结果产生重大影响。此外，随着无人机数量的增加，导致的操作人力成本显著上升，操作人员的组织与协调任务随之加

中国知网 https://www.cnki.net

重，进而对团队协作与配合能力提出了更高的要求。鉴于此，在特定情境下，赋予无人机一定的自主控制和决策能力显得尤为重要。这不仅能够提升无人机集群在复杂战场环境中的适应性和灵活性，还能有效降低对地面站操作员的依赖，减少人力成本和通信压力，显著提升无人机集群作战的整体效能。

无人机集群博弈对抗在智能军事[7]、无人机交通管制[8]、海洋监测[9]及野外勘探[10]等领域表现出广泛的应用潜力。其核心研究方向在于如何通过计算框架与决策算法提升集群的自主协同能力，特别是在非完全信息环境下的动态适应性。基于规则的约束、专家系统策略规划及启发式算法曾被视为解决复杂问题的主要技术途径。例如，分布式任务分配算法通过信息分发与局部优化实现全局协同，而博弈论模型（如矩阵博弈）则被用于目标分配与火力协同。然而，这些方法在应对高维连续状态空间和实时决策挑战时存在局限性。近年来，深度强化学习 (Deep Reinforcement Learning, DRL) 的引入显著提升了无人机集群的智能化水平。DRL 通过试错机制和策略迭代，能够学习动态环境下的最优决策路径，尤其在追踪合围、态势评估等场景中展现出高效性。此外，演化博弈理论结合分布式控制框架，通过自适应规则调整优化集群协同效率，已在编队重组、资源分配等场景得到验证。现阶段研究难点多集中在多智能体交互的稳定性、部分可观测性及纳什均衡收敛性，其解决的主流方法包括：将全局优化问题分解为分布式子任务，通过粒子群算法引入动态自适应权重解决局部搜索问题，以及结合动态贝叶斯网络与博弈论建模复杂对抗过程。未来需进一步突破深度强化学习在多智能体环境下的样本效率问题，并探索更鲁棒的对抗策略生成框架。

无人机集群博弈对抗研究具有重要的意义与价值，在智能化战争范式加速演进背景下，其通过构建动态不完全信息博弈模型，融合多维度态势要素实现策略空间动态博弈均衡，能有效提升集群在高度异构化、强对抗战场环境中的自主协同决策能力，突破单平台能力边界，解决预先程序设定和地面站实时操控的局限性，降低人力成本与通信压力，实现集群生存概率最大化、任务完成度优化等多目标综合优化，不仅为智能军事领域提供关键技术支撑，还在无人机交通管制、海洋监测等民用领域展现广阔应用前景，推动群体智能在复杂动态环境中的理论与技术创新，增强系统整体作战弹性与任务适应性，是应对未来智能化战争及复杂场景任务的核心研究方向。

1.2 研究现状

1.2.1 无人机集群博弈对抗

无人机集群博弈对抗是指在一个特定的场景中，两个或多个无人机集群通过智能算法进行博弈，互相对抗，以达到某个目标[11]。无人机集群对抗的核心挑战在于动态战场中单机对移动目标的高效打击任务分配[12]。需通过协同指挥决策机制，统筹敌方动态目标威胁评估、打击代价建模及分配策略优化，并考量任务配对关系的持续性，以最大化集群整体作战效能。

中国知网 https://www.cnki.net

在过去的几十年中，众多国内外学者致力于基于传统算法解决无人机集群对抗问题[13]。随着各类先进技术的不断发展，无人机集群对抗的研究也取得了显著进展。例如，通过先进的雷达[14]、传感器[15]和通信技术，无人机能够较为精准地获取敌我双方的机动策略和状态信息，从而对战场态势进行准确评估[16]。在此基础上，许多学者针对战场动态威胁态势的评估展开研究，通过实时威胁分析优化集群空战决策。赵振宇等人[17]通过敌我战斗意图评估与威胁态势融合分析，实现了动态空战环境下的无人机集群目标分配，提升了无人机集群在复杂战场环境下的作战效能。王晓光等人[18]构建了人工势场空战态势评估模型，融合文化基因算法 (Memetic Algorithm, MA) 实现了无人机超视距空战目标动态分配任务，高效地解决了复杂战场环境下的目标分配问题。Duan 等人[19]从博弈论的角度对空战中的动态任务分配问题进行了建模，将无人机的下一刻位置、生存概率和武器剩余量定义为状态变量，目标分配关系作为决策变量，提高了任务分配的实时性和解的质量。肖亮等人[20]将无人机集群空战任务中的优劣势范围划分为四类，并通过神经网络训练生成无人机空战优势矩阵。基于该优势矩阵，进一步对无人机的攻击顺序进行排序，从而为无人机集群在复杂战场环境中的作战任务分配提供了高效的决策支持。

除了上述基于空战态势建模的目标分配方法外，近年来新型算法相继涌现，显著提升了无人机集群对抗场景下的策略生成效率与协同稳定性[21]。例如，Xia 等人[22]对传统蚁群算法进行改进，不仅实现了对多个地面目标移动轨迹的精准预估，还通过目标分配策略将无人机的攻击效益最大化。Wang 等人[23]将博弈论应用于无人机决策对抗中，构建了态势演化博弈模型，设计了态势评估函数，并结合社会力模型实现了动态对抗，为无人机集群在复杂战场环境中的高效作战提供了理论支持和实践指导。Garcia 等人[24]研究并提出合作差分博弈，为无人机集群在目标防御场景中的决策对抗提供了新的视角。从最优控制的角度来看，Chen 等人[25]使用分布式制导律来解决无人机攻防控制问题。Kang 等人[26]通过将基于模型预测控制的协同制导律和共识理论的结合提高了无人机协同攻击的精度，还增强了制导律在复杂环境下的适应性。Su 等人[27]提出了无人机集群协作状态空间重建机制来解决异构无人机集群对抗问题，这种机制通过使用相对状态信息来描述 UAV 集群之间的协作关系，从而重建 UAV 自身的状态空间。Hong 等人[28]提出了一种通用攻击成本函数和自适应攻击的策略 (Adaptive Attack Strategy, AAS)，以提高无人机集群在空中战场对敌方无人机集群的协同打击能力。

1.2.2　多智能体强化学习

在人工智能领域研究中，关键信息的有效提取与高效利用是核心挑战之一。面对复杂问题中庞杂的参数体系与多维观测信息，传统方法如启发式搜索与专家系统虽可应对常规场景，但随着信息规模扩张，其知识归纳与特征提取过程常因计算复杂度激增而引发时间成本大幅度提高，导致实时性与可扩展性受限。

强化学习技术的不断发展为复杂问题的求解开辟了新途径。强化学习的本质在于智

中国知网　https://www.cnki.net

能体通过环境交互实现经验驱动型策略更新，基于试错机制完成策略自优化，最终使动态迭代模型高效达成预设任务目标。[29]。智能算法因其独特的学习能力而区别于传统算法，能够高效利用环境信息实现自主学习与策略优化。强化学习算法作为一种模拟生物学习机制的算法，通常能够在与环境的交互过程中不断优化自身策略，从而在复杂多变的环境中展现出强大的适应性和优化能力[30]。

虽然强化学习算法在博弈决策等场景已经取得了一定的成果，但随着相关研究的不断深入，其在发展过程中仍面临着诸多挑战，如无法高效处理价值函数高维表征与策略生成效率的失衡问题[31]。传统 Q-Learning 算法[32]基于表格化存储机制，面对大规模状态空间时存在策略更新延迟与存储冗余问题。参数化的函数拟合机制[33]通过小样本训练优化资源占用，虽然能够节省计算成本和存储空间，但在融合强化学习框架时仍需应对三个核心问题：动态环境中的非稳态数据分布、时序差分误差累积，以及探索-开发延迟效应。因此，在应用强化学习算法解决实际问题时，还需要根据实际情况对算法进行复杂的设计并不断进行参数调优。

随着深度学习的发展，强化学习研究范式已向深度强化学习演进，其核心在于耦合强化学习决策框架与深度学习表征能力，通过深度神经网络对动作价值函数进行高维拟合，从而解决传统算法在复杂状态-动作空间中的维数灾难问题[34]。典型代表如深度 Q 网络[35](Deep Q Network, DQN) 及其改进型双深度 Q 网络[36](Double Deep Q Network, DDQN)，均通过逼近状态-动作价值函数实现策略优化。在决策过程中，这些算法通常采用 $\varepsilon - greedy$ 策略，即以较大概率选择当前状态下具有最大动作价值的动作，从而实现高效的探索与利用平衡，显著增强高维状态-动作空间的信息提取效能。尽管基于价值函数的方法虽在离散空间表现优异，却难以有效处理连续空间优化问题。传统离散化方法易引发维度灾难与策略次优性[37]。为此，Lillicrap 等人[38]将 DQN 嵌入确定性策略梯度框架，构建了基于演员-评论家 (Actor-Critic) 架构的深度确定性策略梯度算法 (Deep Deterministic Policy Gradient, DDPG)。针对 DDPG 的策略震荡与 Q 值过估计缺陷，Fujimoto 等人[39]借鉴与 DDQN 算法相似的思想，提出了双延迟深度确定性策略梯度算法 (Twin Delayed Deep Deterministic Policy Gradient, TD3)，引入延迟更新机制抑制误差累积，进一步提高了算法性能。相较于传统 DQN 系列算法，DDPG 系列算法在连续状态-动作空间的复杂问题中展现出显著优势，但仍然难以直接应用于多智能体博弈对抗任务[40]。

多智能体强化学习 (Muti-Agent Reinforcement Learning, MARL) 算法[41]的出现为多智能体博弈对抗任务提供了新的思路。在 MARL 框架中，每个智能体在每个时间步的迭代过程中获取独立局部观测信息。基于局部观测，智能体通过分布式策略生成机制（随机探索或时序动作仲裁）执行个体决策行为。随后，环境状态转移函数将依据全局状态与联合动作空间分布完成状态跃迁，并通过多目标奖励分配机制对各智能体进行收益反馈。该过程在动态观测-决策循环中持续演进，形成具有马尔可夫性质的动态博弈闭环。由于任务场景的异质性，智能体间可能呈现合作型或竞争型目标导向。合作场景下共享

中国知网 https://www.cnki.net

全局奖励函数，竞争场景下遵循个体理性原则，即每个智能体基于局部观测信息与历史交互数据，以策略梯度方法持续优化策略网络参数，旨在最大化个体累计折扣回报。

独立 Q 学习 (Independent Q-Learning, IQL) 算法[42]通过分布式 Q-Learning 架构实现多智能体协同，各智能体在马尔可夫决策框架下独立构建局部 Q 函数，以个体累计奖励最大化为目标进行策略优化。该算法采用非对称环境建模方法，将其他智能体的行为建模为环境动态扰动项，通过分布式经验回放实现无显式知识共享机制与全局目标函数的协同范式。这种基于个体经验隔离的更新机制虽能规避联合动作空间维度爆炸问题，但会引发竞争性奖励冲突与收敛速度显著降低的问题。为解决 IQL 算法存在的问题，Sunehag 等人[43]提出了一种值函数分解网络算法 (Value-Decomposition Network, VDN)，该算法将集中式多智能体强化学习中的全局 Q 值函数解构为多个局部价值函数的线性组合，在保持分布式决策架构的同时实现全局目标优化。在 VDN 框架下，每个智能体独立维护其专属的局部价值函数，该函数专注于量化个体行为对系统整体目标的边际贡献。通过分布式的反向传播机制，各智能体协同优化自身的价值评估网络参数，旨在实现全局回报的最大化。然而，VDN 算法的核心假设建立在价值函数的完全可分解性基础上，这种强约束虽然保证了理论上的可分解性，但实质上限制了模型对复杂协作关系的表达能力，特别是在处理需要高阶交互或动态角色分工的协同任务时，其表征能力的局限性愈发显著。而 QMIX[44]作为一种更先进的值分解的方法，通过设计混合网络架构，突破了传统线性组合的价值函数建模范式。该算法构建的非线性价值聚合机制，使得全局 Q 值函数能够以超加性方式融合局部智能体的行为价值，这种高阶交互建模能力显著扩展了算法在复杂协同场景中的应用边界。

随着多智能体强化学习的不断发展，基于 Actor-Critic 框架的算法体系不断突破。其中，多智能体深度确定性策略梯度算法 (Multi-Agent Deep Deterministic Policy Gradient, MADDPG)[45]作为 DDPG 方法在多智能体场景的延伸，构建了“集中式训练-分布式执行”的协同范式。该算法在训练阶段通过智能体间信息共享机制，使每个智能体的价值网络能够整合全局观测空间进行联合价值评估，而在实际执行阶段则严格遵循分布式决策原则，各智能体的策略网络仅依赖局部观测信息生成策略。这种训练与执行阶段的解耦设计，有效平衡了全局协同优化与分布式实时决策的工程需求。此外，COMA[46]针对多智能体协作中的信用分配难题，在 Actor-Critic 框架中引入反事实推理机制。通过构建具有因果推断能力的基准评估体系，在仅依赖全局团队奖励的约束条件下，精确量化个体行为对系统整体收益的边际贡献。Soft Actor-Critic(SAC)[47]在最大化预期的同时最大化熵值，从而在获得最高累计收益的同时保持探索避免过早掉入局部最优解。多智能体双延迟深度确定性策略梯度算法 (Multi-Agent Twin Delayed Deep Deterministic Policy Gradient, MATD3)[48]是基于 TD3 算法的多智能体版本，通过双 Critic 结构减少 Q 值估计偏差，采用延迟更新机制进一步提高了训练过程的稳定性。

近年来，部分学者在大规模多智能体强化学习领域也取得了一定成就，Multi-Actor-Attention-Critic(MAAC)[49]通过将注意力机制与价值网络结合，能够在复杂的多智能体环

中国知网　https://www.cnki.net

境中实现更有效和可扩展的学习。文献[50]提出了动态多智能体课程学习框架 (Dynamic Multi-Agent Curriculum Learning, DMACL)，将课程学习机制与深度卷积神经网络进行深度融合，大幅提高了大规模多智能体学习的性能。Yang 等人[51]提出了平均场强化学习 (Mean-Field Reinforcement Learning, MFRL)，通过单个智能体和整体智能体或者是相邻智能体的平均影响来估计智能体内部的交互作用，在理论层面证明了当智能体数量趋向无穷时，系统均衡策略收敛于均值场博弈解的严格数学性质，为超大规模群体智能系统的研究奠定了理论基础。

1.2.3 基于强化学习的无人机集群博弈对抗

深度强化学习继承了深度学习的特征表示能力和强化学习的决策能力，能够自动从经验中学习并适应环境及对手的变化。因此，将深度强化学习应用于无人机集群对抗问题，有助于克服传统方法的局限性，并提高无人机集群的适应性和自主决策能力。在当前强化学习技术赋能无人机集群博弈对抗的研究中，多智能体协同决策机制的构建成为关键挑战。针对多无人机集群对抗的高维状态空间与动态博弈复杂性，学界提出多种改进方案，施伟等人[52]研发了一种基于改进强化学习的多无人机协同对抗算法，通过细致处理训练过程中的经验数据，并设计合理的奖励机制，达到了快速收敛和高效决策的效果。Chi 等人[53]提出了一种新的基于生物的无人机集群对抗决策方法，通过建立基于分组机制的无人机集群对抗决策框架，并设计仿生动作空间，并在奖励函数中加入密集奖励，大幅加快了训练的收敛速度。Wang 等人[54]引入并行解耦奖励机制 (Parallel Decoupled Reward Mechanism, PDRM) 对 MADDPG 算法进行适用性提升，收敛效率和执行质量得到显著提高，自主对抗策略学习呈良性演化趋势，进一步提高了无人机集群对抗自主对抗策略实战应用的可信度。Zhang 等人[55]将 QMIX 算法和人工势场法做出的决策相结合，用于无人机集群对抗，进一步解决了无人机集群不对称对抗问题。

在大规模无人机集群对抗方面，当前研究已在分布式协同决策架构与群体智能涌现机制等维度取得一定进展。Wang 等人[56]提出了一种新的 MARL 范式，称为加权平均场强化学习，其中任何无人机与其相邻无人机之间的成对通信被建模为中央无人机和虚拟无人机之间的通信，减少智能体的输入维度并适应不断变化的集群大小。Nian 等人[57]提出了一种分层注意力演员-评论家算法 (Hierarchical Attention Actor-Critic, HAAC)，通过于对无人机之间的关系进行建模，并从相邻的无人机中提取关键信息，从而能够生成先进的合作和竞争策略，HAAC 算法有效地降低了动作空间和状态空间的维度，提升了训练效率。Liu 等人[58]将进化策略 (Evolutionary Strategy, ES) 方法应用于大规模无人机集群对抗问题，有效地避免了使用强化学习处理高维模型时难以获得准确梯度的问题，促进了自主无人机寻找性能更高的策略，提出了使用 OpenAI 进化策略 (OpenAI Evolutionary Strategy, ES) 和集成进化策略 (Integrated Evolutionary Strategy, IES) 的两种无人机集群博弈算法，有效解决了大规模无人机集群对抗博弈问题。Hu 等人[59]提出了一种基于模糊多智能体强化学习的方法，将大规模无人机集群中的对抗建模为模糊博弈，建立了相应

中国知网 https://www.cnki.net

的群体决策过程，通过去模糊计算，将抽象智能体的策略映射到特定的无人机行为，在保证策略有效性的同时，显著降低计算消耗。

1.3　研究动机与研究内容

在复杂环境下的大规模无人机集群系统下，多智能体强化学习存在以下问题：1）传统策略梯度算法在训练过程中面临稳定性问题，需要调整精细的超参数来实现良好的性能；2）基于采样方差的影响，策略梯度算法在较为复杂的环境场景中需要探索的次数过多，导致训练时间长甚至出现无法收敛的情况；3）直接在难度较高的环境中训练可能使模型运行困难，难以训练学习出有效策略。现实空战对抗环境复杂且动态多变，无人机集群需在复杂战场态势、有限感知能力和不确定通信条件下完成任务。然而，现有研究多聚焦于小规模无人机集群对抗，难以应对大规模集群作战的复杂性。大规模无人机集群对抗建模面临稳定性差、训练时间过长等挑战，且现有方法在真实复杂环境上存在局限。因此，解决复杂环境下的大规模无人机集群对抗问题具有重要价值，亟待进一步研究。综上所述，本文采用改进的多智能体强化学习算法，针对复杂环境下的大规模无人机集群博弈对抗问题展开深入研究。主要研究内容包括简单无人机集群博弈对抗问题、大规模无人机集群博弈对抗问题及复杂环境下的大规模无人机集群博弈对抗问题，并通过相应的仿真环境验证算法的有效性。

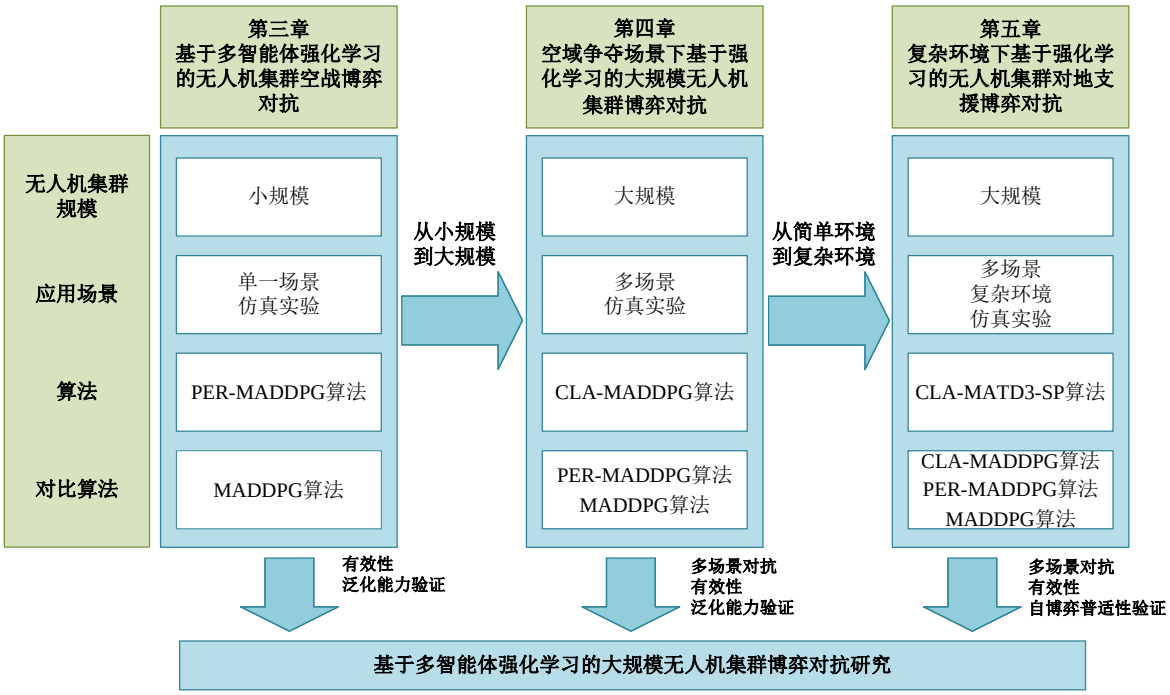


图 1-1 论文主要研究内容结构

论文主要研究内容如图 1-1 所示。为深入研究大规模无人机集群博弈对抗问题，本文按照由简到繁的思路逐步展开。首先，针对数量少于 10 的无人机集群对抗问题，本

中国知网　https://www.cnki.net

文将其转化为合适的马尔可夫决策问题，并提出了一种改进的 PER-MADDPG 算法。该算法通过引入优先经验回放机制优化网络训练过程，显著提升了样本利用效率和训练收敛速度，并在无人机集群对抗仿真环境中展现出了良好的有效性与泛化性。其次，针对大规模无人机集群空域争夺问题，本文考虑到无人机数量增加导致环境趋于更加复杂的情况，将 MADDPG 算法与课程学习训练策略相结合，保留 PER 机制，提出了 CLA-MADDPG 算法，该算法可以充分利用课程学习的难度等级设置，从而提高决策的准确性。在大规模无人机集群博弈对抗的仿真环境中，成功验证了该算法的有效性和泛化性。最后基于上述研究，针对复杂环境下无人机集群对地支援问题，提出了一种结合改进 MATD3 算法和自博弈训练框架的 CLA-MATD3-SP 算法，算法保留课程学习以及注意力机制，无人机集群的对抗策略进一步优化，最后在仿真环境中验证了算法的有效性以及自博弈框架的普适性。

本文的主要研究内容相互关联且层层递进。第三章对无人机集群空战对抗的研究为后续章节奠定了基础，第四章对大规模无人机集群空域争夺的研究是对复杂环境下对地支援研究的前置问题，第五章则进一步将研究拓展到复杂环境下的大规模集群博弈对抗，是对前两章内容的延伸与深化。这三章内容从小规模到大规模、从简单到复杂逐步深入，系统地扩展了无人机博弈对抗任务的研究范围。

1.4 论文组织结构

本文共分为六个章节，其中第三章到第五章为本文主要研究内容，以下为各个章节的主要内容：

第一章为绪论，主要介绍了论文的研究背景和意义，然后针对无人机集群博弈对抗、多智能体强化学习和基于强化学习的无人机集群博弈对抗的研究现状进行总结，最后介绍了本文主要研究内容和论文结构。

第二章对多智能体强化学习的基本理论进行介绍，分别介绍了传统强化学习方法、多智能体强化学习算法和基于多智能体强化学习的无人机集群对抗方法，为后续章节使用多智能体强化学习解决大规模集群对抗问题提供了理论基础。

第三章研究无人机集群空战问题。简单场景下小规模无人机集群对抗是复杂环境下无人机集群对抗问题的研究基础。对于该问题，本章首先建立定高飞行模式下的无人机运动学方程，为后续建模提供理论基础；进而构建马尔可夫决策过程框架，通过状态空间、动作空间及观测空间的数学表征，设计相应的奖励机制以引导智能体学习有效策略。在算法层面，提出 PER-MADDPG 算法，通过在经典 MADDPG 算法框架中引入优先经验回放机制，实现对关键经验样本的动态加权采样，有效提升策略迭代过程中的学习效率。为验证算法性能，基于自主构建的无人机集群空战仿真平台开展系统性实验，通过对比实验验证了算法在策略优化效率与泛化性能方面的优势。

第四章研究大规模无人机集群空域争夺问题。随着无人机集群规模逐步扩展，传统多智能体强化学习面临维度灾难、策略震荡加剧等挑战。因此对于该问题，本章首先基

中国知网 https://www.cnki.net

于大规模无人机集群博弈对抗问题构建了对应的马尔可夫决策过程并且设置了对应的奖励函数。其次，考虑到大规模对抗场景中存在的维度灾难及策略震荡问题，本章融合课程学习训练策略和注意力机制，提出了 CLA-MADDPG 算法，构建渐进式难度提升的课程训练体系，通过分阶段的集群规模扩展实现了无人机集群规模从 10 架到 50 架的平滑策略过渡。最后，在搭建的大规模集群对抗环境中验证了算法能够由易到难的让无人机集群学习到高效的对抗策略，并通过泛化性测试验证了所提出的算法具有较强的泛化性。

第五章研究复杂环境下的无人机集群对地支援问题。与简单高空对战对抗环境相比，复杂城市环境中障碍物的存在大幅提升了集群协同的挑战性，这对无人机间的协作能力提出了更高要求。本章首先针对该问题构建了相应的马尔可夫决策过程，并设计了适配的奖励函数。在算法设计方面，考虑到传统多智能体强化学习算法在复杂场景中易受误差累积影响，本章选用 MATD3 算法作为基础框架，以有效抑制误差传播。同时，沿用课程学习与注意力机制，并引入自博弈训练框架，提出了 CLA-MATD3-SP 算法。最终，通过复杂环境下的仿真实验，验证了所提算法在策略有效性和对抗能力方面的优势，并通过自博弈对抗分析进一步证实了自博弈训练框架的普适性。

第六章为总结与展望。对本文在大规模无人机集群博弈对抗问题的研究工作进行总结，分析了研究中的不足，并且对未来研究工作进行了展望。

中国知网　https://www.cnki.net

中国知网 https://www.cnki.net

第二章　多智能体强化学习基本理论

2.1　强化学习算法

2.1.1　强化学习基本概念

强化学习 (Reinforcement Learning, RL) 是一种基于环境交互的机器学习范式，其核心机制在于通过试错探索实现自主学习。智能体在执行动作后接收环境反馈的奖励信号，若获得正向激励，则其在后续相同状态下重复该动作的倾向性随之提升；反之若产生负面反馈，则相应行为的选择概率将受到抑制。这种学习模式通过持续积累环境交互产生的经验数据，动态调整模型参数，使得智能体逐步形成适应特定任务的最优决策机制。智能体与环境交互的过程如图 2.1 所示。

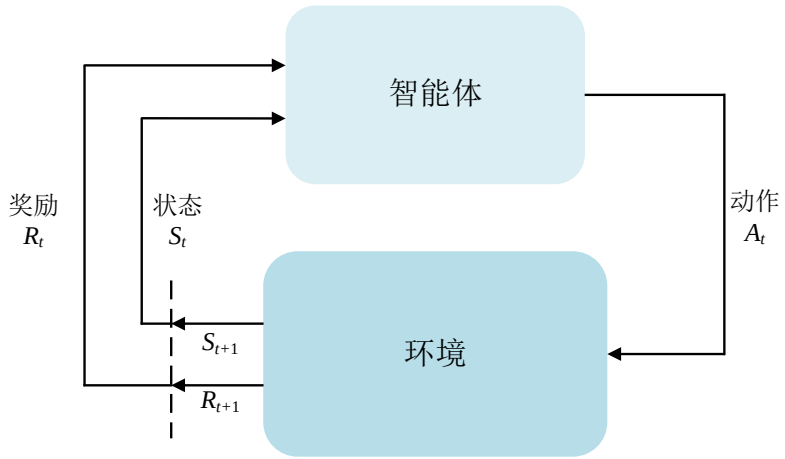


图 2-1 智能体与环境交互图

如图 2-1 所示，强化学习基本组成为：智能体（Agent，即进行学习的对象）、环境（Environment，除了智能体外的一切）、状态（State，环境的表征）、动作（Action，智能体的行为）、奖励（Reward，环境给予智能体的正/负反馈，用于对 Agent 的动作执行策略优劣的评价）。

智能体环境通常被建模为一个马尔可夫决策过程 (Markov Decision Process，MDP)，由一个五元组 (S, A, P, R, γ) 组成，其中 S 为状态空间集，包含所有可能的状态；A 为动作空间集，由所有可能的动作组成；P 为状态转移概率集，用来描述在某一状态采取某一动作后转移到下一状态的概率分布；R 为奖励函数，用来描述在某一状态采取某一动作后获得的奖励；$\gamma \in [0, 1]$ 为折扣系数，用来衡量未来奖励的重要性，即采取一次动作的决策，未来时间步的奖励被折扣为当前时间步的 γ 倍。

中国知网　https://www.cnki.net

智能体与环境交互的过程中，智能体在有限的时间步 $t = \{0, 1, 2, \cdots, n\}$ 内相互作用，环境为智能体提供状态集合 S 的当前状态 S_t，智能体在动作集中选择一个动作 A_t，在下一个时间步 $t+1$ 时刻，智能体执行动作 A_t 后对环境信息产生影响，环境产生新的状态 S_{t+1}，并生成上一轮动作的奖励值 R_t 反馈给智能体。智能体根据环境反馈的奖励，调整自身动作策略，再进入下一轮的决策。由于智能体在当前状态下所执行的动作会对后续状态和策略产生一定的影响，智能体在决策阶段并非以最大化即时奖励为目标，而是以最大化累积折扣奖励为最终任务目标。在强化学习过程中，智能体期望生成的最优决策方案通常与能够最大化每一个时间步的奖励值之和的方案相对应，其期望目标如式 (2.1) 所示：

$$E_\pi\{G_t \mid S_t = s\}, \quad G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \tag{2.1}$$

其中，G_t 是最大折扣累积奖励。π 表示智能体的策略函数，即 $\pi : S \to A$，表示智能体的环境状态序列与执行动作序列间的映射关系。

在强化学习中，价值函数作为策略性能的量化指标，可分为状态值函数 $V_\pi(s)$ 和动作值函数 $Q_\pi(s, a)$。状态值函数 $V_\pi(s)$ 表征智能体在初始状态 s 下，严格遵循策略 π 进行序列决策时所能获取的长期回报期望，定义如式 (2.2) 所示：

$$V_\pi(s) = E_\pi[G_t|S_t = s] = E_\pi[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1}|S_t = s] \tag{2.2}$$

动作值函数 $Q_\pi(s, a)$ 则进一步细化了评估维度，衡量智能体在状态 s 执行特定动作 a 后继续遵循策略 π 的预期累积收益，可表示为：

$$Q_\pi(s, a) = E_\pi[G_t|S_t = s, A_t = a] = E_\pi[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1}|S_t = s, A_t = a] \tag{2.3}$$

价值函数通常都会满足递归的特性，因此状态值函数 $V_\pi(s)$ 和动作值函数 $Q_\pi(s, a)$ 可以使用其迭代形式进行表示，根据贝尔曼方程 (Bellman Expectation Equation) 推导得到价值函数的迭代形式如下：

$$V_\pi(s) = E_\pi[R_{t+1} + V_\pi(S_{t+1})|S_t = s] \tag{2.4}$$

$$Q_\pi(s, a) = E_\pi[R_{t+1} + Q_\pi(S_{t+1}, A_{t+1})|S_t = s, A_t = a] \tag{2.5}$$

在强化学习理论框架中，核心目标是构建一个最优策略 π^*，使得智能体任意状态 $\forall s \in S$ 下，其状态价值函数 $V_{\pi^*}(s)$ 满足全局最优性条件：

$$V_{\pi^*}(s) \geq V_\pi(s), \ \forall \pi' \in \Pi, \ \forall s \in S \tag{2.6}$$

其中 Π 表示所有可行策略的集合，该最优策略 π^* 所对应的状态价值函数 $V_{\pi^*}(s)$ 被称为最优状态值函数, 可以表示为：

$$V_{\pi^*}(s) = \max_\pi V_\pi(s) \tag{2.7}$$

中国知网 https://www.cnki.net

同样在最优策略 π^* 下也存在最优动作值函数 $Q_{\pi^*}(s,a)$，$Q_{\pi^*}(s,a)$ 表示在任意状态 s，采取动作 a 可以获取到的最大奖励期望值，可以表示为：

$$Q_{\pi^*}(s,a) = \max_{\pi} Q_{\pi}(s,a) \tag{2.8}$$

所以最优策略 π^* 的求解可形式化表示为基于最优动作价值函数 $Q_{\pi^*}(s,a)$ 的贪婪策略选择过程。具体而言，当获得最优动作价值函数 Q^* 后，最优策略 π^* 在任意状态 $\forall s \in S$ 下将确定性选择使最大化 $Q_{\pi^*}(s,a)$ 的动作 a，其数学表达为：

$$\pi^*(s) = \begin{cases} 1 & if\ a = \text{argmax}_{a \in A} Q_{\pi^*}(s,a) \\ 0 & otherwise \end{cases} \tag{2.9}$$

在最优策略 π^* 下，最优状态值函数 $V_{\pi^*}(s)$ 的数学表征揭示了状态价值的全局最优性。其定义为从状态 s 出发遵循任意策略所能获得的最大期望回报，可形式化为贝尔曼最优方程的显式表达：

$$\begin{aligned} V_{\pi^*}(s) &= \max_{a \in A} Q_{\pi *}(s,a) \\ &= \max_{a} E[r_{t+1} + \gamma V_{\pi_*}(s_{t+1}) | S_t = s, A_t = a] \end{aligned} \tag{2.10}$$

同理，Q_{π^*} 的贝尔曼最优方程可以表示为：

$$Q_{\pi^*}(s,a) = E[R_{t+1} + \gamma \max_{a^*} Q_{\pi^*}(S_{t+1}, a^*) | S_t = s, A_t = a] \tag{2.11}$$

其中 a^* 表示在状态 S_{t+1} 使得 Q_{π^*} 最大的动作。

2.1.2　基于值函数的强化学习方法

基于值函数的强化学习方法的核心原理在于：智能体通过构建并优化状态-动作对的期望累积回报评估模型（即 Q 函数），在马尔可夫决策过程框架下实现策略的渐进式优化。具体而言，该方法要求智能体精确评估每个状态 s 下执行动作 a 的长期价值函数，并基于当前策略通过贪心准则选择可最大化期望回报的最优动作，当由此形成的新策略与当前策略存在差异时，智能体将通过学习更新至该更优策略。这一过程通过策略评估与策略改进的交替迭代持续推进，直至智能体收敛到最优策略。

Q-Learning[32]和 SARSA[60]算法作为强化学习中基于值函数的经典方法，均属于无模型时序差分学习框架，致力于在马尔可夫决策过程中通过动态规划逼近最优策略。二者通过构建状态-动作价值函数 $Q(s,a)$ 实现智能体决策优化。其中，$Q(s,a)$ 表示在特定状态 s 下采取动作 a 后所获长期累积回报的数学期望。其核心机制均采用贝尔曼方程的增量式更新规则，即结合即时奖励与下一时刻状态价值估计（时序差分目标）完成价值函数迭代修正，SARSA 更新公式如下：

$$Q(s,a) \leftarrow Q(s,a) + \alpha \left[r + \gamma Q(s',a') - Q(s,a) \right] \tag{2.12}$$

中国知网　https://www.cnki.net

其中，s 是当前状态，a 是当前动作，r 是当前状态下采取动作 a 获得的即时奖励，s' 是在采取动作 a 后转移到的下一个状态，a' 是在下一个状态下的最大 Q 值对应的动作，γ 是折扣因子，α 是学习率。

SARSA 算法作为典型的在线策略 (on-policy) 算法，其核心特征在于策略评估与改进的同步性，更新 Q 值时采取的下一动作必须基于当前策略实际选择的动作，这种机制使得算法在训练过程中始终遵循" 探索-利用平衡" 原则，既通过 ε 概率的随机动作扩大状态覆盖，又利用最大 Q 值动作提升策略质。

Q-Learning 是离线策略 (off-policy) 强化学习方法，其核心优势在于目标策略与行为策略的分离机制。在实际问题中，当直接遵循最优策略进行探索面临困难时，Q-Learning 支持智能体通过执行非最优动作进行环境探索，同时仍能通过迭代更新收敛至最优策略。该算法在状态-动作价值函数的更新规则中引入最大化 (max) 操作，有效降低了环境噪声对价值估计的干扰。具体而言，Q-Learning 从任意初始 Q 值出发，通过持续迭代更新状态-动作对的价值估计，最终收敛于最优策略。Q-Learning 更新公式如下：

$$Q(s,a) \leftarrow Q(s,a) + \alpha \left[r + \gamma \max_{a} Q(s',a') - Q(s,a) \right] \tag{2.13}$$

Q-Learning 算法与 SARSA 算法的主要区别在于策略选择方式的不同。Q-Learning 算法的行动策略采取的是 $\varepsilon - greedy$ 策略选取动作，而评估策略采用贪婪策略直接选取使得 Q 值最大的动作，即其行动策略与评估策略不一致，因此 Q-Learning 算法被认为是离线策略算法。相比之下，SARSA 算法的行动策略和评估策略均采用 $\varepsilon - greedy$ 策略选取动作，行动策略与评估策略保持一致，所以 SARSA 是一种在线策略算法。Q-Learning 与 Sarsa 算法的具体实现分别如算法 2.1 和算法 2.2 所示。

算法 2.1 Q-Learning 算法

对于所有 $s \in S, a \in A(s)$，随机初始化 $Q(s,a)$
for 回合数 to 最大回合数 **do**
  初始化 s
  while s 不是终止状态 **do**
    在状态 s 时根据行动策略 ($\varepsilon - greedy$ 等) 选择动作 a
    执行动作 a，得到 r，s'
    $Q(s,a) \leftarrow Q(s,a) + \alpha \left[r + \gamma \max_a Q(s',a') - Q(s,a) \right]$
    $s \leftarrow s'$
  end while
end for

当状态与动作空间规模显著增大时，传统 Q-Learning 直接存储和更新 Q 值表的方式会导致计算复杂度急剧上升。作为 Q-Learning 的深度神经网络改进版本，DQN[35]DQN 通过函数逼近方法解决这一问题，其核心是利用深度神经网络近似状态 - 动作价值函

中国知网 https://www.cnki.net

算法 2.2 Sarsa 算法

对于所有 $s \in S, a \in A(s)$，随机初始化 $Q(s,a)$
for 回合数 to 最大回合数 **do**
　初始化 s
　在状态 s 时根据行动策略 ($\varepsilon - greedy$ 等) 选择动作 a
　while s 不是终止状态 **do**
　　执行动作 a，观测到 r，s'
　　在状态 s' 时根据行动策略 ($\varepsilon - greedy$ 等) 选择动作 a'
　　$Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma Q(s',a') - Q(s,a)]$
　　$s \leftarrow s'$，$a \leftarrow a'$
　end while
end for

数，避免了显式存储高维 Q 值表，从而降低存储与计算成本。该算法通过经验回放 (experience replay) 和目标网络 (target network) 两大机制提升稳定性与收敛性：经验回放技术通过构建回放内存池存储智能体与环境交互产生的序列样本，并以随机小批量采样方式训练网络，利用样本间的低时序相关性减少训练数据偏差，提高样本利用效率；目标网络机制则通过引入与在线网络结构相同但参数更新频率不同的独立网络，生成用于计算目标 Q 值的稳定目标信号，避免因当前网络参数频繁更新导致的价值估计偏移累积问题。具体而言，在线网络负责实时预测当前状态动作对的 Q 值，目标网络则周期性同步在线网络参数并用于计算下一状态的目标 Q 值，通过这种参数分离机制抑制训练过程中的模型波动。上述改进使 DQN 能够从任意初始参数出发，通过迭代优化神经网络权重逼近最优策略，算法具体流程如算法 2.3 所示。

2.1.3　基于值函数和策略梯度结合的强化学习方法

尽管 DQN 算法在处理高维离散状态-动作空间时展现出显著优势，但其核心设计仍受限于离散动作空间的约束。当面对连续状态-动作空间时，传统离散化方法虽可通过划分区间将连续变量转化为离散值，但由此引发的维度爆炸问题会显著降低算法效率：对于 n 维连续空间，若每维离散化为 k 个区间，总状态数将激增至 k^n 量级，导致神经网络参数规模与训练数据需求呈指数级增长。这种维度灾难不仅造成计算资源浪费，还会削弱模型对状态-动作关联性的捕捉能力，尤其在自动驾驶、机器人控制等需要精细动作调节的场景中，离散化带来的信息损失可能导致策略次优化

针对传统值迭代方法在连续状态-动作空间建模中的表征局限性，研究者们构建了 Actor-Critic 框架，将基于价值迭代和基于策略迭代的强化学习算法相结合。在该框架中，Actor 网络和 Critic 网络分别由在线网络和目标网络两部分组成。训练过程中，在线 Actor 网络和在线 Critic 网络通过随机梯度优化实现策略梯度与价值函数的动态适配，

中国知网　https://www.cnki.net

算法 2.3 DQN 算法

初始化经验池 D，经验池最大容量 N，在线网络参数 θ，目标网络参数 θ'
for episode = 1 to M **do**
  初始化状态 s_1
  for $t = 1$ to T **do**
    以概率 ε 选择随机动作 a_t，否则根据 $a_t = \underset{a}{\text{argmax}}\, Q(s_t, a, \theta)$ 选择动作
    执行动作 a_t，获得奖励 r_t 和下一时刻状态 s_{t+1}
    设置 $s_t = s_{t+1}$
    存储经验数据 (s_t, a_t, r_t, s_{t+1}) 到经验池 D
    从经验池 D 随机采样小批量数据 (s_j, a_j, r_j, s_{j+1})
    设置 $y_j = \begin{cases} r_j & if\ \text{episode} == j+1 \\ r_j + \gamma \max\limits_{a} \hat{Q}(s_{j+1}, a, \theta') & otherwise \end{cases}$
    使用梯度下降法更新 $(y_j - Q(s_j, a_j, \theta))^2$ 中的网络模型参数 θ
    每 C 步更新目标网络
  end for
end for

而目标 Actor 网络和目标 Critic 网络则采用渐进式参数同步机制维持学习稳定性。在所有在线网络完成更新后，目标网络采用软更新的方式进行参数迭代。这种分离式更新策略有效平衡了探索-利用的矛盾，使系统在连续控制任务中实现可靠收敛。Actor-Critic 框架的提出赋予了智能体处理具有连续状态-动作空间问题的能力，因此衍生出大量基于 Actor-Critic 框架的改进算法，如 DDPG 算法[38]，异步优势演员评论家算法 (Asynchronous Advantage Actor-Critic，A3C)[61]，信赖域策略优化算法 (Trust Region Policy Optimization, TRPO)[62]以及近端策略优化算法 (Proximal Policy Optimization, PPO)[63]等。

DeepMind 团队基于 Actor-Critic 框架创新性地融合 DQN 算法与策略网络相结合，构建了 DDPG 算法。该算法采用双网络结构：Actor 网络通过确定性策略函数实现状态空间到连续动作空间的映射，Critic 网络则构建状态-动作价值函数 $Q(s, a)$ 评估 Actor 网络的策略。其核心创新体现在引入深度神经网络的层次化特征提取机制，既保留策略梯度方法的连续动作生成能力，又兼具价值迭代算法对动作效用的动态评估特性。通过在线网络与目标网络的参数解耦设计，结合经验回放与延迟更新技术，有效解决了连续控制场景下价值函数估计偏差与策略更新不稳定问题。DDPG 算法框架如图 2-2 所示。

经典随机决策模型通过概率分布实现动作选择，而 DDPG 算法创新性地采用确定性策略生成机制。该算法中的 Actor 网络通过参数化策略函数逼近，直接将状态空间映射为确定性动作输出，而非传统方法中的概率分布采样。这种机制使网络能够建立状态空间到动作空间的确定性映射，从而消除随机策略中动作选择的方差干扰。其核心突破在于通过端到端的深度神经网络架构，将策略函数建模为连续状态下的最优动作生成

中国知网 https://www.cnki.net

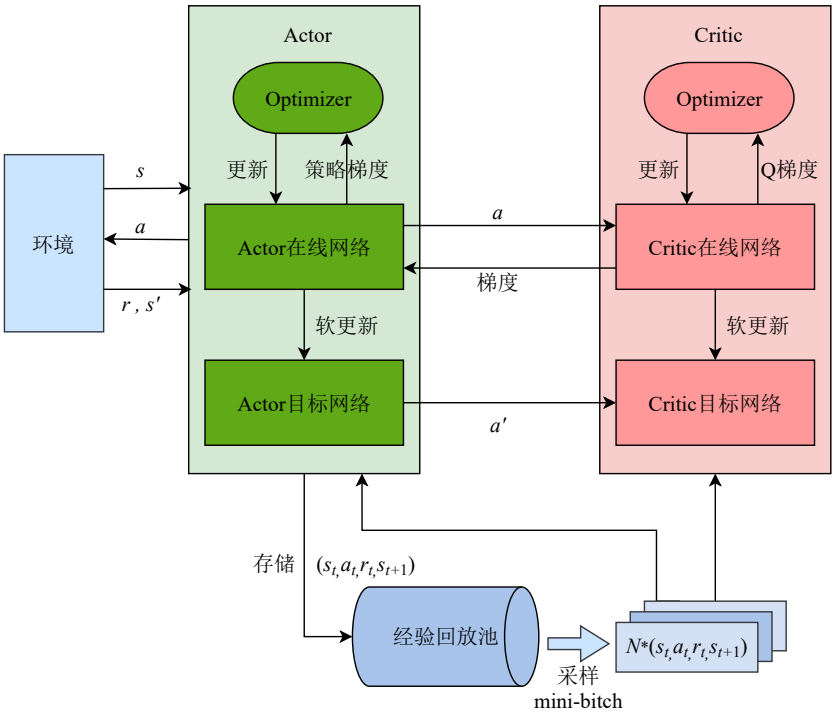


图 2-2 DDPG 算法框架

器，而非对动作概率分布进行离散化估计，这种确定性策略优化机制显著提升了连续控制任务中动作序列的稳定性与收敛效率。Actor 网络的更新目标函数如式 (2.13) 所示：

$$J(\theta^{\mu}) = E_{\theta^{\mu}}\{r_1 + \gamma r_2 + \gamma^2 r_3 + \ldots\} \tag{2.14}$$

式中：θ^{μ} 为 Actor 网络参数。Q^{μ} 表示智能体在状态 s 下根据策略 μ 选择动作 a 后能够获得的累积折扣奖励期望值，Critic 网络对该期望值进行拟合，如式 (2.14) 所示：

$$Q^{\mu}(s,a) = E\{r(s,a) + \gamma Q^{\mu}(s',a')\} \tag{2.15}$$

Actor 网络参数采用梯度下降的方法进行参数更新，Actor 网络的更新梯度如式 (2.15) 所示：

$$\nabla_{\theta^{\mu}} J(\mu) = E_{s\sim p}\{\nabla_{\theta^{\mu}}\mu(s)\cdot Q^{\mu}(s,a)|_{a=\mu(s)}\} \tag{2.16}$$

式中的网络参数更新梯度即为策略梯度。DDPG 算法的训练目标为最小化 Critic 网络的损失函数 L，同时最大化 Actor 网络的目标函数 $J(\theta^{\mu})$，Critic 网络的损失函数如式 (2.16) 所示：

$$L(\theta) = \frac{1}{N}\cdot\sum_{i=1}^{N}\left\{\left[y_i - Q^{\mu}(s_i,a_i;\theta^{Q})\right]^2\right\} \tag{2.17}$$

中国知网　https://www.cnki.net

针对单 Critic 网络在策略评估与参数更新耦合场景下引发的训练失稳问题，DDPG 算法设计了双网络结构以优化强化学习过程。该框架通过复制在线 Actor-Critic 网络生成具有参数解耦特性的目标网络组，形成策略评估与梯度计算的物理隔离。在参数优化过程中，目标网络作为基准评估器为在线网络提供稳定的价值梯度信号，其自身则通过软更新机制 (Soft Target Update, STU) 实现渐进式参数同步，即每次迭代仅以微小比例融合在线网络参数。这种延迟更新策略通过降低目标网络与在线网络间的参数耦合度，有效抑制了传统单网络架构中因同步参数更新引发的价值估计震荡现象，从而显著提升策略优化过程的收敛稳定性。目标网络的参数更新如式 (2.17) 所示:

$$\theta' \leftarrow \tau\theta + (1-\tau)\theta' \tag{2.18}$$

式中：$\tau(\tau \ll 1)$ 为软更新系数，该系数通过将目标网络的参数调整幅度控制在较小范围，使其以渐进方式缓慢更新，避免了目标函数值在短时间内的剧烈波动，从而保障了网络学习过程的稳定性。相较于 DQN 算法，DDPG 算法在处理连续状态 - 动作空间问题时，凭借该机制显著提升了策略模型学习的稳定性、网络训练效率及决策速度。

2.2 多智能体强化学习算法

2.2.1 多智能体马尔可夫决策过程

在复杂动态环境中，传统深度强化学习方法驱动的单一智能体模型常因感知与决策维度受限难以有效应对高复杂度任务，这推动研究者将研究范式拓展至多智能体协同系统领域。此类系统通过整合多个具备自主决策能力的个体单元，利用智能体间的异构特性实现动态协同与资源整合。研究表明，多智能体框架下的分布式学习机制不仅能突破单一智能体的性能瓶颈，其群体智能的协同效应更使得系统整体效能显著优于单智能体的简单叠加，尤其在无人机编队、城市交通控制等场景中的任务适应性与鲁棒性方面展现出明显优势。多智能体系统与环境的交互过程如图 2-3 所示。

这种情况下，单智能体的 MDP 在多智能体环境中的扩展被称为马尔科夫博弈 (Markov Game, MG)。MG 通常由元组 (n, S, A, T, R) 所表示，其中 n 表示参与博弈的智能体的数量；S 表示联合状态，即 $S = [S_1, \cdots, S_n]$；A 表示联合动作，即 $A = [A_1, \cdots, A_n]$；T 为状态转移函数，表示多智能体系统在联合状态 S 下执行联合动作 A 后对应的状态转移概率；R 表示联合奖励函数，而对多智能体系统的求解过程等价于生成一组联合策略 $\pi = [\pi_1, \cdots, \pi_n]$ 以最大化系统最终获得的联合奖励值。

虽然深度强化学习算法在处理具有连续状态-动作空间的问题时展现出了巨大的优势，但传统的单智能体算法（如 DQN 和 DDPG）通常难以直接应用于多智能体问题。随着智能体数量的增加，状态-动作空间呈指数级增长，这不仅大幅增加了计算所需的资源，还导致模型训练的难度上升。在多智能体系统中，策略模型的动态更新机制会引发复杂的协同优化困境。由于智能体间的策略存在耦合效应，单个智能体的策略迭代更新

中国知网 https://www.cnki.net

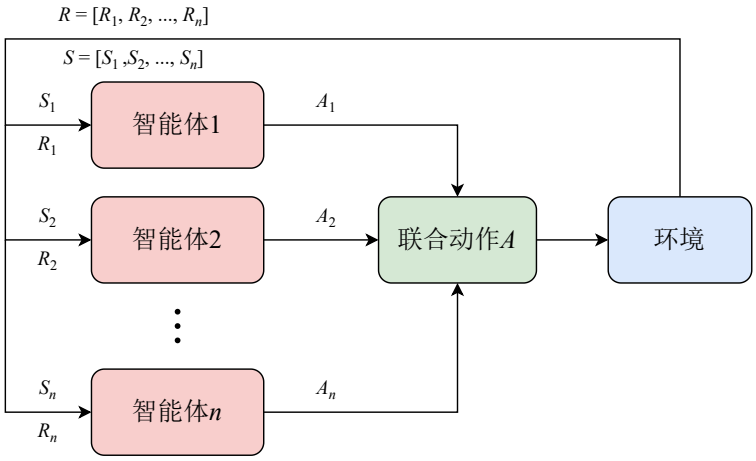


图 2-3 多智能体系统与环境的交互图

会触发其他智能体的自适应调整，这种连锁反应导致 MG 的全局最优解呈现时变特性，尤其在非平稳环境下加剧了策略模型的收敛难度。智能体在进行自主决策时，不仅需要解析局部状态信息与观测数据，还必须通过信息共享机制整合外部智能体的行为特征。然而，当系统内存在目标冲突或竞争关系时，智能体对同伴策略的预测行为会显著放大环境的不确定性，致使算法在迭代过程中易陷入震荡状态或局部次优策略空间。上述问题也进一步表明，单智能体算法以完全分布式的方式应用于多智能体问题时，通常难以获得有效的策略模型。

2.2.2　多智能体深度 Q 网络算法

当前多智能体强化学习算法根据架构设计差异可分为集中式与分布式两大范式。集中式架构采用统一建模策略，将多智能体系统视为整体进行协同训练，通过中央控制器实现全局策略协调。在此框架下，所有智能体共享同一策略更新模块，训练阶段中央控制器基于联合状态空间生成个体行为策略。然而，这种强耦合架构难以充分挖掘智能体间的协同效应，导致策略学习效率受限。

相较于集中式架构的全局控制特性，分布式学习范式强调智能体的自主决策能力。该范式为每个智能体配置独立的学习模型，通过局部观测实现策略的分布式优化。其中的典型代表多智能体深度 Q 网络算法 (Multi-Agent Deep Q Network, MADQN) 算法将经典 DQN 框架拓展至多智能体领域，基于分布式学习理论构建技术体系。其核心设计理念在于：每个智能体基于自身观测独立更新 Q 网络，通过最大化个体价值函数实现策略优化。这种去中心化的架构设计不仅增强了系统的扩展性，更有效适应了复杂动态环境下的实时决策需求。

然而，MADQN 算法虽然突破了传统算法的部分局限，但将单智能体 DQN 简单迁移应用于多智能体场景仍面临显著挑战。其一，局部观测带来的环境不确定性。由于智

中国知网　https://www.cnki.net

能体仅能获取有限的环境信息，其他智能体的状态空间和行为策略构成不可观测变量，这种信息缺失直接导致个体策略的马尔可夫决策过程发生本质改变。具体表现为环境动态特性随其他智能体策略更新而持续变化，造成策略模型的收敛稳定性显著降低。其二，经验回放机制的有效性衰减问题。在多智能体协同场景下，传统的经验采样方法难以准确表征系统状态的关联特征，这种特征表达的局限性容易引发策略模型陷入局部最优陷阱，特别是在非平稳环境中的策略退化现象尤为突出。

2.2.3 多智能体深度确定性策略梯度算法

单智能体算法难以直接适配多智能体场景，原因在于多智能体环境中各智能体更新策略与决策时需对其他智能体行为进行预测，而若智能体目标存在差异，这种交互预测会导致环境动态性增强、稳定性下降，进而显著提升策略模型收敛的难度。针对多智能体系统中单智能体算法直接迁移的可行性障碍，OpenAI 团队提出的 MADDPG 算法[45]构建了异构网络协同优化框架。该算法采用“集中式评价-分布式执行”的混合架构：训练阶段通过中心化 Critic 网络整合全局状态空间与联合动作空间信息，为各智能体 Actor 网络提供策略梯度修正的基准信号；执行阶段则仅依赖局部观测信息进行分布式动作决策。其核心创新在于通过中心化 Critic 的全局信息建模能力，有效解决多智能体策略空间的动态耦合问题。当智能体目标存在分歧时，Critic 网络通过联合动作价值函数的隐性协调机制，抑制因策略相互预测引发的环境状态震荡。这种机制在维持策略独立性的同时，利用全局价值引导实现多智能体策略的协同优化，显著降低策略更新的方差累积效应，使系统在部分可观测条件下仍能收敛至近似纳什均衡状态。MADDPG 算法的结构如图 2-4 所示。

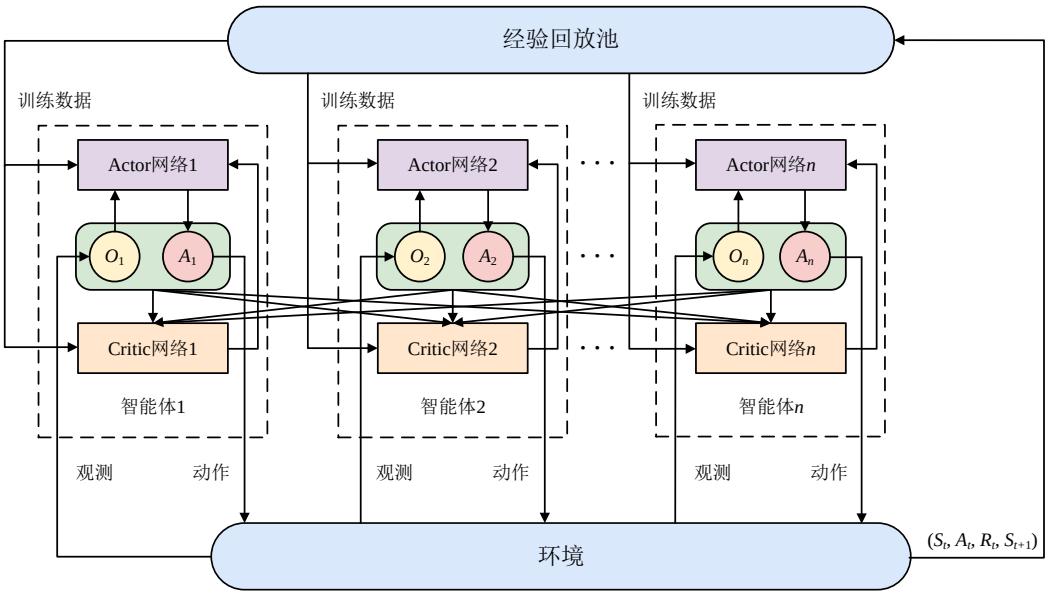


图 2-4 MADDPG 算法结构图

基于 DDPG 算法原理，Critic 网络以智能体状态序列与 Actor 网络输出的动作序列

中国知网 https://www.cnki.net

构成的状态-动作对为输入，通过输出状态-动作价值函数实现对策略的评估，其评估结果为 Actor 网络提供策略修正的反馈信号。训练完成后，智能体仅通过 Actor 网络与环境交互，由该网络根据输入状态生成对应动作序列以完成决策。

与 MADQN 算法不同的是，MADDPG 算法继承 DDPG 的 Actor-Critic 架构并扩展至多智能体场景，构建分布式执行-集中式训练框架。其核心机制体现为：训练阶段 Critic 网络通过全局状态空间与联合动作空间的关联建模，为各智能体的 Actor 网络提供协同策略梯度信号，而执行阶段各智能体仅依赖局部观测信息进行分布式决策。在此过程中，Actor 网络基于局部感知数据生成确定性策略动作，Critic 网络则利用全局信息动态评估联合动作价值函数，形成策略解耦优化机制。这种架构—通过集中式 Critic 的全局价值引导，智能体在仅获取局部状态信息时仍能有效建模其他智能体的策略分布，创新性地解决了部分可观测环境下多智能体策略预测难题。

2.3　基于多智能体强化学习的无人机集群对抗技术

多智能体深度强化学习技术在多无人机博弈对抗领域实现了创新性融合，通过构建异构网络架构显著提升无人机集群的动态博弈能力。在典型的多智能体强化学习框架中，各无人机单元被建模为独立智能体，其 Actor 网络基于局部观测信息 S_{local} 输出个体动作 A_{local}，而 Critic 网络则整合集群联合观测信息 S_{global} 与联合动作信息 A_{global} 输出联合观测-动作价值函数 $Q(S_{global}, A_{global})$。该架构通过局部决策与全局评估的协同优化机制，有效解决了无人机集群博弈中的策略动态耦合问题，使无人机集群在缺乏全局信息共享条件下仍能实现高效协同策略优化。基于多智能体强化学习算法的无人机集群博弈对抗模式如图 2-5 所示。

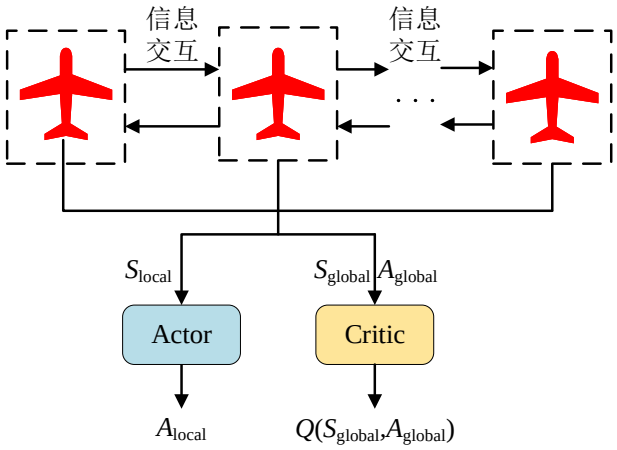


图 2-5 无人机集群博弈对抗模式

多智能体强化学习在无人机集群博弈对抗任务中展现出独特的策略优化特性，其决

中国知网　https://www.cnki.net

策机制建立于当前状态空间的实时映射而非依赖历史动作。这种无记忆性策略建模通过解耦历史状态依赖性，有效降低博弈对抗场景下的计算负载并提升响应速度。相较于传统时序关联决策模型，该机制通过状态-动作的即时映射关系构建马尔可夫决策过程，使无人机集群在环境状态突变时能够快速生成适应性的动作策略。这种基于当前状态空间的策略生成模式不仅显著提高无人机集群的决策频率，其策略空间的动态重构能力更赋予无人机集群在博弈对抗中灵活的战术调整优势。

2.4 本章小结

本章主要介绍了多智能体强化学习的理论基础。首先介绍了强化学习的基本概念，包括马尔可夫决策过程、状态值函数和动作值函数等。其次，从值函数方法、策略梯度方法以及值函数与策略梯度相结合的方法三个方面，对常用的单智能体强化学习算法进行了详细介绍。随后，对多智能体马尔可夫博弈以及常用的多智能体强化学习算法MADDPG 进行了阐述。最后，简要介绍了多智能体强化学习在无人机集群对抗中的应用，为后续研究内容提供了理论基础。

中国知网 https://www.cnki.net

第三章　基于多智能体强化学习的无人机集群空战博弈对抗

3.1　引言

随着无人机集群作战在现代军事对抗中的重要性日益凸显，如何实现多无人机在动态对抗场景下的自主协同决策已成为亟待攻克的关键挑战。无人机集群博弈对抗本质可建模为多智能体动态不完全信息博弈问题，其决策过程需综合处理高维连续状态空间建模、异构智能体交互耦合以及实时战术策略生成等关键挑战。传统基于规则的控制范式在处理高维连续状态空间和实时动态博弈需求时，普遍存在策略生成单一与环境适应性不足的固有缺陷。本章针对无人机集群空战场景，首先建立了固定翼无人机在定高飞行状态下的运动学模型，然后基于无人机集群博弈对抗问题构建了对应的马尔可夫决策过程，并且设置了对应的奖励函数，并提出一种融合优先经验回放机制的改进多智能体深度确定性策略梯度算法，该算法基于时序差分误差动态调整经验样本优先级，有效缓解了稀疏奖励场景下的样本利用偏差。最后，在搭建的无人机集群对抗环境中仿真环境中，验证了该算法在解决无人机集群对抗问题上的有效性以及模型的泛化能力。

3.2　问题建模

3.2.1　无人机运动模型

本文训练的智能体对象为固定翼无人机，无人机运动学可以由六自由度模型描述。由于无人机集群对抗问题的复杂性和现实战场空间相对于无人机尺寸的开阔性，为了简化博弈对抗问题的复杂度，本文忽略无人机飞行高度这一空间维度，假定无人机始终保持等高飞行。无人机俯仰角、横滚角和偏航角共同决定的机身姿态映射为平面内的航向角变化。航向角定义为前进方向和环境坐标系 X 轴正方向的夹角 ψ。因此无人机运动学模型简化为如式 (3.1) 所示。

$$\begin{cases} \dot{x} = v\cos\psi \\ \dot{y} = v\sin\psi \\ \dot{v} = \frac{F}{m} \end{cases} \tag{3.1}$$

其中 (x, y) 为无人机在 $X-Y$ 平面中的坐标位置，v 为无人机运动速度，ψ 为航向角，F 为无人机受到的推力，m 为无人机质量。

由于无人机自身机能和对战环境限制，无人机的速度和加速度不能无限大。在二维的仿真对战平台中，无人机的航向速度 v、航向角速度 $\dot{\psi}$ 以及航向加速度 a 要满足最大值约束：

中国知网　https://www.cnki.net

$$\begin{cases} |v| \leq v_{\max} \\ |\dot{\psi}| \leq \dot{\psi}_{\max} \\ |a| \leq a_{\max} \end{cases} \tag{3.2}$$

3.2.2 无人机空战博弈对抗模型

在无人机对抗过程中，本文设计了如图 3-1 的无人机空战博弈对抗模型，每个无人机配备一个最大探测半径为 d_{max}，最大探测角度为 θ_{att} 的雷达探测器，该探测器的上下边界与无人机航向方向夹角为 $\pm\theta_{att}/2$。在该探测范围内无人机可以探测到敌方无人机，并对敌方无人机发射空对空导弹，因此雷达探测器范围形成的一个扇形区域可以定义为无人机的攻击区域。相应地，敌方无人机也配备了相同的雷达探测器。对空导弹有不可逃逸距离，因此，无人机在其航向方向的反方向存在一个扇形的防御盲区，即危险区域。该扇形区域的上下边界与无人机航向方向的反方向夹角为 $\pm\theta_{dan}/2$，扇形区域的的半径等于雷达探测器最大探测半径 d_{max}。如果敌方无人机在我方无人机的危险区域中发射空对空导弹攻击，那么我方无人机将无法躲避。

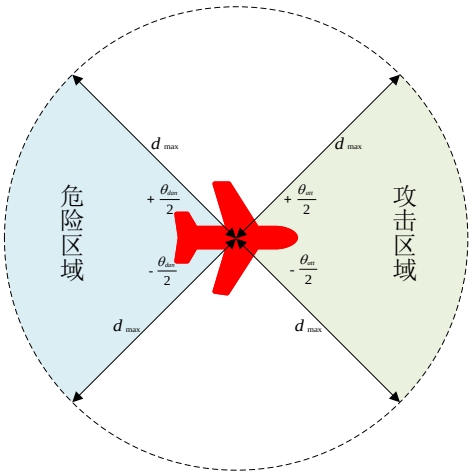


图 3-1 无人机空战博弈对抗模型

因此，根据无人机空战博弈对抗原则，如图 3-2 所示，当红蓝双方无人机在空战对抗中同时满足以下双重约束时，此时红方无人机对蓝方无人机发射空对空导弹可以视为一次有效攻击，可以确保击毁敌方无人机：1）被攻击无人机位于攻击无人机的攻击区域；2）攻击无人机位于被攻击无人机的危险区域。

中国知网 https://www.cnki.net

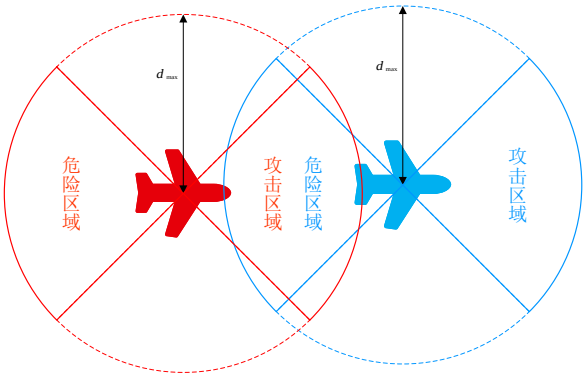


图 3-2 无人机有效攻击示意图

3.2.3　无人机集群空战环境模型

本章构建了标准化二维无人机空战对抗环境，用于验证算法在基础空战场景下的有效性。红蓝双方各配置固定数量 N 的同构无人机，部署于限定空域左右两侧的初始位置。在 $X-Y$ 平面构成的二维正方形对环境景中，双方无人机集群沿 X 轴方向向中心战略区发起对抗，该区域被定义为以坐标系原点为中心，边长为正方形对抗环境的一半的核心战略要地。所有无人机遵循严格的运动学约束，独立配备脉冲雷达及两枚空对空导弹。当敌方目标进入雷达探测范围时，无人机可发射导弹实施攻击，导弹采用比例导引法追踪目标，若与目标距离小于 5m 则判定击毁。对抗终止条件为任意方全员损毁或达到预设对战时长，胜负判定遵循如下机制：首先对比中心战略区域内双方无人机的数量；若数量持平，则统计全区域内存活单位，剩余无人机数量多的一方获胜；若仍无法决出胜负，则判定为平局。该判定机制通过赋予中心战略区域更高的战术权重，充分突显核心作战区域在空战博弈对抗中的决定性价值。

由于空战环境有范围限制，故环境模型对双方无人机都有边界约束，红方无人机 i 的坐标 (x_i, y_i) 和蓝方无人机 j 的坐标 (x_j, y_j) 必须满足如下约束：

$$\begin{cases} -x_{\max} \leq x_i, x_j \leq x_{\max} \\ -y_{\max} \leq y_i, y_j \leq y_{\max} \end{cases} \tag{3.3}$$

其中，$x_{\max}$ 是无人机在 x 轴的最大飞行范围，$y_{\max}$ 是无人机在 y 轴的最大飞行范围。

3.2.4　无人机集群空战博弈对抗 MDP 模型

本节根据无人机集群空战博弈对抗的特点，将无人机集群空战任务建模为马尔可夫决策过程，下面详细介绍马尔可夫决策过程的相关元素。

状态空间：对于集群中的无人机 i，其局部观测空间 O^i 由无人机状态信息 O_1^i 和雷达探测器状态信息 O_2^i 所组成，可以表示为：

$$O^i = [O_1^i, O_2^i] \tag{3.4}$$

中国知网　https://www.cnki.net

无人机状态信息 O_1^i 包括自身坐标、速度和航向角信息，其中 x_i 和 y_i 表示自身位置的横纵坐标，v_i 表示自身速度信息，ψ_i 表示自身航向角信息，如式 (3.5) 所示。

$$O_1^i = [x_i, y_i, v_i, \psi_i] \tag{3.5}$$

此外，无人机还可以根据雷达的观测范围，确定检测到最近的敌方无人机 j 的位置信息以及敌机的航向角信息（用于判断我方无人机是否在敌方无人机的威胁区域内）作为雷达探测器状态信息 O_2^i，x_j 和 y_j 表示敌机位置的横纵坐标，$\Delta\psi_{ij}$ 表示无人机 i 与敌机 j 之间的航向角之差，若是没有检测到敌方无人机则信息均为 0，如式 (3.6) 所示。

$$O_2^i = [x_j, y_j, \Delta\psi_{ij}] \tag{3.6}$$

由此可以得到无人机集群的联合观测空间 O 如下式所示：

$$O = [O^1, O^2, \ldots, O^N] \tag{3.7}$$

动作空间：根据本章构建的无人机运动模型，将控制无人机动作的输入设计为单位时间内航向角改变量和单位时间内速度改变量两个有限范围内的连续量。因此，无人机 i 动作空间定义为 $A^i = [a_i, \dot{\psi}_i]$，参数依次是无人机航向加速度 a_i 和航向角速度 $\dot{\psi}_i$。参数的取值是连续有界，受到无人机建模中的运动约束限制，因此，该动作空间是一个连续空间。无人机集群的联合动作空间 A 如下式所示：

$$A = [A^1, A^2, \ldots, A^N] \tag{3.8}$$

奖励函数：对于无人机集群博弈对抗问题，若要等双方完整对抗后才得到一个回合的奖励值，其奖励值延迟性太强。因此，为了提高算法整体的学习效率，引入过程中的奖励值。由于无人机集群博弈对抗问题的最终目标是通过集群协同击败敌方，故将无人机集群的每一时间步的过程奖励定义为集群内所有无人机的奖励之和 R_t：

$$R_t = R_t^1 + R_t^2 + \ldots + R_t^N \tag{3.9}$$

对于每个无人机 i，奖励 R_t^i 包括四个部分，分别为击毁奖励，被击毁奖励，出界奖励，中心奖励。

$$R_t^i = R_{\text{destroy}} + R_{\text{destroyed}} + R_{\text{outside}} + R_{\text{center}} \tag{3.10}$$

（1）击毁奖励 R_{destroy}

当无人机击毁敌方无人机后，对本方无人机集群有利，因此给予一个正奖励，R_{destroy} 定义如下：

$$R_{\text{destroy}} = \begin{cases} r_{\text{d}}, & \text{if 击毁敌方无人机} \\ 0, & \text{otherwise} \end{cases} \tag{3.11}$$

中国知网 https://www.cnki.net

（2）被击毁奖励 $R_{\text{destroyed}}$

当无人机被敌方无人机击毁后，对本方无人机集群不利，因此给予一个负奖励，$R_{\text{destroyed}}$ 定义如下：

$$R_{\text{destroyed}} = \begin{cases} -r_{\text{d}}, & \text{if 被敌方无人机击毁} \\ 0, & \text{otherwise} \end{cases} \tag{3.12}$$

（3）出界奖励 R_{outside}

为了确保无人机在规定的作战区域内进行博弈对抗，若无人机脱离规定的作战区域，则应给予惩罚。因此，当无人机出界时，会给予一个负奖励，R_{outside} 定义如下：

$$R_{\text{outside}} = \begin{cases} -r_{\text{o}}, & \text{if 无人机出界} \\ 0, & \text{otherwise} \end{cases} \tag{3.13}$$

（4）中心奖励 R_{center}

根据 3.2.3 中空战环境模型定义，为了确保无人机集群在博弈对抗初期时能够朝着空战环境的中心战略区域方向飞行，并在一定程度上解决博弈对抗初期时的稀疏奖励问题，当无人机在作战区域的中心战略区域外部时，会根据距离给予一个负奖励。相反，当无人机处于中心战略区域时会给予正奖励，R_{center} 定义如下：

$$R_{\text{center}} = \begin{cases} -k_{\text{c}} * d_{\text{u,c}}, & \text{if 无人机不位于中心战略区域} \\ r_{\text{c}}, & \text{otherwise} \end{cases} \tag{3.14}$$

其中 k_{c} 为中心奖励调节系数，$d_{\text{u,c}}$ 是当前时刻无人机与中心战略区的最短距离。

3.3　基于 PER-MADDPG 算法的无人机集群博弈对抗算法设计

3.3.1　算法框架结构

无人机集群对抗作为复杂动态环境下多智能体协同控制的典型场景，其核心问题可建模为多智能体强化学习框架下的分散决策优化问题。当前，基于集中式训练-分布式执行 (Centealized Training and Decentralized Execution, CTDE) 范式的 MADDPG 算法已成为领域的主流方法之一。该算法通过构建集中式价值网络与分布式策略网络的 Actor-Critic 协同架构，实现了全局信息指导下的局部策略优化。

虽然 MADDPG 算法在多智能体系统领域取得了显著进展，但其在复杂对抗环境中仍面临两大关键挑战：奖励信号稀疏性导致的学习效率低下和基于均匀采样的经验回放机制引发的低质量经验样本高频率抽取问题。优先经验回放 (Prioritized Experience Replay, PER) 机制通过引入优先级机制提升经验样本的差异化存储与利用效率，为解决上述问题提供了有效途径。因此本章基于 MADDPG 算法框架，引入了优先经验回放

中国知网　https://www.cnki.net

机制，提出了融合优先经验回放机制的多智能体深度确定性策略梯度算法 (Prioritized Experience Replay Multi-Agent Deep Deterministic Policy Gradient, PER-MADDPG)。算法框架结构图如图 3-3 所示。

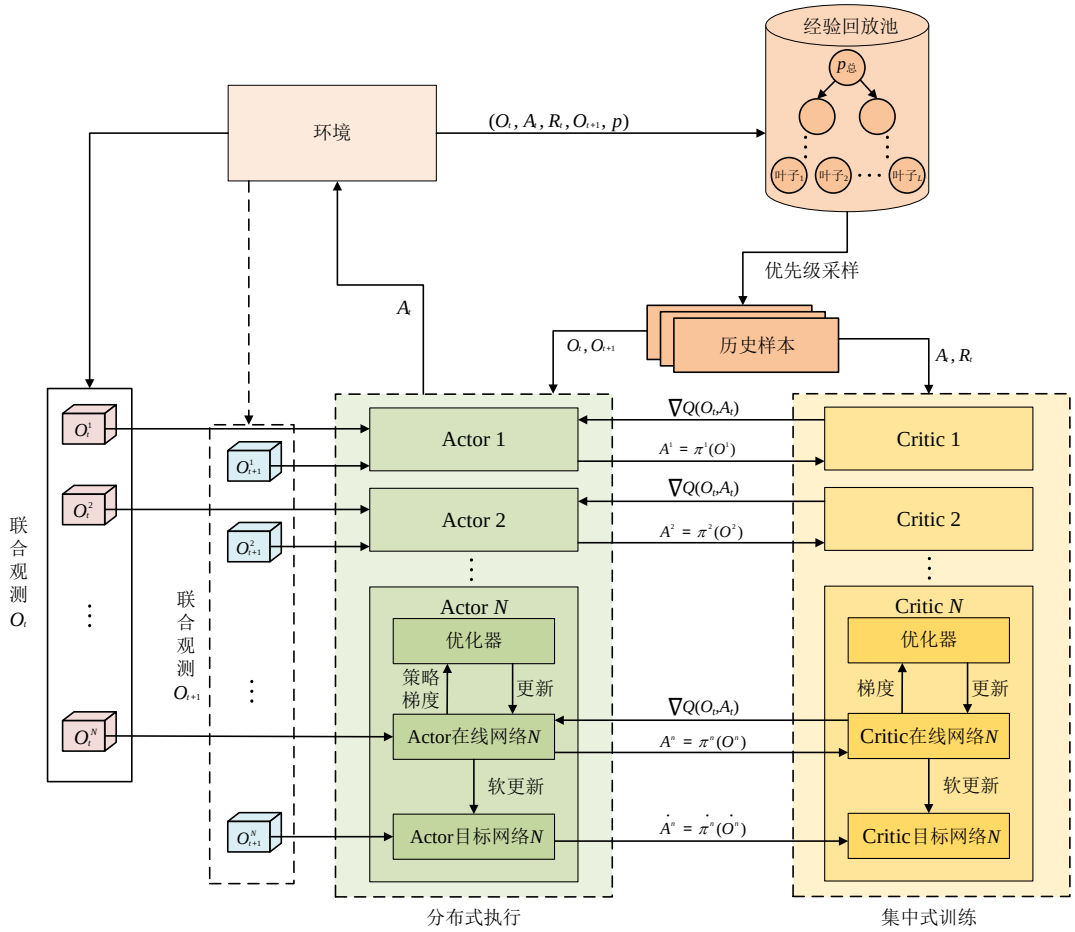


图 3-3 PER-MADDPG 算法结构图

PER-MADDPG 算法在环境完成初始化后，每个无人机将自身的局部观测信息 O_t^i 输入到策略网络中，策略网络会输出该无人机的动作 A_t^i，之后所有无人机执行动作并通过奖励函数计算公式获得奖励值 R_t^i。随后再与每个无人机得到的下一时刻的观测信息 O_{t+1}^i 组成联合数据组 $(O_t, A_t, R_t, O_{t+1}, p_t)$ 放入经验回放池中。此外，在训练时过程中，算法会从经验回放池中采用优先回放机制训练在线网络和目标网络，使用目标 Q 值和当前 Q 值之间的均方误差来计算损失，并使用反向传播算法更新策略网络参数，随后计算策略梯度，更新价值网络参数。同时，算法会使用经验回放池中采样的样本计算采样概率和重要性采样权重，并通过时序差分误差更新采样样本的优先级。算法 3.1 给出了 PER-MADDPG 算法的流程。

PER-MADDPG 算法框架通过构建动态优先级队列，实现对经验样本的价值量化存

中国知网 https://www.cnki.net

储与高效利用。具体而言，在经验存储阶段，根据时序差分误差对样本进行优先级排序，显著经验被赋予更高的存储权重；在经验采样阶段，采用基于优先级的概率采样策略，提升关键经验的抽取频率，从而有效缓解稀疏奖励环境下的信用分配难题。通过这种优化设计，PER-MADDPG 在保持原有 CTDE 架构优势的同时，实现了经验利用效率的显著提升，为无人机集群博弈对抗策略优化提供了优异的解决方案。

算法 3.1 PER-MADDPG 算法

初始化价值网络参数 θ_i 和策略网络参数 φ_i，经验缓冲区 D，叶子节点优先级 p_1
for episode=1 to MAX_EPISODE **do**
　重置环境
　获取无人机集群的初始联合观测信息 $O_t = [O_t^1, O_t^2, ..., O_t^N]$
　for t = 1 to EPISODE_LENGTH **do**
　　每个无人机 i，使用无人机的 Actor 网络获取动作 a_i
　　根据所有无人机动作得到联合动作 $A_t = [A_t^1, A_t^2, ..., A_t^N]$，执行动作得到奖励值 R_t、下一时刻的联合观测信息 O_{t+1} 状和终止标志 $done$
　　将无人机集群的 $(O_t, A_t, R_t, O_{t+1}, p_t)$ 存储到经验缓冲区 D 中
　　$O_t = O_{t+1}$
　end for
　if 缓冲区中样本数 $> N_m$ **then**
　　从经验缓冲区 D 中按照优先级采样得到 N_m 个样本 $(O_k, A_k, R_k, O_{k+1}, p_k)$
　　for 无人机 $i = 1$ to N **do**
　　　计算目标 Q 值：$y_k = R_k^i + \gamma Q_i^{\theta'}(O_{k+1}, A_{k+1})|_{A_{k+1}^i = \mu_i'(O_{k+1}^i)}$
　　　计算损失函数：$L(\theta_i) = \frac{1}{M}\sum_k (y_k - Q_i^{\theta}(O_k, A_k))^2$，更新价值网络参数
　　　计算策略梯度：$\nabla_{\theta_i} J(\mu_i) = \frac{1}{M}\sum_k \nabla_{\theta_i}\mu_i(O_k^i)\nabla_{A^i} Q_i^{\theta}(O_k, A_k)|_{A^i=\mu_i(O_k^i)}$，更新策略网络参数
　　end for
　　for $k = 1$ to N_m **do**
　　　计算采样概率 $P(k) = \frac{p_k^\alpha}{\sum_j p_j^\alpha}$ 和重要性采样权重 $\omega_k = \frac{(M*P(k))^{-\beta}}{\max_j \omega_j}$
　　　计算 TD 误差：$\delta_k = R_k + \gamma Q_k^{\mu'}(O_{k+1}, A_{k+1}) - Q_k^{\mu}(O_k, A_k)$
　　　更新优先级 $p_k = \delta_k + \epsilon$
　　end for
　　更新目标网络参数：$\theta_i' \leftarrow \tau\theta_i + (1-\tau)\theta_i'$，$\varphi_i' \leftarrow \tau\varphi_i + (1-\tau)\varphi_i'$
　end if
end for

中国知网　https://www.cnki.net

3.3.2 优先经验回放机制

传统强化学习算法采用均匀采样经验回放机制，假设所有经验样本具有同等学习价值。但在实际训练中，不同样本对策略优化的贡献度存在显著差异。优先经验回放通过构建样本重要性评估机制，有效提升了经验利用率。该机制的核心在于基于时序差分误差 (Temporal Difference Error, TD-error) 动态分配样本优先级，其实现流程包含三个关键环节：首先，依据 TD-error 绝对值量化样本重要性，误差越大则优先级越高；其次，采用非均匀采样策略，优先选择高优先级样本参与网络更新；最后，通过重要性采样权重修正技术，补偿优先级采样导致的分布偏移问题。此外，为保障探索充分性，新生成样本被赋予初始最高优先级以确保至少一次经验回放机会。优先经验回放机制流程如图 3-4 所示。

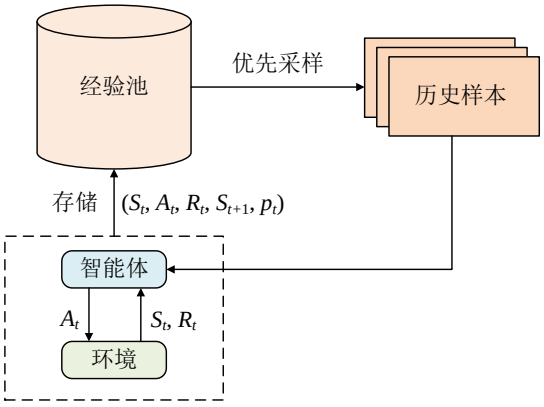


图 3-4 优先经验回放机制流程图

TD-error 的幅值直接表征动作价值函数估计值与实际值的偏差程度，其绝对值越大表明当前样本对策略更新的信息增益越高。具体而言：1）较大 TD-error 样本通常关联于关键策略更新节点，通过优先回放可显著加速模型收敛过程；2）较小 TD-error 样本反映智能体已掌握该状态-动作对的决策规律，针对性回放此类样本能有效抑制错误决策的重复发生，提升策略稳定性。这种差异化处理机制通过强化关键经验学习与抑制低效探索的协同作用，提升强化学习算法的总体表现。TD-error 的表示如式 (3.15) 所示。

$$\delta_k = r_k + \gamma Q_k^{\mu'}\left(s'_k, a'_k\right) - Q_k^{\mu}\left(s_k, a_k\right) \tag{3.15}$$

虽然 TD-error 的值越大表明样本的学习价值越高。但若持续优先选择最高偏差的样本，可能导致模型陷入局部最优或出现过拟合风险。为此，需采用基于优先级的概率化采样策略，即在保证高优先级样本被高频选中的前提下，通过概率分布引入适度的随机性机制。具体而言，每个样本的采样概率与其优先级呈正相关，但并非确定性映射，如式 (3.16) 所示。该机制在加速关键经验学习与维持模型泛化能力之间实现了有效平衡。

$$P(k) = \frac{p_k^{\alpha}}{\sum_{m=1}^{M} p_m^{\alpha}} \tag{3.16}$$

中国知网 https://www.cnki.net

其中，p_k 是样本 k 的采样优先级，按照每个样本各自的 TD-error 由高到低进行排序，N_m 代表经验回放池中的样本总数，参数 α 代表使用优先级的比重。当 $\alpha = 0$ 时，采样方式为均匀采样；当 $\alpha = 1$ 时，采样方式为贪心采样。

优先经验回放机制虽然通过非均匀采样提升了数据利用率，但也可能因改变经验分布的特性而引入偏移偏差。为此，本章中引入重要性采样权重校正机制，通过计算样本优先级与均匀采样概率的密度比，动态调整网络更新时的梯度权重。该方法在维持优先级采样优势的前提下，有效补偿了经验分布偏移对策略优化的负面影响，保障了算法收敛的理论完备性，重要性权重的计算公式如式 (3.17) 所示。

$$\omega_k = \frac{1}{\max\limits_s \omega_s} \left(\frac{1}{N_m} * \frac{1}{P(k)} \right)^{\beta} = \frac{(N_m * P(k))^{-\beta}}{\max\limits_s \omega_s} \tag{3.17}$$

其中，β 是重要性权重调节系数，表示对优先经验回放机制的抵消效果，β 越大对优先经验回放的抵消效果越大。在训练初期，为 β 设定一个较低的初始值 β_0。随着训练的进行，β 逐渐线性变化到 1，以确保训练过程的无偏性，从而保证训练后期误差能够有效收敛。β 的变化公式如式 (3.18) 所示。

$$\beta = \beta_0 + \Delta\beta \cdot t_{\text{env}} \tag{3.18}$$

为提升优先经验回放机制的采样效率，本章采用 SumTree 数据结构实现优先级快速检索。该结构通过二叉树形式存储样本优先级，其中叶子节点记录个体样本优先级，非叶节点保存子树优先级累加值。此数据结构可以在 $O(logN)$ 时间复杂度内完成样本检索与更新操作，显著降低大规模经验池的采样开销。在 SumTree 中，每个叶子节点存放的是优先经验回放池中每个回合优先级的幂指数，回合的优先级可以用于指导经验采样的过程。

3.3.3　神经网络结构

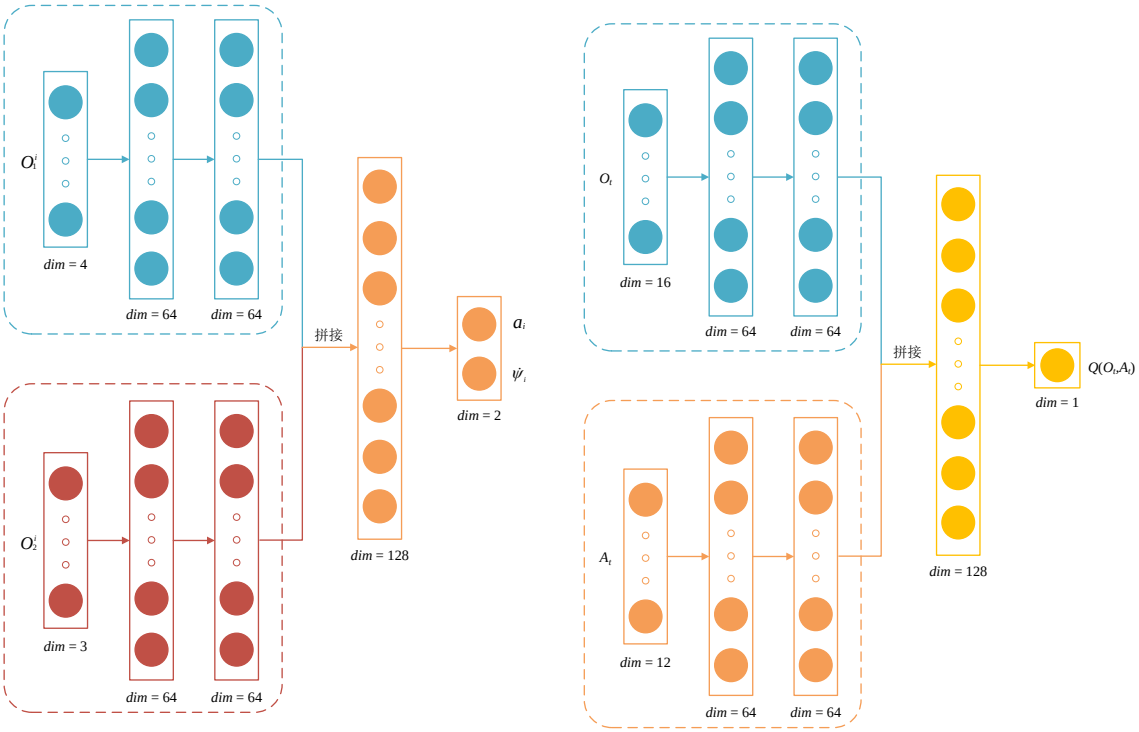
本算法的神经网络采用 Actor-Critic 架构，包含策略网络与价值网络。两类均包含在线网络与目标网络 。策略网络基于局部观测生成动作，价值网络则利用联合观测和联合动作信息来评估策略价值，二者通过目标网络机制实现稳定训练。

针对无人机集群系统中多维空间交互的复杂性，传统单一网络架构在处理时易引发网络收敛效率低下等问题。本章提出一种新型网络结构设计策略：在网络前两层分别构建独立子网络，对观测空间中的核心要素进行差异化特征提取，分别聚焦无人机本体状态参数和雷达探测获取的外部环境信息。经独立子网络处理后，将两类特征进行融合编码形成复合特征向量，继而输入后续全连接层完成输出。该设计通过显式分离无人机内部状态与外部环境，有效增强了无人机对复杂场景的理解能力，在保持模型表达能力的同时显著提升了训练过程的收敛效率。

策略网络与价值网络的具体架构如图 3-5 所示。策略网络的输入为状态空间的两个部分，网络结构总共有三层，两个特征的组合向量作为第三层的输入，最后输出得到当

中国知网　https://www.cnki.net

前状态下的二维动作。价值网络的输入包括当前联合观测和当前局部观测下由动作网络选择的联合动作。相应地，该网络同样有三层构成，前两层中状态的两个子网络也是分别输入各自网络。与策略网络不同的是，在价值网络的第一层中需要分别先将单个无人机的动作向量和观测向量的两个部分向量连接组合得到新向量，之后输入各自网络。最后，将处理后的特征向量合并，输入到最后一层的全连接层，得到一维的状态动作价值。



(a) 策略网络　　(b) 价值网络

图 3-5 神经网络结构

另外，两种网络结构中都有三个隐藏层，前两个层由两个全连接层组成，每部分都有 64 个神经元，第三层有 128 个神经元，层与层之间都是完全连接的，并通过 RELU 函数激活。RELU 函数公式如下：

$$\mathrm{RELU}(x) = \max(0, x) \tag{3.19}$$

该函数通过非线性变换增强网络表达能力，同时缓解梯度消失问题。输出层则采用 Tanh 函数约束动作范围：

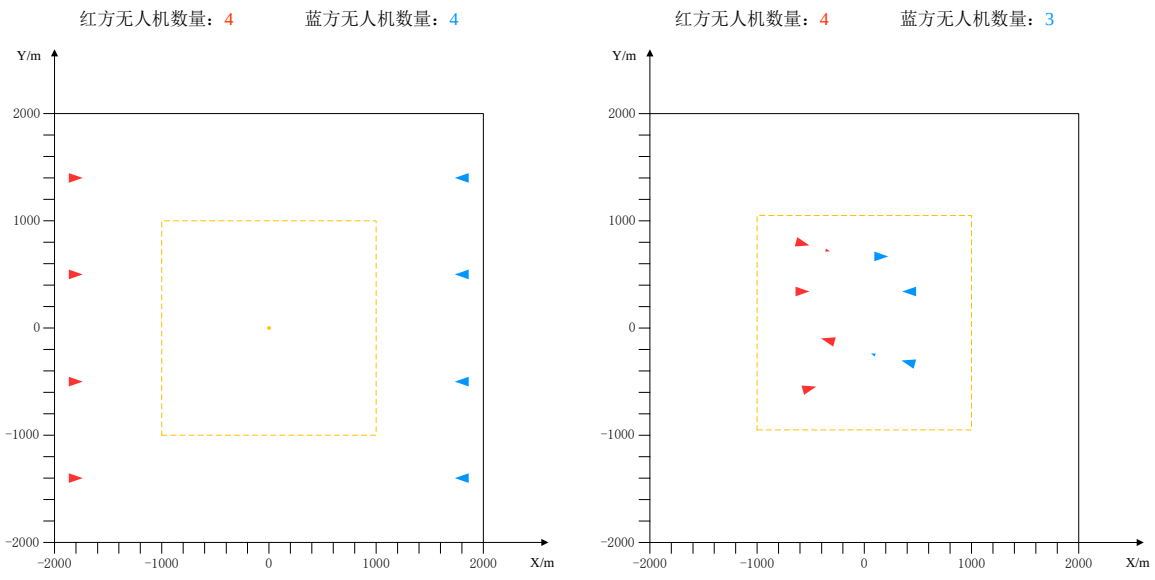
$$\mathrm{Tanh}(x) = \frac{e^{x} - e^{-x}}{e^{x} + e^{-x}} \tag{3.20}$$

中国知网 https://www.cnki.net

3.4　仿真实验结果

3.4.1　仿真实验环境

本章实验环境选用 3.2.2 节的无人机集群博弈对抗环境模型。实验环境采用 Python 语言，借助 Gym 框架搭建了仿真训练环境，该环境的具体布局和配置如图 3-6 所示。无人机在有限大小的正方形对抗区域内保持固定高度飞行，该区域以区域中心为坐标原点，右水平方向为 X 轴的正方向，垂直向上方向为 Y 轴的正方向，双方无人机集群规模 N 均为 4。在环境图中，红色等腰三角形为红方无人机，蓝色等腰三角形为蓝方无人机，三角形的顶角定义为无人机的飞行朝向，双方无人机的各种属性完全相同。双方无人机都配备了两枚空对空导弹，图 3-6(b) 中红色小等腰三角形为红方无人机发射的导弹，蓝色小等腰三角形为蓝方无人机发射的导弹，同样，三角形的顶角定义为导弹的飞行朝向。黄色圆点为对抗区域中心点，即坐标原点，黄色虚线包裹的正方形区域为中心战略区域。该环境通过统一的物理引擎实现无人机运动学运动学建模，为算法验证提供实验平台。



(a) 仿真环境初始图　　(b) 仿真环境对抗图

图 3-6 仿真环境图

每轮仿真实验开始时双方无人机集群都对称初始化在环境中的两侧，4km*4km 的对抗区域表示为 $x, y \in [-2, 2]$km，而 2km*2km 的中心战略区域表示为 $x, y \in [-1, 1]$km，红方无人机集群的初始位置限制为 $x \in [-2, -1.8]$km，蓝方无人机集群的初始位置限制为 $x \in [1.8, 2]$km。仿真对抗开始后，双方无人机集群朝着中心战略区域前进，并在区域中进行对抗。若一方无人机全部被击毁或者达到设定的时间步数则本轮对抗结束，结束时的胜利准则按照 3.2.3 节中的规则定义。具体的仿真环境和无人机参数如表 3-1 所示。

中国知网　https://www.cnki.net

表 3-1 仿真环境参数

参数	参数含义	参数值
$x_{\max}$	X 轴方向环境边界限制	2km
$x_{\max}$	Y 轴方向环境边界限制	2km
x_{center}	X 轴方向中心区域边界限制	1km
y_{center}	Y 轴方向中心区域边界限制	1km
$v_{\max}$	无人机最大速度	40m/s
$a_{\max}$	无人机最大加速度	5m/s^2
ψ	无人机航向角	$[0, 2\pi]$
$\dot{\psi}_{\max}$	无人机最大航向角速度	2rad/s
$d_{\max}$	雷达探测器探测半径	200m
θ_{att}	雷达探测器探测角度	$[-\pi/6, \pi/6]$
θ_{dan}	无人机威胁区域角度	$[5\pi/6, 7\pi/6]$

3.4.2 训练结果与测试评估

（1）模型训练与对比实验分析

仿真平台的运行环境采用的硬件配置是 Ubuntu18.04 操作系统，CPU 是 Intel core i7-12700H，GPU 是 NVIDIA GeForce 3080，运行内存是 32G。仿真环境使用 Python 语言搭建，训练代码所使用的神经网络基于 Pytorch 构建，使用 Adam 优化器优化算法参数。本章中为了探究 PER 机制在提升多智能体系统稳定性方面的效用，分别使用了 PER-MADDPG 算法和 MADDPG 算法进行对比实验。两种算法的神经网络参数设置完全一致，仿真平台和训练算法中的具体参数设置如表 3-2 所示，

表 3-2 算法相关参数

参数符号	参数含义	参数值
γ	奖励折扣因子	0.95
lr_θ	策略网络学习率	0.0001
lr_φ	价值网络学习率	0.0001
D	经验回放池容量	5000
MAX_EPISODES	最大训练轮数	10000
EPISODE_LENGTH	单轮最大执行步数	500
BATCH_SIZE	采样批次大小	128
ϵ	极小常数值	1×10^{-6}

为了定量的对比分析 PER-MADDPG 算法和 MADDPG 算法的训练结果，本章中分

中国知网 https://www.cnki.net

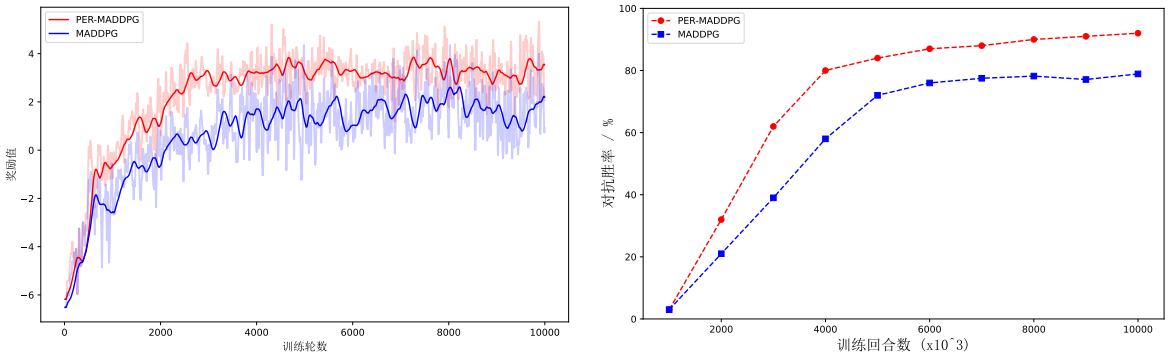
别用两种算法训练红方无人机集群的空战行为策略，将蓝方无人机集群的空战行为策略设定为固定的规则策略，作为环境的一部分。固定规则策略根据对抗胜利准则，设计了三个递进阶段的作战流程：

（1）第一阶段是突进阶段。对战开始后，蓝方集群所有无人机沿最优路径全速朝向中心战略区前进。

（2）第二阶段是巡航阶段。到达中心战略区后，所有蓝方无人机在战略区内定速巡航探测敌方无人机。

（3）第三阶段是交战阶段。与敌方无人机交战时，无人机会在尽量不丢失探测目标的情况下绕到敌机后方发动有效攻击击毁敌机。

另外本章设计了四个指标用以评估这两种算法的性能优劣：1）平均奖励峰值 (Average Reward Peak, ARP)；2）收敛时间 (Convergence Time, CT)；3）收敛后的平均奖励 (Average Reward after Convergence, ARC)；4）对抗胜率峰值 (Win Rate Peak, WRP)；5）平均单步决策时间 (Average Decision Time per Step, ADTS)。两种算法分别在仿真环境中进行 10000 回合的训练，每回合中执行的最大步数为 500（若是一方无人机全部死亡则提前结束回合）。训练中的奖励曲线对比图如下图 3-7(a) 所示，胜率曲线图如下图 3-7(b) 所示，红色曲线代表根据 PER-MADDPG 算法训练的无人机集群在测试环境中获得平均奖励以及胜率变化趋势，而蓝色曲线代表根据 MADDPG 算法训练的无人机集群在测试环境中获得的平均奖励以及胜率变化趋势。



(a) 两种算法平均奖励曲线图　　(b) 两种算法对抗胜率曲线图

图 3-7 两种算法训练结果对比

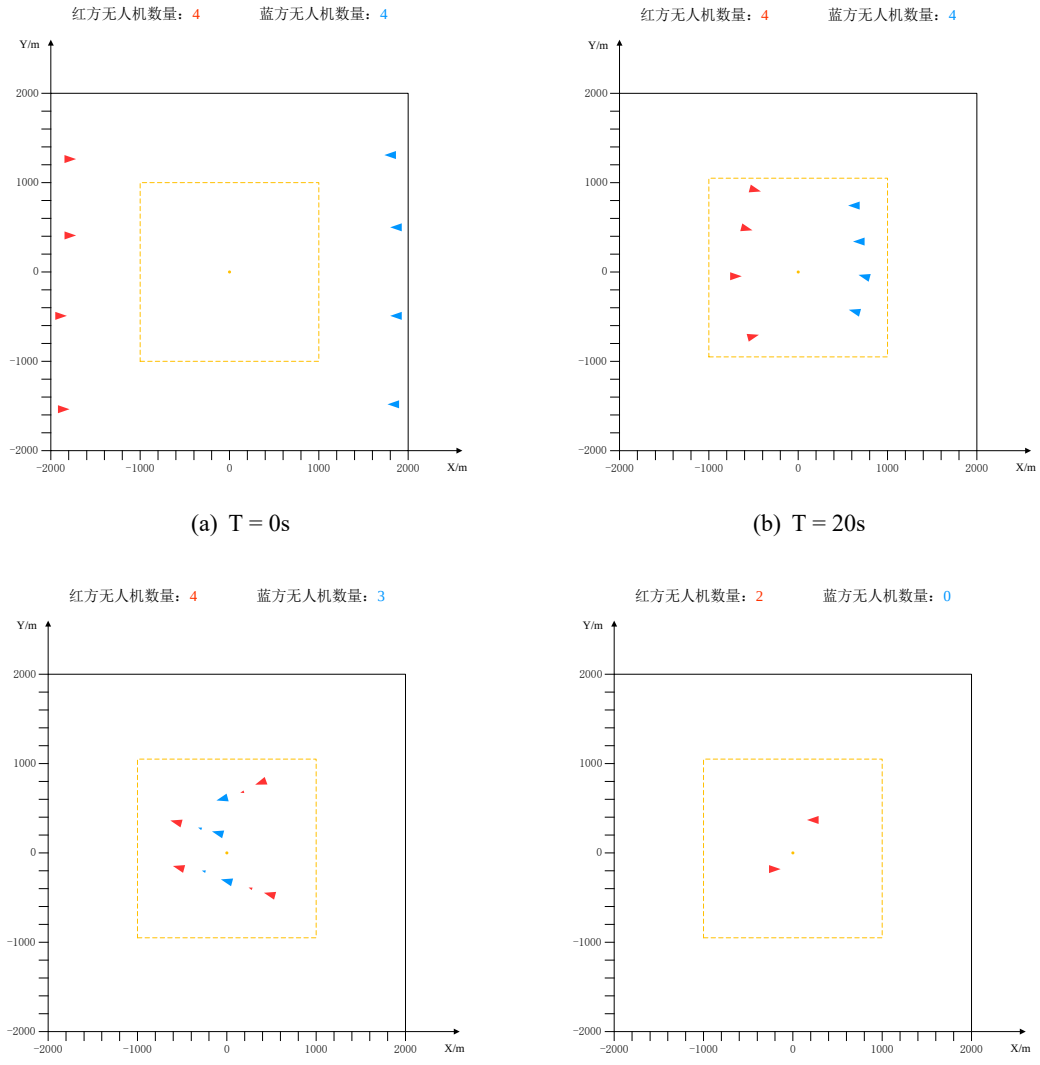
设计的四种指标的结果如表 3-3 所示，PER-MADDPG 算法需要 2658 个回合达到收敛，然而 MADDPG 算法却需要 3217 个回合才能达到收敛，明显 PER-MADDPG 算法比 MADDPG 算法收敛速率更快。MADDPG 算法的平均奖励峰值 ARP 和收敛后的平均奖励 ARC 为 3.54 和 1.97，而 PER-MADDPG 算法的 ARP 和 ARC 分别达到了 4.98 和 3.45，说明 PER-MADDPG 算法比 MADDPG 算法的训练得到的策略更优。在收敛后的对抗胜率峰值方面，PER-MADDPG 算法同样显著高于 MADDPG 算法，这表明在对抗固定的规则策略时，使用 PER-MADDPG 算法训练博弈对抗策略可以更好的完成无人机集群空

中国知网　https://www.cnki.net

战对抗的任务。此外，PER-MADDPG 算法的平均单步决策时间也要比 MADDPG 算法更短，算法决策的效率更高。

表 3-3 两种算法的评估指标值

算法	ARP	CT	ARC	WRP(%)	ADTS
PER-MADDPG	4.98	2658	3.45	91.8	0.15s
MADDPG	4.04	3217	1.97	78.9	0.18s



(a) T = 0s　(b) T = 20s

(c) T = 40s　(d) T = 67s

图 3-8 不同时刻无人机集群状态图

为了更直观地观察算法控制的无人机集群在对抗中具体的机动决策行为、针对性地调试算法参数，在训练过程中选择性渲染出对抗仿真过程的实时态势。图 3-8 为不同时刻无人机集群对抗的过程图。在 T = 0s 时，双方无人机集群随机分布在对抗环境两侧的

中国知网 https://www.cnki.net

设定区域后，准备开始前往中心战略区域对抗；在 T = 20s 时，双方无人机集群到达中心战略区域，开始尝试探测敌方无人机并发动有效攻击；在 T = 40s 时，双方无人机绕到敌方无人机后方发动有效攻击；最终，T = 67s 时，红方无人机击毁全部蓝方无人机，对抗提前结束，红方无人机集群获得对抗胜利。

（2）对抗实验分析

为了消除由于固定的规则策略导致的性能分析误差，本节设计了 PER-MADDPG 算法和 MADDPG 算法的直接对抗分析。在算法训练阶段，红方无人机集群采用 PER-MADDPG 算法进行模型训练，而蓝方无人机集群采用 MADDPG 算法进行模型训练。在对抗环境中，双方无人机集群通过直接的博弈对抗来验证两种算法的性能优劣。两种算法共同训练 10000 个回合，每 1000 回合的直接对抗结果比例如图 3-9 所示。其中，红色柱状代表根据 PER-MADDPG 算法训练的无人机集群对抗胜利的比例；蓝色柱状代表根据 MADDPG 算法训练的无人机集群对抗胜利的比例；灰色柱状代表两个算法训练的无人机集群对抗平局的比例。分析图中数据可知，根据 PER-MADDPG 算法训练的无人机集群在对抗场景中与根据 MADDPG 算法训练的无人机集群对战能够将胜率稳定在 68% 左右，对抗结果进一步证明了 PER-MADDPG 算法在处理无人机集群博弈对抗问题时更为适用。

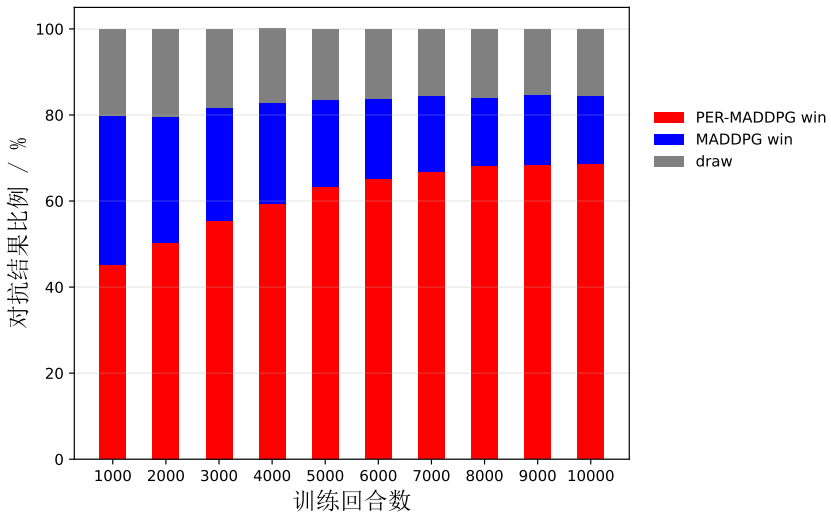


图 3-9 两种算法直接对抗结果图

（3）模型泛化性分析

本节在不进行额外训练的情况下，对提出的 PER-MADDPG 算法训练的模型进行泛化性测试。泛化性实验具体设置为：增加无人机集群的数量和增大对抗的边界范围，同时按照原有比例调整中心战略区域的边界。在此基础上，针对不同无人机集群数量的情况，分别进行 1000 次对抗实验。实验中，敌方无人机集群对抗中采用固定的规则策略，统计实验中模型的对抗胜率。

泛化性实验结果如表 3-4 所示。从表中可以看出，在不同无人机集群数量和不同对

中国知网　https://www.cnki.net

抗环境大小情况下，基于所提算法训练的无人机集群，尽管随着无人机集群数量的增加和对抗环境边界的扩大，其对抗胜率略有下降，但总体上仍保持较高的对抗胜率。泛化性实验验证了所提算法训练的无人机能够适应环境变化，展现出较强的泛化性能。

表 3-4 泛化性实验测试结果

无人机集群规模	对抗环境范围（正方形区域边长）	实验次数	对抗胜率 (%)
6	4km	1000	91.4
	5km	1000	90.3
	6km	1000	89.1
8	4km	1000	89.4
	5km	1000	88.9
	6km	1000	87.6
10	4km	1000	87.2
	5km	1000	86.1
	6km	1000	85.7

3.5 本章小结

本章针对无人机集群空战博弈对抗问题，提出了一种结合优先经验回放机制的 PER-MADDPG 算法，构建了无人机集群空战博弈对抗环境模型，对无人机进行运动学模型建模，构建相应的马尔可夫过程并设置对应的奖励函数。随后，详细介绍了优先经验回放机制和算法的整体训练框架以及新设计的神经网络结构。最后，在仿真环境中对提出的算法进行模型训练和验证分析。结果表明，相较于传统 MADDPG 算法，改进后的算法在解决无人机集群博弈对抗上有着明显优势并具有较强泛化性。不过，在最后的泛化性实验中也发现，改进后的算法在无人机集群数量逐步增加的情况下效果略有下降，因此，在后面的研究中，本文将进一步深入探究无人机集群规模进一步增大的情况下的博弈对抗问题，以期为无人机集群对抗的应用提供更加全面广泛和高效的解决方案。

中国知网 https://www.cnki.net

第四章 空域争夺场景下基于强化学习的大规模无人机集群博弈对抗

4.1 引言

随着现代空战的大力发展，小规模的无人机集群协同作战已经渐渐无法满足军事作战的需求。小规模的无人机集群难以完成更为复杂的军事任务，更多时候要考虑大规模无人机集群联合作战，因此，本章将使用多智能体强化学习算法解决大规模集群空域争夺任务。在上一章的研究中，主要针对了多智能体强化学习算法在无人机集群空战对抗决策系统中的运用，并成功实现了无人机集群自主博弈对抗。然而，随着无人机集群规模逐步扩展，传统多智能体强化学习面临维度灾难、策略震荡加剧等挑战。本章针对大规模无人机集群对抗任务中强化学习存在的维度灾难及策略震荡问题，首先设计了大规模集群空域争夺任务模型，并针对该任务构建了对应的马尔可夫决策过程。随后，在 MADDPG 算法框架的基础上，融合课程学习训练策略，引入注意力机制优化价值网络输入，该算法在无人机集群对抗任务中实现了由易到难的平滑过渡，使集群在拓展作战规模时依然保持显著的协同决策优势。最后，在搭建的大规模集群对抗仿真环境中，证明算法能够由易到难地引导无人机集群学习到高效的对抗策略，有效解决了传统 MADDPG 算法在智能体较多场景下的训练效率问题。此外，通过泛化性测试验证了所提出的算法具有较强的泛化性。

4.2 问题建模

4.2.1 无人机集群联合攻击模型

在大规模无人机集群对抗过程中，本章设计了如图 4-1 的无人机集群联合攻击模型。在本章中，单个无人机的运动模型以及博弈对抗模型均与第三章中采用的模型保持一致。在大规模集群对抗环境中，由于双方无人机数量较多，当敌方无人机进入本方任意一架无人机的雷达探测范围，该无人机即可与其他本方无人机共享敌方无人机位置信息，此时处于敌方无人机危险区域的本方无人机可发射空对空导弹实施有效攻击，击毁敌方无人机。

如图 4-1 中所示，蓝方 1 号无人机虽然不在红方 2 号无人机的攻击区域内，但是红方 2 号无人机处于蓝方无人机的危险区域，且红方 1 号无人机为红方 2 号无人机提供了蓝方 1 号无人机的位置信息。因此，在这种情况下，红方 2 号无人机对蓝方 1 号无人机发射空对空导弹同样视为有效攻击，可以直接击毁目标。

中国知网 https://www.cnki.net

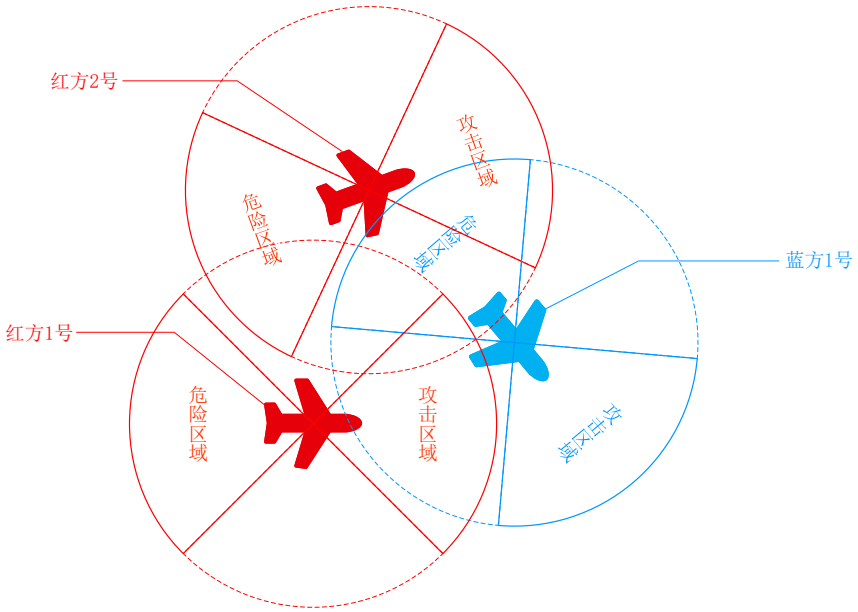


图 4-1 无人机集群联合攻击示意图

4.2.2 大规模无人机集群空域争夺任务模型

（1）可扩展的空战环境模型设计

针对大规模集群作战场景，本章构建了具备动态可扩展特性的空战环境模型。红蓝双方无人机集群规模采用 1 : 1 比例配置。由于集群中无人机数量可变，本章在第将三章的二维地面坐标系的 $X-Y$ 平面作为对抗环境的基础上，采用了战场边界的弹性扩展机制。正方形环境边长 $x_{\max}$ 与集群规模 N 满足线性关系：

$$x_{\max} = x_{\max_0} + \beta_0(N - N_0) \tag{4.1}$$

其中 $x_{\max_0}$ 为集群规模最小时的基准空战环境边长，N_0 为最小集群规模，β_0 为空间扩展系数。该模型通过动态调整空战环境密度，确保不同规模集群具有等效机动空间占比。

（2）空域争夺任务设计

为增强集群对抗的战术博弈特性，本模型设计了空域占领区控制权争夺机制。空域占领区是在限定的空战区域内部的若干个半径不同的圆形区域，空域占领区的数量同样随着参与对抗的无人机集群的数量增加而增加。由于初始阶段红方无人机集群占据空战区域左侧，蓝方无人机集群则占据空战区域右侧，为了公平起见，环境中会在空战区域的对称轴 $x = 0$ 的两侧分别生成 k 个空域占领区 ($k = \lceil N/10 \rceil$)。区域控制权判定遵循排他性占领准则：当且仅空域占领区只有某一方无人机一架及以上且保持一定时长以上时，判定该方获得区域控制权，若是区域内无人机数量不足一架则会丢失区域控制权。图 4-2 为无人机空域争夺任务的具体示意图。双方无人机集群率先控制本方半区的占领区，随后双方开始展开对抗攻占对方半区的占领区。

中国知网 https://www.cnki.net

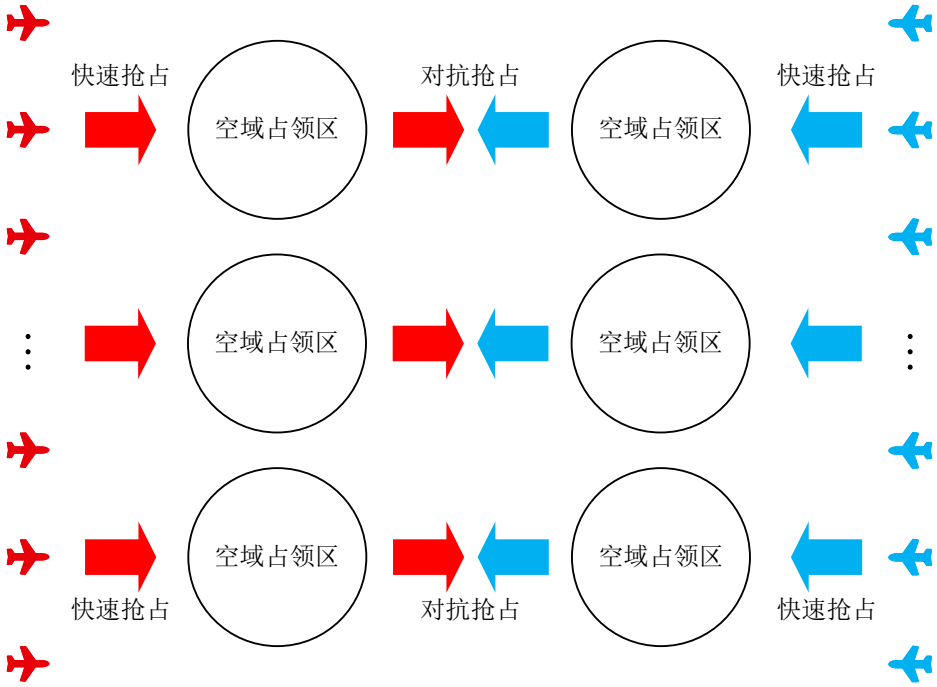


图 4-2 空域争夺任务示意图

（3）对抗任务胜负判定规则

在本章设计大规模无人机集群对抗任务中，对抗终止遵循双阈值判定准则：当任意方无人机全部被击毁，或对抗持续时长达到任务设定时长时，自动结束战斗。胜负评估采用三级优先级判定体系：1）第一优先级：比较双方控制的有效占领区数量；2）第二优先级：当控制的占领区数量相等时，对比存活无人机数量；3）第三优先级：若存活无人机数量也相同，则判定为平局。该机制通过引入空间控制权量化指标，强化了大规模集群空域争夺作战中的区域价值。

4.2.3　大规模无人机集群空域争夺博弈对抗 MDP 模型

本节结合大规模集群空域争夺环境的设计的特点，将大规模无人机集群空域争夺任务建模为马尔可夫决策过程，下面详细介绍马尔可夫决策过程的相关元素，包括状态空间、动作空间和奖励函数三个部分。

状态空间：对于集群中的无人机 i，其局部观测空间 O^i 由无人机状态信息 O_1^i 和雷达探测器状态信息 O_2^i 所组成，可以表示为：

$$O^i = [O_1^i, O_2^i] \tag{4.2}$$

无人机状态信息 O_1^i 包括自身坐标、速度和偏航角信息，其中其中 x_i 和 y_i 表示自身位置的横纵坐标，Δx_{iz} 和 Δy_{iz} 表示无人机在 X 轴和 Y 轴方向相对于最近的未被占领的空域占领区圆心的距离，v_i 表示自身速度信息，ψ_i 表示自身航向角信息，如式 (4.2)

中国知网　https://www.cnki.net

所示。

$$O_1^i = [x_i, y_i, \Delta x_{iz}, \Delta y_{iz}, v_i, \psi_i] \tag{4.3}$$

此外，无人机还可以根据雷达的观测范围，确定与最近的 M 架敌方无人机的空间状态信息作为雷达探测器的状态信息 O_2^i。该信息由距离-航向角差二元组序列构成，其中 d_{ij} 表示无人机 i 与敌方无人机 j 之间的欧氏距离，$\Delta\psi_{ij}$ 表示无人机 i 与敌机 j 之间的航向角差，当雷达探测范围内有效目标数不足 M 时，空缺项以零填充，确保状态空间维度一致性，如式 (4.3) 所示。

$$O_2^i = [(d_{i1}, \Delta\psi_{i1}), (d_{i2}, \Delta\psi_{i2}), \ldots, (d_{iM}, \Delta\psi_{iM})] \tag{4.4}$$

本章设定无人机集群联合观测空间 O 是由无人机集群的局部观测空间组成，如下式所示：

$$O = [O^1, O^2, \ldots, O^N] \tag{4.5}$$

动作空间：动作空间采取和第三章相同的动作空间，分别控制无人机航向加速度 a_i 和航向角加速度 $\dot{\psi}_i$ 来控制无人机的运动，无人机 i 的动作空间可以表示为：

$$A^i = [a_i, \dot{\psi}_i] \tag{4.6}$$

同样的，无人机集群的联合动作空间 A 定义为 $A = [A^1, A^2, \ldots, A^N]$。

奖励函数：对于大规模无人机集群博弈对抗问题。由于无人机集群规模的逐步增加，空战环境边界同样增大，为了提高强化学习算法整体的学习效率，引入过程中的奖励值尤为重要。本章中设计大规模集群博弈对抗问题最终的目标是通过集群协同占领更多区域击败敌方，因此，每一时间步的过程奖励 R_t 即为占领区域获得的奖励值与所有无人机获得的奖励值之和：

$$R_t = R_t^{\text{occ}} + R_t^1 + R_t^2 + \ldots + R_t^N \tag{4.7}$$

占领区域获得的奖励值的大小与该时间步时本方和敌方占领的区域的数量有关，若是本方占领的区域的数量大于敌方占领的区域的数量，则获得正奖励，反之获得负奖励。具体的奖励值 R_t^{occ} 定义如下：

$$R_t^{\text{occ}} = k_{\text{z}} * (C_{\text{r}} - C_{\text{b}}) \tag{4.8}$$

其中 k_{z} 为区域奖励调节系数，C_{r} 为本方占领的区域的数量，C_{b} 为敌方占领的区域的数量。

对于每个无人机 i，奖励 R_t^i 包括五个部分，分别为协同击毁敌机奖励，击毁敌机奖励，被敌机击毁奖励，出界奖励，占领区域奖励。

$$R_t^i = R_{\text{syn}} + R_{\text{destroy}} + R_{\text{destroyed}} + R_{\text{outside}} + R_{\text{zone}} \tag{4.9}$$

中国知网 https://www.cnki.net

（1）协同击毁敌机奖励 R_{syn}

当无人机的雷达成功检测到敌方无人机后，即可与本方其他无人机共享敌方无人机位置。这使得本方其他无人机有可能成功进行一次有效攻击摧毁敌方无人机，从而对本方无人机集群有利。因此，若是在这种情况下，本方其他无人机成功击毁该敌方无人机，给予本方无人机一个正奖励，R_{syn} 定义如下：

$$R_{\text{syn}}=\begin{cases} r_{\text{s}}, & \text{if 协同击毁敌方无人机} \\ 0, & \text{otherwise} \end{cases} \tag{4.10}$$

（2）击毁敌机奖励 R_{destroy}

当无人机直接击毁敌方无人机后，也对本方无人机集群有利，因此给予一个正奖励，R_{destroy} 定义如下：

$$R_{\text{destroy}}=\begin{cases} r_{\text{d}}, & \text{if 击毁敌方无人机} \\ 0, & \text{otherwise} \end{cases} \tag{4.11}$$

由于本文更侧重于无人机集群协作的研究，所以为了训练集群的协同攻击，本章中设计的 r_d 大小为 r_s 的 1.5 倍。

（3）被击毁奖励 $R_{\text{destroyed}}$

当本方无人机被敌方无人机击毁后，对本方无人机集群不利，因此给予一个负奖励，$R_{\text{destroyed}}$ 定义如下：

$$R_{\text{destroyed}}=\begin{cases} -r_{\text{d}}, & \text{if 被敌方无人机击毁} \\ 0, & \text{otherwise} \end{cases} \tag{4.12}$$

（4）出界奖励 R_{outside}

无人机若是脱离规定的作战区域应该给予惩罚，确保双方无人机可以在规定区域内进行博弈对抗，因此无人机出界会被给予一个负奖励，R_{outside} 定义如下：

$$R_{\text{outside}}=\begin{cases} -r_{\text{o}}, & \text{if 无人机出界} \\ 0, & \text{otherwise} \end{cases} \tag{4.13}$$

（5）占领区域奖励 R_{zone}

由于无人机集群占领区域需要保持一定的时间，所以当无人机在未控制的占领区内部时，或者无人机是控制的占领区中的唯一无人机时，会给予一个正奖励。其余情况下，为了引导无人机向未控制的占领区前进，会在无人机处于未控制的占领区外部时给予一个负奖励，R_{zone} 定义如下：

$$R_{\text{zone}}=\begin{cases} r_{\text{z}}, & \text{if 无人机位于未被占领的区域内部} \\ -k_{\text{z}}*d_{\text{u,z}}, & \text{otherwise} \end{cases} \tag{4.14}$$

其中 k_{z} 是占领区域奖励调解系数，$d_{\text{u,z}}$ 是当前时刻无人机距离最近的未控制占领区圆心的距离。

中国知网　https://www.cnki.net

4.3 基于 CLA-MADDPG 的大规模无人机集群空域争夺任务算法设计

4.3.1 算法框架结构

本文在第三章中提出的 PER-MADDPG 算法虽然在处理数量较少的无人机集群博弈对抗任务时表现出色，但随着无人机集群数量的逐步增加，该算法的效果就略显不足。因此，本文为了进一步提升 MADDPG 的训练效果，在训练中加入了课程学习的思想，同时结合注意力机制让无人机更多的注意与自己关系更大的友机，提出了融合课程学习和注意力机制的多智能体深度确定性策略梯度算法 (Curriculum Learning and Attention Multi-Agent Deep Deterministic Policy Gradient, CLA-MADDPG)，算法框架结构图如图 4-3 所示。CLA-MADDPG 算法的价值网络输入信息为经过注意力机制模块处理后的联合观测-动作对 (O_t, A_t)，策略网络输入信息为无人机自身局部观测 O_t，CTDE 框架中每个无人机都有自己独立的价值网络和策略网络，但是由于本章的控制的多个无人机需要完成的目标是相同的且本章中无人机集群规模较大，因此所有无人机共用一个价值网络和策略网络。

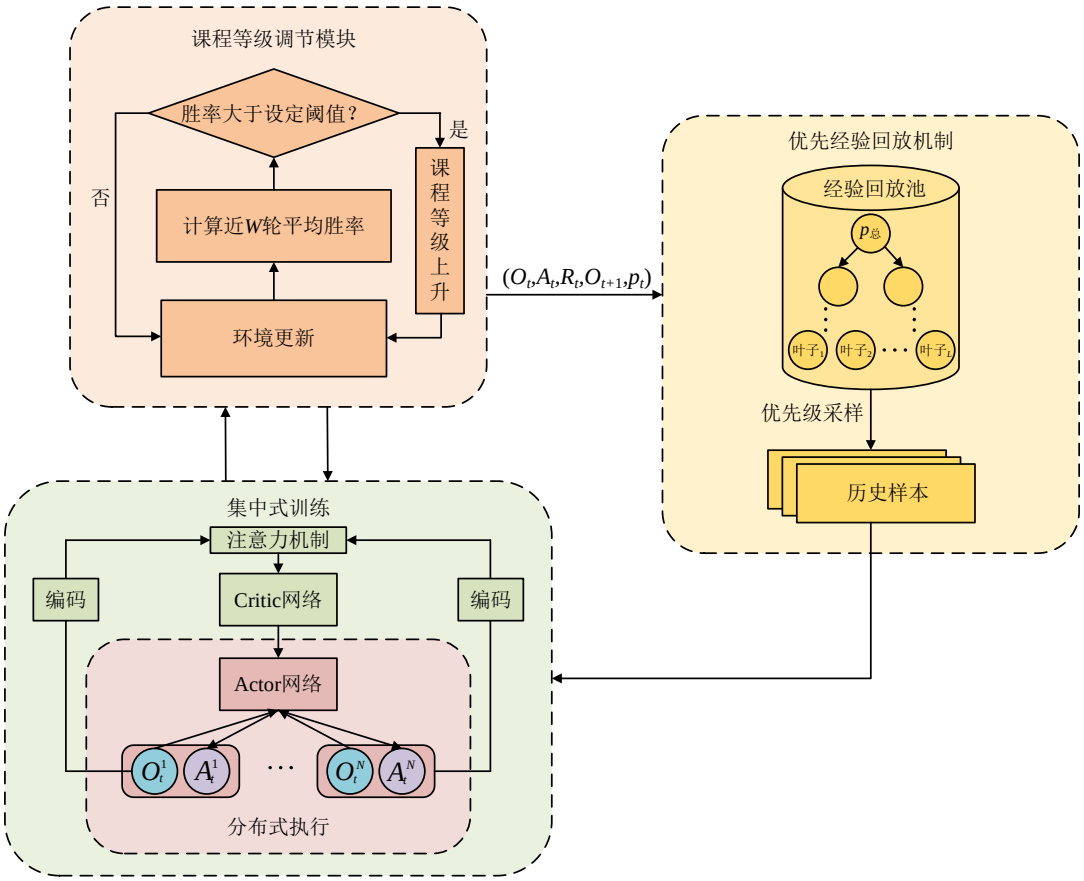


图 4-3 CLA-MADDPG 算法结构图

在第三章的无人机集群空战任务中，经常会出现无人机死亡的情况，当无人机死亡后，仅保留无人机编号而将其他信息屏蔽。那么在联合观测空间和动作空间中，将与该

中国知网 https://www.cnki.net

死亡无人机相关的特征信息用 0 向量描述即可。但是在本章的大规模集群对抗任务中，由于双方集群规模会达到很大的量级，一旦集群中有较多的无人机被击毁，这可能导致无人机集群的联合动作空间和联合观测空间关于阵亡友机的信息消失。价值网络无法应对大量输入信息的突然减少，价值估计可能会受到较大影响。此外，本章算法中结合了课程学习思想，无人机集群规模会随着课程等级的提升而增大，从而使得无人机集群的联合动作空间和联合观测空间变大，也会影响价值网络 Q 值的输出。针对本章对抗环境中价值网络输入节点随着无人机数目变化而变化的特性对价值网络训练的影响，引入注意力机制对价值网络的输入信息进行改进。具体而言，就是利用注意力机制从其他无人机的观测-动作对中选取重要的信息用于构造每个无人机价值网络的输入，这样做既能解决集群规模扩展的问题，还能帮助无人机有选择性地筛选出重要的环境信息，忽略掉不重要的信息。

算法 4.1 基于 CLA-MADDPG 的大规模无人机集群对抗训练算法

初始化价值网络参数 θ 和策略网络参数 φ，经验缓冲区 D，叶子节点优先级 p_1
初始化课程学习参数：更新阈值 η_{w}，课程评估窗口 W
for 回合 $episode = 1$ to MAX_EPISODE **do**
　重置环境至课程等级 L 对应的初始状态，获取联合观测 O_t
　if $episode$ % $W == 0$ **and** $L < L_{\max}$ **then**
　　计算最近 W 轮平均胜率 $avg_success$
　　if $avg_success > \eta_{\text{w}}$ **then**
　　升级课程等级 $L \leftarrow L + 1$，清空经验缓冲区 D 内数据
　　end if
　end if
　for 时间步 $t = 1$ to EPISODE_LENGTH **do**
　　集群中每架无人机 i 执行动作 $A_t^i = \{\mu(O_t^i)\}_{i=1}^N$，根据奖励函数计算奖励 R_t^i
　　环境更新，得到下一时刻局部观测 O_{t+1}^i，获取终止标志 $done$ 及奖励 R_t
　　存储经验 $(O_t, A_t, R_t, O_{t+1}, p_t)$ 至缓冲区 D
　　if 缓冲区样本数 $|D| > N_m$ **then**
　　按优先级采样 N_m 组经验 $\{(O_k, A_k, R_k, O_{k+1}, p_k)\}_{k=1}^{N_m}$
　　更新策略网络：$\nabla_\theta J(\mu) = \frac{1}{M}\sum_k \nabla_\theta \mu(O_i^k) \nabla_{A_i} Q^\theta(O^k, A^k)|_{A_i=\mu(O_i^k)}$
　　更新价值网络：$L(\theta) = \frac{1}{M}\sum_k (y^k - Q^\theta(O^k, A^k))^2$
　　计算 TD 误差并更新优先级 p_k
　　目标网络软更新：$\theta' \leftarrow \tau\theta + (1-\tau)\theta'$，$\varphi' \leftarrow \tau\varphi + (1-\tau)\varphi'$
　　end if
　end for
end for

中国知网　https://www.cnki.net

算法的具体流程如算法 4.1 所示，在算法达到最大训练轮数之前都会在仿真对抗环境中循环进行博弈对抗。首先根据当前课程等级生成对应的对抗环境，双方无人机集群在环境中对抗。在此过程中，无人机获取局部观测信息 O_t^i 输入到策略网络生成自身动作 A_t^i。随后，将 N 架无人机输出动作组合成联合动作 A_t 和输入到仿真环境中进行交互，得到仿真环境反馈的奖励值 R_t 和下一时刻的联合观测信息 O_{t+1}。进而不断更新策略网络和价值网络。每个时刻都将当前的联合观测信息 O_t，联合动作信息 A_t，奖励值 R_t 和下一时刻的联合观测信息 O_{t+1} 以及样本优先级 p_t 存入经验回放池中用于训练。训练阶段，算法会从经验回放池中通过优先经验采样取得一组历史样本计算 TD-error 更新样本优先级。随后，各无人机将联合观测-动作对信息经过注意力网络的处理后输入价值网络得到 Q 值，并通过计算策略梯度更新策略网络参数以及最小化损失函数更新价值网络参数。最后，每隔一定步数通过软更新目标网络参数。

算法会在每完成 W 轮训练后，评估近 W 轮中的平均对抗胜率是否达到设定的更新阈值 η_{w}。若是满足条件，则提升当前课程等级。升级后，算法保留历史策略参数，将神经网络参数从上一课程等级迁移过来，从而避免从头开始训练。同时，清空经验回放池中上一课程中的数据，仅保留当前等级的经验，以保证训练的稳定性。

4.3.2 神经网络结构

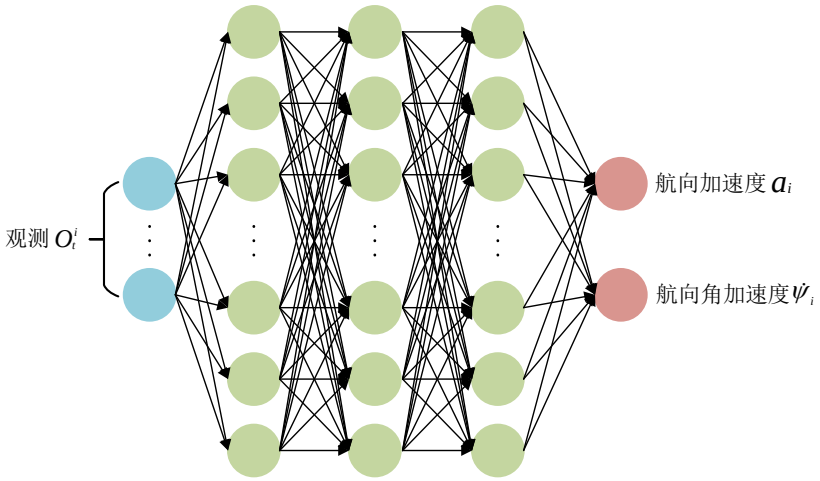
本算法的神经网络同样采用 Actor-Critic 架构，包含策略网络与价值网络，其中每类网络均包含在线网络 与目标网络 。策略网络基于局部观测生成动作，价值网络则利用联合观测和联合动作信息来评估策略价值，二者通过目标网络机制实现稳定训练。策略网络与价值网络的具体架构如图 4-4 所示。策略网络的输入是每个无人机 i 在环境中的局部观测信息的两个部分 O_1^i 和 O_2^i，输出则是动作值 A^i。价值网络的输入包括当前联合观测信息和由策略网络选择的联合动作信息。将无人机的自身观测-动作对和其余友方无人机的观测-动作对通过编码层编码为同维度向量后作为注意力模块的输入，注意力模块通过注意力机制提取无人机对其余友方无人机观测-动作对的关注度，将注意力机制的输出信息与无人机自身的观测-动作对拼接，作为完整的观测-动作对输入价值网络。最终，价值网络输出当前时刻联合观测-动作价值函数预估值。

策略网络由四层全连接层构成，每层全连接层包含 128 个神经元，全连接层的激活函数采用 RELU 函数。价值网络通过编码层将无人机观测-动作对信息编码后，输入注意力机制模块进行信息处理。随后，将注意力机制的输出信息经过四层全连接层处理，最终输出价值 Q。如图 4-5 所示，以无人机 i 的信息输入为例展示了注意力机制处理联合观测-动作信息到输入价值网络的过程。在博弈对抗的某一时刻 t 无人机 i 基于局部观测信息 O_t^i 和动作信息 A_t^i 构建自身观测-动作对 (O_t^i, A_t^i)。将无人机 i 的自身观测-动作对 (O_t^i, A_t^i) 和 $N-1$ 架友机的观测-动作对 $\{(O_t^j, A_t^j)\}_{j=1,j\neq i}^{N}$ 作为注意力机制中的输入序列。注意力机制采用的是键值对 (key-value) 记忆模型，其通过线性投影构建注意力机制的键值对记忆模型：

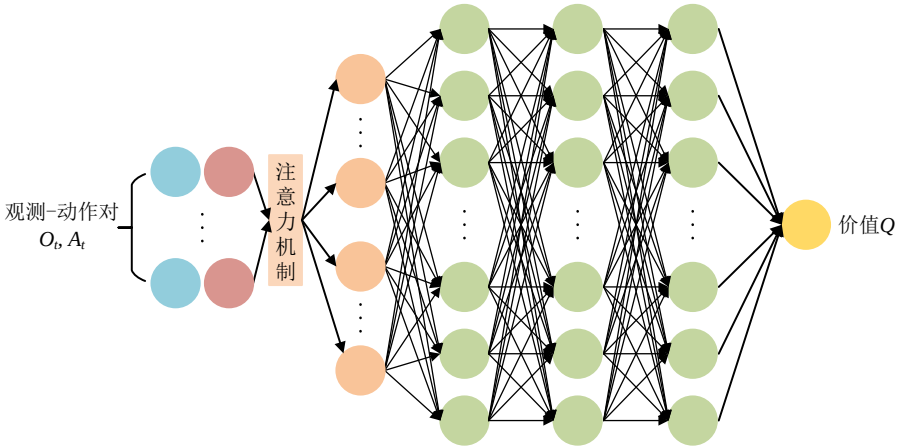
中国知网 https://www.cnki.net

$$\begin{aligned} q_i &= W_q \cdot [O_t^i \| A_t^i] \\ k_j &= W_k \cdot [O_t^j \| A_t^j] \\ v_j &= W_v \cdot [O_t^j \| A_t^j] \end{aligned} \tag{4.15}$$

其中，W_q, W_k, W_v 为可学习投影矩阵。



(a) 策略网络



(b) 价值网络

图 4-4 神经网络结构

因此需要通过友机的观测-动作对 (O_t^j, A_t^j) 得到键向量 k 和值向量 v。随后，通过无人机 i 的自身观测-动作对得到询问向量 q，采用点积的方式将 q 与其他友机的 k 结合计算出无人机 i 对其他无人机信息的注意力分数 α_{ij}。并使用 softmax 函数对所有的 α_{ij} 进行归一化处理得到 α'_{ij}，可以表示无人机 i 对友机 j 的注意力权重。最后，根据注意力权重对友机的观测-动作对求和，得到包含所有友机观测-动作对信息的复合信息 (O_t^f, A_t^f)，并将复合信息 (O_t^f, A_t^f) 与自身信息 (O_t^i, A_t^i) 拼接得到价值网络的输入。

中国知网　https://www.cnki.net

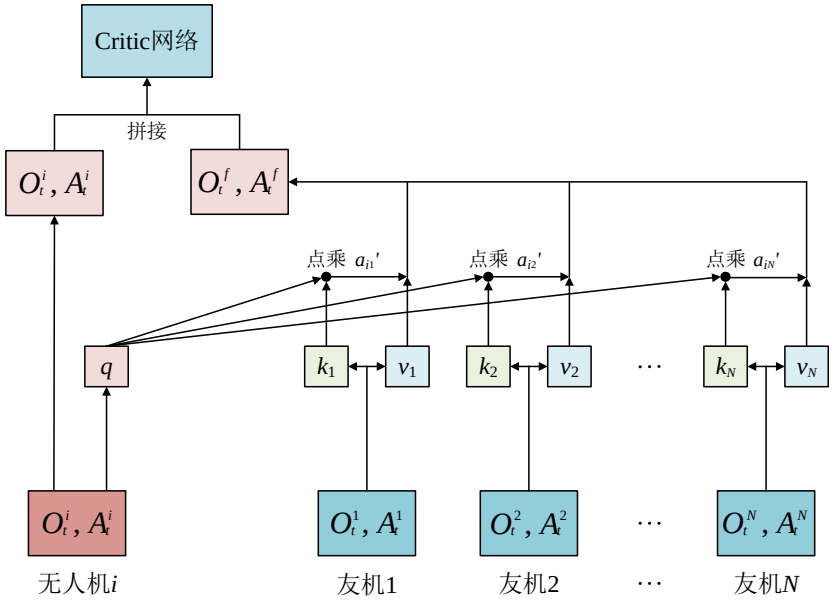


图 4-5 注意力机制流程图

通过对价值网络引入注意力机制可以保证无人机的观测-动作信息经过编码后的维度为 dim 不会随着环境中无人机数量的改变而改变。因为经过注意力机制的编码和整合后，所有无人机的观测-动作信息从 $dim*n$ 维压缩为固定的 dim 维，从而可以让无人机在大规模集群作战的大范围对战环境中更多地关注与自己更为相关的友机，对友机信息的利用率更高，另外通过将所有无人机的观测-动作对合并成一个固定维度向量，也解决了课程学习过程中等级提升带来的价值网络输入维度大幅度扩展的问题。

4.3.3 课程学习思想

课程学习 (Curriculum Learning, CL) 作为一种渐进式训练范式，其核心机制在于分阶段调节训练样本的复杂程度与任务目标难度，通过层次化知识迁移路径实现模型能力的系统性提升。该范式在计算机视觉（如图像细粒度分类）、自然语言处理（如长文本生成）等复杂数据建模领域展现出显著优势，尤其在多智能体系统中通过设计分布式学习范式，构建由简至繁的交互场景序列，有效缓解策略协同优化过程中的非平稳性问题。研究证实，CL 通过模拟人类认知发展中的知识递进规律，建立从具体操作到抽象推理的层次化知识迁移架构，为智能体提供符合学习动力学的优化轨迹。针对强化学习智能体在高维状态-动作空间中面临的探索效率低与收敛困难问题，CL 通过构建层次化任务迁移框架，从简单源任务中提炼共性知识表征，从而提升复杂目标任务的训练稳定性与策略泛化能力。

难度测量器与训练调度器作为课程学习的核心组件，共同构成其通用框架。难度测量器通过评估训练样本的难度层级并进行有序排序，使模型能够从相对简单的样本入手，逐步过渡到复杂样本的学习。训练调度器则依据难度测量器的排序结果，动态调整

中国知网 https://www.cnki.net

训练数据选择与策略，引导模型依循预设课程逐步提升训练难度，从而优化训练效率与性能。该框架支持预定义课程学习与自动课程学习两种实现方式。

预定义课程学习 (Predefined CL) 作为一种静态训练管理方法，其核心在于研究者依据任务特性与模型训练规律，通过预先设定的规则和条件调控训练流程。具体而言，实验者可针对任务需求预先定义难度测量器与训练调度器的参数及策略，使训练过程按照预设的难度梯度有序推进。与之相对，自动课程学习 (Automatic CL) 是动态管理范式，模型能够基于训练过程中的反馈信息，自适应调整难度测量与训练调度策略，以匹配任务需求与数据分布的动态变化。

鉴于本文第三章中已对无人机集群博弈对抗问题形成充分的先验认知，且考虑到资源与时间约束，本章采用预定义课程学习方式。该方法通过预设合理的难度评估与训练调度策略，可在有限计算资源下避免动态自适应过程的额外开销，从而显著提升训练效率。通过精确控制训练样本的难度梯度与调度时序，可在有限训练周期内实现模型能力的快速收敛，同时降低动态策略搜索带来的额外计算开销。课程学习思想有效平衡了训练效率与模型性能的关系，为复杂博弈场景下的智能体训练提供了有效的解决方案。

本章设计的课程学习模块采用分层递进训练机制，通过构建动态可扩展的对抗规模演化模型实现策略能力的系统性提升。课程等级 L 对应的集群规模 N 演化公式为：

$$N = N_{\text{base}} + \Delta N \cdot (L - 1) \tag{4.16}$$

其中 N_{base} 初始等级下 ($L = 1$) 一方集群中无人机的数量，ΔN 表示每次课程等级增加集群中新增无人机的数量。随着集群规模 N 的增加，对抗区域的边长大小，空域占领区的数量等都会随之增加，具体设置与 4.2.2 中设定保持一致。

4.4 仿真实验结果

4.4.1 仿真实验环境

本章实验是采用基于 CLA-MADDPG 的多智能体强化学习算法框架，选用 4.2.2 节的大规模无人机集群空域争夺任务环境。该环境同样是基于 Python 的 gym 框架搭建的二维仿真训练环境。无人机在有限大小的正方形对抗区域内保持固定高度飞行，右水平方向为 X 轴的正方向，垂直向上方向为 Y 轴的正方向。环境中，红色等腰三角形为红方无人机，蓝色等腰三角形为蓝方无人机，三角形的顶角定义为无人机的飞行朝向。环境中双方最终对战的无人机集群规模 N 是 2 到 50，且环境设定正方形对抗区域的范围大小随着无人机数量的增加而扩大，因此，选用以 800m 为边长的正方形作为集群规模最小时的对抗环境，以 20km 为边长的正方形作为集群规模最大时的对抗环境。黄色虚线包裹的圆区域为空域占领区域，被红方无人机集群占领后区域虚线会变成红色，反之，会变成蓝色。空域占领区域的个数为 $2k(k = \lceil N/10 \rceil)$，区域半径 $R_z = \sqrt{\lceil N/10 \rceil}$km，平均分配在 $x = 0$ 轴线两侧。具体的仿真环境如图 4-6 所示。

中国知网　https://www.cnki.net

每个回合红方无人机集群在对抗区域的左侧初始化，范围是 $x \in [-x_{\max}, -0.8x_{\max}]$. 相反的，蓝方无人机集群在对抗区域的右侧初始化，范围是 $x \in [0.8x_{\max}, x_{\max}]$。双方无人机集群在初始化时均采用固定位置分布进行部署，以确保无人机之间不会出现重合，且初始阶段集群不会混乱. 假设双方无人机集群内容之间能够正常通信并且没有通信延迟，所有无人机都搭载了两枚空对空导弹和雷达传感器。

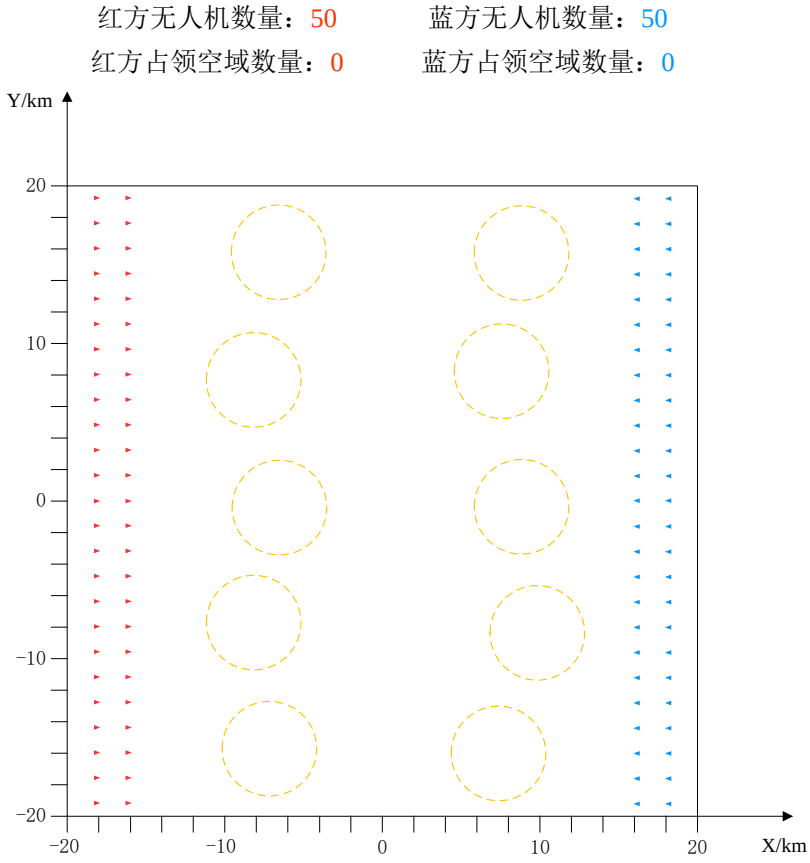


图 4-6 仿真环境图

4.4.2 训练结果与测试评估

（1）模型训练与对比实验

仿真平台的运行环境采用的硬件配置是 Ubuntu18.04 操作系统，CPU 是 Intel core i7-12700H，GPU 是 NVIDIA GeForce 3080，运行内存是 32G。仿真环境使用 Python 语言搭建，训练代码所使用的神经网络基于 Pytorch 构建，使用 Adam 优化器优化算法参数。每回合训练开始后，双方无人机集群开始抢占空域占领区，并进行对抗。当无人机达到终止状态时将会结束该回合训练，终止状态分别为：1）任何一方无人机集群全部被击毁；2）达到回合最大执行步数。结束时的胜利条件设定在 4.2.2 节中已经给出。训练过程中算法各参数设置如表 4-1 所示，表中 N 代表环境中的无人机集群的规模。

为了突出算法在大规模无人机集群对抗中的优势，本章在对比实验中共设计三种

中国知网 https://www.cnki.net

表 4-1 算法相关参数

参数符号	参数含义	参数值
γ	奖励折扣因子	0.97
lr_θ	策略网络学习率	0.0005
lr_φ	价值网络学习率	0.0005
D	经验回放池容量	500 * N
MAX_EPISODES	最大训练轮数	5000 * N
EPISODE_LENGTH	单轮最大执行步数	100 * N
W	课程学习评估窗口	5 * N
η_{w}	课程学习等级更新阈值	0.8
BATCH_SIZE	采样批次大小	128

对抗环境，对应无人机集群规模 N 为 10、30 和 50 的三种场景。在环境中分别使用所提出的 CLA-MADDPG 算法、第三章提出的 PER-MADDPG 算法和未改进的 MADDPG 算法训练模型，训练时三种算法在相同的环境中使用相同的训练参数进行训练。CLA-MADDPG 算法采用了课程学习思想，设定课程等级从 1 到 5，模型从课程等级 1 的环境开始训练，此时的无人机集群规模为 $N/5$，最终到达课程等级 5 的环境，此时的无人机集群规模为 N。其他两种算法直接在集群规模为 N 的环境中进行模型训练。为了确保在算法胜率对比分析中能够排除其他外部因素的干扰，本文将敌方无人机的空战行为策略设定为固定的规则策略，以此作为算法有效性对比验证的基础。本章设定的无人机集群对抗固定规则策略同样分为三个阶段：

（1）抢占阶段：在对战开始后，集群中无人机会分散朝着与自身距离最近的空域占领区全速前进，以最快的速度占领本方半区内的所有占领区。

（2）控制阶段：集群在完全控制本方半区内的所有占领区后，会在占领区内留一半左右的无人机防守，其他无人机会向距离最近的敌方半区内的占领区前进。若是友机出现阵亡，则会从距离最近的控制后的占领区中派出留守的无人机进行支援，直到控制的占领区中只剩下一架无人机。

（3）争夺阶段：出击的无人机在遇到敌机时会与敌机对抗，通过与友机合作实现对敌机的联合攻击，附近没有友机则采用第三章中固定规则中交战阶段的博弈对抗规则展开攻击。若成功击毁敌方半区内的占领区内所有无人机，则保留一架无人机在占领区内控制区域，其余无人机继续进攻其余未控制的占领区。

首先，在无人机集群规模为 10 的对战环境中进行对比实验，训练过程最大训练回合数为 50000，每个回合最大执行步数为 1000，得到实验结果如图 4-7 所示。图中横轴表示无人机与环境交互的时间步数，纵轴表示三种不同算法训练的无人机集群对抗模型获得的平均奖励。从图 4-7 可以看出，三种训练算法最终均可以收敛成功。CLA-MADDPG 算法在 10000 个回合后就可以成功收敛，另外两种对比算法均在 20000 个回合以后才完成收敛，表明未改进的 MADDPG 和 PER-MADDPG 算法均需要更长时间的探索与尝

中国知网　https://www.cnki.net

试。此外，相较于另外两种对比算法，CLA-MADDPG 算法在实验中取得了更高的平均奖励值，并且收敛后稳定性也相对更高。

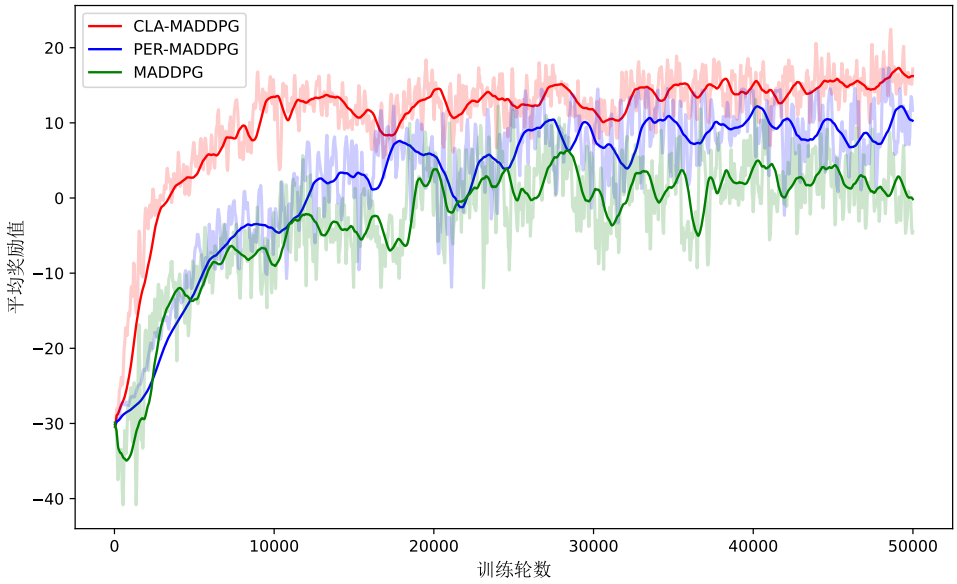


图 4-7 10 vs 10 对比实验结果图

随后，在无人机集群规模为 30 的对战场景环境中进行性能对比，训练过程最大训练回合数为 150000，每个回合最大执行步数为 3000，得到实验结果如图 4-8 所示。MADDPG 算法虽然收敛很快，但是收敛后的平均奖励值很低且奖励值震荡明显；PER-MADDPG 算法的收敛比较困难，达到收敛需要训练的轮数大幅度增加，最终收敛的平均奖励值同样较低，而 CLA-MADDPG 算法的收敛速率仍非常快，最终收敛的平均奖励值比另两种对比算法的优势明显。

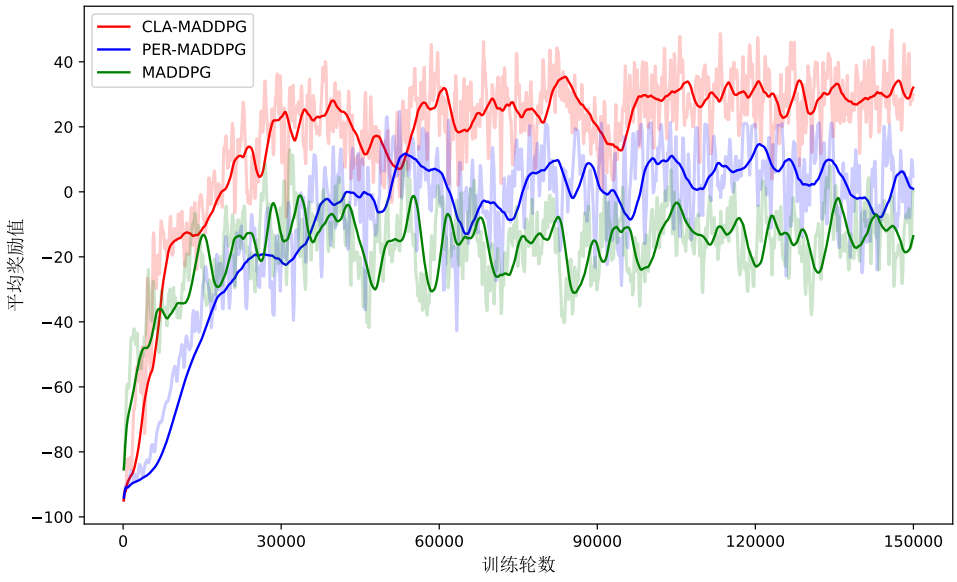


图 4-8 30 vs 30 对比实验结果图

中国知网 https://www.cnki.net

最后，在无人机集群规模为 50 的对战场景环境中进行三种算法的对比实验，训练过程最大训练回合数为 250000，每个回合最大执行步数为 5000，得到实验结果如图 4-9 所示。MADDPG 算法在处理集群规模进一步扩大的对抗问题中难以困难，即使勉强收敛其平均奖励值很低并且震荡严重。PER-MADDPG 算法收敛速率略强于 MADDPG 算法，但是收敛后的平均奖励值同样较低。上述两种算法在协调大规模多智能体行为时的局限性较大，而 CLA-MADDPG 算法在收敛速率和收敛后的平均奖励值上都显著优于另外两种对比算法，证明了引入课程学习策略后的多智能体强化学习算法在处理大规模多智能体训练任务中具有显著优势。

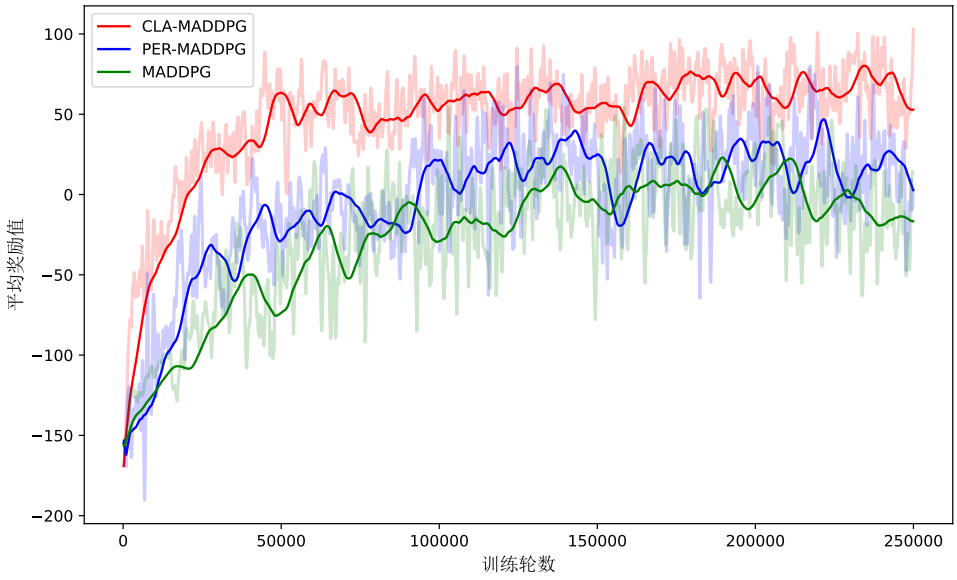


图 4-9 50 vs 50 对比实验结果图

为了更直观地观察算法策略控制的无人机集群在空域争夺任务中具体的机动决策行为，本节选用在无人机集群规模是 50 时训练收敛后的策略模型，在仿真环境中加载模型，并与采用固定规则策略的敌方无人机集群展开空域争夺对抗。图 4-10 为不同时刻无人机集群空域争夺对抗的过程图，T = 0s 时双方无人机集群均匀分布在对抗环境两侧的设定区域内，准备开始前往抢先控制本方半区内的占领区；T = 250s 时双方无人机集群均已成功控制本方半区的占领区，并分别派出集群中的大部分无人机前往攻占对方半区内的占领区；T = 500s 时，红方无人机集群已经抢占了两个敌方半区内的占领区，剩下三个区域中双方集群还在进行联合对抗；最终，T = 750s 时，到达设定的对抗时间，红方无人机集群控制了 8 个占领区，蓝方无人机集群控制了 2 个占领区。存活的红蓝双方方无人机携带的导弹均已经发射，所以都在己方的控制区内防守。此时双方对抗结束，红方无人机集群获得对抗胜利。

中国知网　https://www.cnki.net

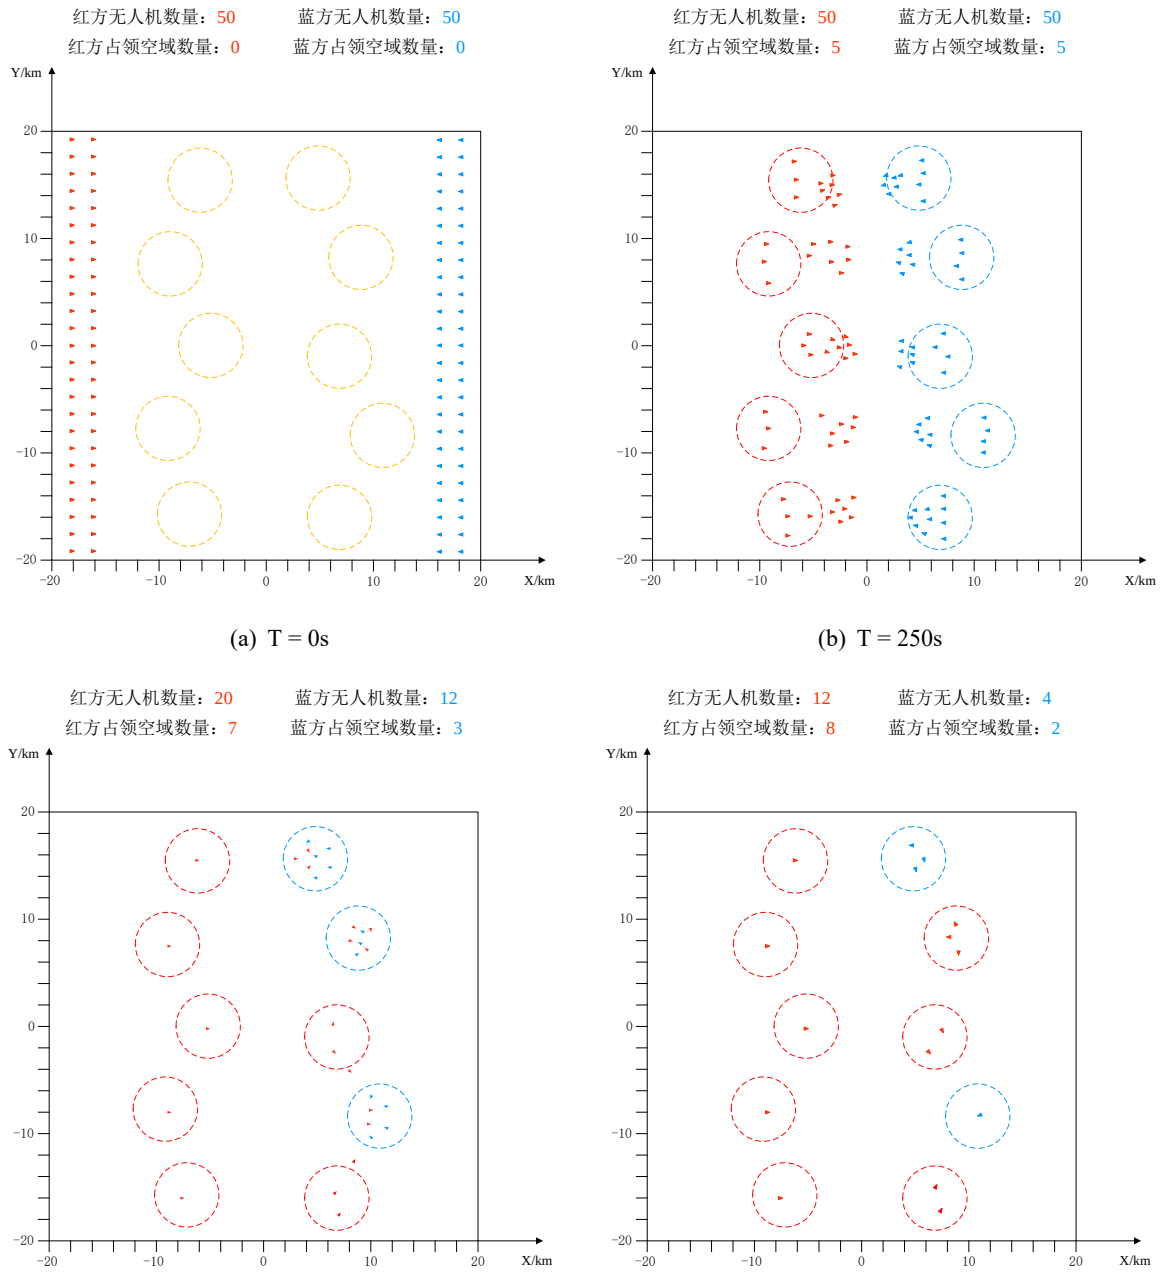


图 4-10 不同时刻无人机集群对抗状态图

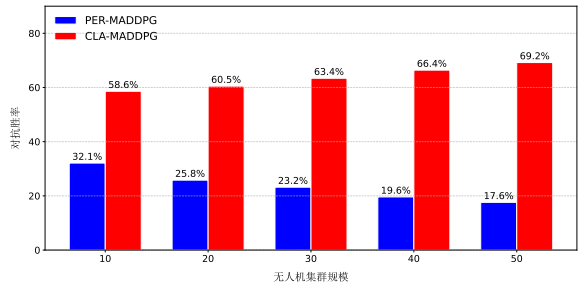
（2）对抗实验分析

鉴于本章提出的算法遵循课程学习框架，其课程难度等级的调整机制依赖于无人机集群在对抗过程中的平均胜率，而非传统基于训练回合数的渐进式更新策略。这种特性导致算法胜率指标与训练迭代次数之间不存在显式关联关系。为此，本节设计了对抗性能对比实验：将三种算法在不同的对抗环境中训练策略模型收敛后，使用收敛后的模型在对应的环境中直接对抗。

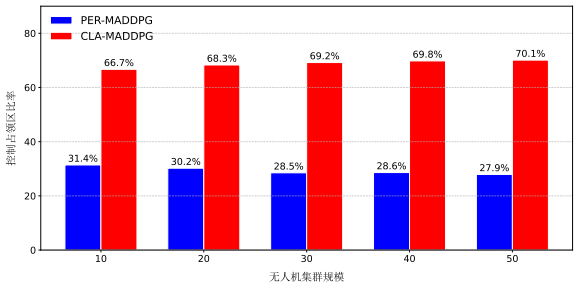
实验共选取五组对抗环境，无人机集群规模分别设置为 10、20 、30、40 和 50。为

中国知网 https://www.cnki.net

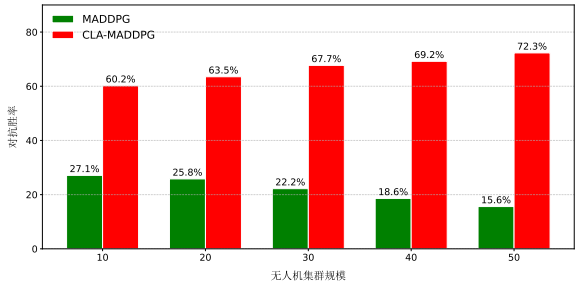
确保评估的公平性，对抗双方均采用对应算法在相同环境参数下独立训练收敛后的最优模型参与测试，排除训练过程中动态参数变化对评估结果的潜在干扰。为了验证 CLA-MADDPG 算法的性能，分别将其与 PER-MADDPG 算法和 MADDPG 算法在不同环境中对抗 1000 次，并统计对抗双方胜率以及双方控制占领区的平均数量占总空域占领区的百分比。该实验设计可有效验证 CLA-MADDPG 算法在不同集群规模下的泛化性能，同时验证算法在处理大规模集群对抗问题的优势。



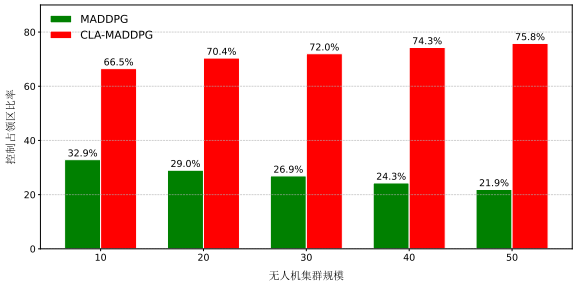
(a) CLA-MADDPG 和 PER-MADDPG 对抗胜率



(b) CLA-MADDPG 和 PER-MADDPG 控制占领区比率



(c) CLA-MADDPG 和 MADDPG 对抗胜率



(d) CLA-MADDPG 和 MADDPG 控制占领区比率

图 4-11 不同环境下算法对抗结果

CLA-MADDPG 算法训练的模型与 PER-MADDPG 算法训练的模型的对抗胜率对比如图 4-11(a) 所示，与 MADDPG 算法训练的模型的对抗胜率对比如图 4-11(c) 所示。分析图中数据可知，随着参与对抗的无人机集群数量的增加，采用本章提出的 CLA-MADDPG 算法训练的模型的对抗优势越明显，在无人机集群数量达到 50 时，对抗其他两种算法训练的模型的胜率达到了 70% 左右。CLA-MADDPG 算法训练的模型与 PER-MADDPG 算法训练的模型的控制区域比率对比如图 4-11(b) 所示，与 MADDPG 算法训练的模型的控制区域比率对比如图 4-11(d) 所示。在空战占领区的控制比例上 CLA-MADDPG 算法相较另外两种算法同样优势明显，控制的区域占比一直保持稳定。从图中可以发现对抗双方的控制区域的比率相加的和略小于 1，这是因为在对抗中的小部分情况下会出现双方都没有控制到的区域。对抗结果进一步证明了 CLA-MADDPG 算法在处理大规模无人机集群空战争夺问题的显著优势。

（3）模型泛化性分析

在不进行额外训练的情况下，本节将对所提出的算法训练的模型进行泛化性测试。

中国知网　https://www.cnki.net

本节采取在集群对抗环境中增加空域占领区的方式验证泛化性，具体实验方式为，加载训练收敛后保存的神经网络模型，增加仿真环境中的空域占领区数量。新增的占领区数量为 2 的倍数，并且同样平均分布在对抗区域对称轴的两侧。采用模型在占领区数量不同的情况下都进行 1000 次测试，统计算法的对抗胜率以及控制的占领区的平均数量。

泛化性实验结果如表 4-2 所示，测试结果表示，在占领区数量发生变化的情况下，基于所提出的算法所训练的模型的对抗胜率仍保持在 87% 以上。在控制的占领区的平均数量方面，训练的模型同样表现出现，可以控制绝大多数的占领区，表明算法具有较强的泛化性能。

表 4-2 泛化性实验测试结果

无人机集群规模	空域占领区数量	实验次数	控制占领区的平均数量	对抗胜率 (%)
10	4	1000	3.44	89.4
	6	1000	5.19	88.5
20	6	1000	5.25	88.8
	8	1000	6.93	88.3
30	8	1000	7.02	88.5
	10	1000	8.82	87.9
40	10	1000	8.93	88.7
	12	1000	10.65	87.5
50	12	1000	10.75	88.1
	14	1000	12.32	87.2

4.5 本章小结

本章针对强化学习在大规模集群对抗中存在的策略收敛困难与扩展性不足的问题，在原先的仿真环境基础上扩展搭建了大规模无人机集群空域争夺任务仿真环境。考虑到传统多智能体强化学习算法难以处理无人机数量较大时出现的维数灾难等问题，本章在上一章研究的基础上，结合了课程学习的训练思想和注意力机制，提出了 CLA-MADDPG 算法，最后在仿真环境中对提出的算法进行验证分析。结果表明，相较于传统 MADDPG 算法和上一章提出的 PER-MADDPG 算法，CLA-MADDPG 算法在解决大规模无人机集群空域争夺问题上具有明显优势并具有较强的泛化性。特别是在集群规模超过 30 架时，CLA-MADDPG 算法展现出显著的对抗优势，其优势源于课程学习引导的渐进式策略探索机制，通过分层难度训练有效缓解了高维状态空间的探索利用失衡的问题。

中国知网 https://www.cnki.net

第五章　复杂环境下基于强化学习的无人机集群对地支援博弈对抗

5.1　引言

在军事作战领域，复杂环境下的无人机集群博弈对抗具有极为重要的应用价值，其核心在于通过多无人机协同作战，实现对抗环境下的分布式作战优势。本章在前两章研究基础上，重点探讨复杂城市作战场景下无人机集群对地支援问题。相较于高空对抗环境，复杂城市环境中障碍物的存在显著增加了集群协同的难度，这对无人机间的协作能力提出了更高要求。针对该问题，本章首先根据复杂环境下无人机集群对地支援对抗的任务模型构建了相应的马尔可夫决策过程。在第四章奖励函数设计的基础上，进一步引入了障碍物规避相关的奖励项，以完善奖励函数的设计。考虑到复杂环境中传统多智能体强化学习算法存在误差累积放大的问题，本章采用多智能体双延迟深度确定性策略梯度算法作为基础框架以有效抑制误差传播。同时，为应对大规模无人机集群的对抗需求，本章保留了第四章提出的课程学习思想和注意力机制。此外，为提高算法在复杂场景中的策略质量，本章引入了自博弈训练框架，最终提出了 CLA-MATD3-SP 算法。通过复杂环境仿真实验，验证了所提算法在集群对地支援作战任务中的优势，同时证明了自博弈训练框架的普适性。

5.2　问题建模

5.2.1　复杂环境下无人机集群对地支援任务模型

（1）城市空战环境模型设计

本章为了验证所提算法在复杂环境下大规模无人机集群对抗中的实际效能，构建了复杂城市场景下的二维无人机集群博弈对抗仿真环境。为了更加真实的模拟城市空战场景，本章中设计了若干高楼作为城市空战场景中的障碍物，无人机在空战的过程中要躲避高楼或者也可以通过高楼躲避敌方的探测。此外，为了模拟城市作战中无人机与地面部队的协同作战，在场景中的高楼中心区域设定有地面交战区，无人机在该区域可以为己方地面部队提供雷达干扰等辅助支持。因此，在地面交战区中无人机数量越多，对部队整体的城市作战更加有利。同时，与前两章相同，本章的城市空战场景中也设有红蓝两个无人机集群，双方无人机集群以 1 : 1 数量比部署于空战环境，作战范围边界与集群规模 N 的大小成正比。双方集群中无人机的运动模型，博弈对抗模型以及联合攻击模型等均和前两章设计相同。

（2）对地支援作战任务设计

本模型为突显城市作战环境中的空地协同特性，设计了基于地理空间约束的协同作

中国知网　https://www.cnki.net

战机制，为城市环境中的地面交战区提供对地支援。地面交战区被定义为城市建筑群中心若干个具有战略价值的圆形区域。根据集群规模自适应的环境生成原则，设定地面交战区数量为 k ($k = \lceil N/10 \rceil$)。另外，通过区域对称性设计确保对抗公平性：所有交战区沿正方形对抗区域的 $x = 0$ 对称轴镜像分布，其总面积由轴线均分至对抗双方半区。与第四章单纯区域占领机制不同，本任务要求双方向时在交战区内执行混合任务，即在为己方地面部队提供战术支援的同时，需与敌方无人机展开动态对抗，通过制空权争夺来削弱敌方对地支援能力。图 5-1 为对地支援作战任务的具体示意图。

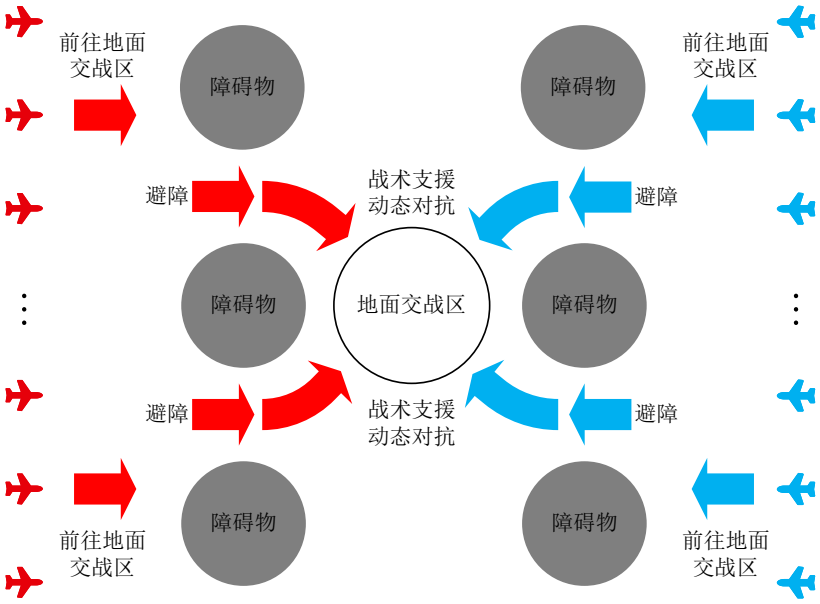


图 5-1 对地支援作战任务示意图

（3）对抗任务胜负判定规则

本章设计的对抗终止条件同样遵循双阈值准则：当任意方无人机全灭，或对抗持续时间达到预设阈值时，系统自动终止仿真。胜负判定采用三级递进评估体系：1）首要评估指标为地面交战区内存活无人机的数量；2）当交战区存活数量持平时，扩展评估全区域无人机存活总量；3）若全域数量仍相同则判定平局。该评估体系通过设置战术支援能力的优先级，从决策层面强化了对地支援在城市作战中的战略价值，引导无人机集群在制空权争夺与对地支援任务间实现动态平衡。

5.2.2 高楼障碍物模型

为提升仿真环境的真实性与复杂性，本章在二维无人机集群博弈对抗仿真环境中引入障碍物模型。障碍物作为城市空战场景的关键要素，对无人机的飞行路径规划、战术决策及生存能力构成新的挑战。障碍物模型设计需综合考虑几何形状、物理特性及与无人机和导弹的交互规则。

本章的障碍物在仿真场景中设计为圆形等规则几何体，其位置、大小与数量依据预

中国知网 https://www.cnki.net

设的战场地图布局随机生成。高楼障碍物建模为具有刚体属性的不可穿透实体，其空间分布服从泊松分布，以此模拟城市环境中建筑物等固定结构对空战的影响。在物理特性方面，障碍物被视为刚体，无人机若与之发生碰撞，则判定无人机损毁并退出当前对抗。此外，障碍物还具备遮蔽功能，无人机可利用其进行战术规避，防止被敌方雷达探测，增加生存几率。

如图 5-2 所示，红方无人机处于蓝方无人机的危险区域内，无障碍物时蓝方无人机处于红方无人机的攻击区域内，理论上红方无人机可以发动有效攻击击毁蓝方无人机。但是由于障碍物阻挡了红方无人机的探测，红方无人机攻击区域变小，此时蓝方无人机并不处于红方无人机的攻击区域内，红方无人机无法发现蓝方无人机并进行有效攻击。

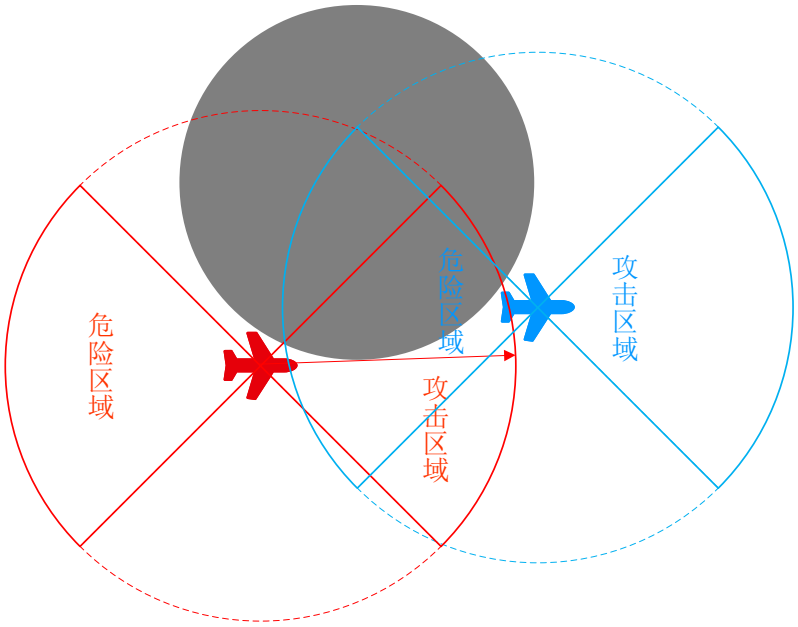


图 5-2 障碍物附近无人机对抗示意图

5.2.3　复杂环境下无人机集群对地支援任务 MDP 模型

本节根据复杂环境下无人机集群空战对抗的特点，将复杂环境下无人机集群对地支援任务建模为马尔可夫决策过程，下面详细介绍马尔可夫决策过程的相关元素，包括状态空间、动作空间和奖励函数三个部分。

状态空间：对于集群中的无人机 i，其局部观测空间 O^i 由无人机状态信息 O_1^i 和雷达探测器障碍物信息 O_2^i 和雷达探测器敌方信息 O_3^i 所组成，可以表示为：

$$O^i = [O_1^i, O_2^i, O_3^i] \tag{5.1}$$

无人机状态信息 O_1^i 包括自身坐标、速度、相对于最近的地面交战区圆心的距离和航向角信息，其中 x_i 和 y_i 是无人机在二维作战平面内的坐标信息，Δx_i 和 Δy_i 表示无人

中国知网　https://www.cnki.net

机在 X 轴和 Y 轴方向相对于最近的地面交战区圆心的距离，v_i 表示自身速度信息，ψ_i 表示自身航向角信息，如式 (5.2) 所示。

$$O_1^i = [x_i, y_i, \Delta x_i, \Delta y_i, v_i, \psi_i] \tag{5.2}$$

此外，由于环境中存在高楼障碍物，本章中设计无人机搭载雷达测距传感器，该传感器用于测量无人机飞行方向正负 $\theta_{att}/2$ 范围内，相对于周围障碍物的距离。雷达测距传感器在 θ_{att} 范围内，每隔 $\theta_{att}/19$ 测量一次距离，因此一共可以测量出 20 个距离值，雷达测距传感状态 O_2^i 可以表示为:

$$O_2^i = [d_1, d_2, \ldots, d_{20}] \tag{5.3}$$

其中 $d_i (i = 1, 2, \cdots, 20) \in [0, L]$ 为雷达测距传感器测量的距离，$d_i = 0$ 表示传感器没有检测到障碍物；$d_i \in (0, L]$ 表示障碍物相对于无人机的距离。

另外，无人机还可以根据雷达的观测范围，确定没有被障碍物阻挡的与本机最近的 M 架敌方无人机的距离以及与敌方无人机之间的偏航角之差（用于判断我方无人机是否在敌方无人机的威胁区域内）作为雷达探测器状态信息 O_3^i，其中 d_{ij} 表示无人机 i 与敌方无人机 j 之间的距离，$\Delta\psi_{ij}$ 表示无人机 i 与敌方无人机 j 之间的偏航角之差，若是没有检测到敌方无人机则信息均为 0，如式 (5.4) 所示。

$$O_3^i = [(d_{i1}, \Delta\psi_{i1}), (d_{i2}, \Delta\psi_{i2}), \ldots, (d_{iM}, \Delta\psi_{iM})] \tag{5.4}$$

由于本章是大规模无人机协同对抗环境，因此联合观测空间 O 是由无人机集群中所有无人机的局部观测空间组成，如下式所示：

$$O = [O^1, O^2, \ldots, O^N] \tag{5.5}$$

动作空间：动作空间与前两章保持一致，通过控制无人机航向加速度 a_i 和航向角速度 $\dot{\psi}_i$ 来控制无人机的运动，无人机 i 的动作空间可以表示为：

$$A^i = [a_i, \dot{\psi}_i] \tag{5.6}$$

同样的，无人机集群的联合动作空间 A 定义为 $A = [A^1, A^2, \ldots, A^N]$。

奖励函数：对于复杂环境下集群博弈对抗问题，与前两章相同，对于无人机集群将其每一时间步过程奖励为定义为 R_t。鉴于无人机集群对地支援问题最终的目标是同样是通过集群协同击败敌方，故每一时间步的过程奖励即为所有无人机奖励之和：

$$R_t = R_t^1 + R_t^2 + \ldots + R_t^N \tag{5.7}$$

对于每个无人机 i，奖励 R_t^i 包括五个部分，分别为击毁敌机奖励，被击毁奖励，碰撞奖励，出界奖励，地面战术援助奖励。

$$R_t^i = R_{\text{destroy}} + R_{\text{destroyed}} + R_{\text{collision}} + R_{\text{outside}} + R_{\text{ground}} \tag{5.8}$$

中国知网 https://www.cnki.net

（1）击毁敌机奖励 R_{destroy}

当无人机直接击毁敌方无人机或者通过提供探测信息帮助友机击毁敌方无人机后，对本方无人机集群有利，因此给予一个正奖励，R_{destroy} 定义如下：

$$R_{\text{destroy}}=\begin{cases} r_{\text{d1}}, & \text{if 自主击毁敌方无人机} \\ r_{\text{d2}}, & \text{if 协同击毁敌方无人机} \\ 0, & \text{otherwise} \end{cases} \tag{5.9}$$

其中，为了训练集群策略侧重于协同攻击，设计 $r_{\text{d2}}=1.5*r_{\text{d1}}$。

（2）被击毁奖励 $R_{\text{destroyed}}$

当无人机被敌方无人机击毁后，对本方无人机集群不利，因此给予一个负奖励，$R_{\text{destroyed}}$ 定义如下：

$$R_{\text{destroyed}}=\begin{cases} -r_{\text{d}}, & \text{if 被敌方无人机击毁} \\ 0, & \text{otherwise} \end{cases} \tag{5.10}$$

（3）碰撞奖励 $R_{\text{collision}}$

碰撞奖励 $R_{\text{collision}}$ 是为了引导无人机在运动过程中，避免与自身周围障碍物相撞。当无人机与自身周围障碍物相撞时，将会获得负向奖励。根据无人机搭载的雷达测距传感器，可以确定无人机是否与障碍物相撞，雷达测距传感器一共有 20 个距离测量值，当这 20 个测量值中的最小值小于安全距离 L_{limit} 时无人机必定会与障碍物相撞，$R_{\text{collision}}$ 定义如下：

$$R_{\text{collision}}=\begin{cases} -r_{\text{c}}, & \text{if 无人机和障碍物碰撞} \\ 0, & \text{otherwise} \end{cases} \tag{5.11}$$

（4）出界奖励 R_{outside}

无人机若是脱离规定的作战区域应该给予惩罚，确保双方无人机可以在规定区域内进行博弈对抗，因此无人机出界会被给予一个负奖励，R_{outside} 定义如下：

$$R_{\text{outside}}=\begin{cases} -r_{\text{o}}, & \text{if 无人机出界} \\ 0, & \text{otherwise} \end{cases} \tag{5.12}$$

（5）地面战术支援奖励 R_{ground}

任务目标是无人机集群能够为地面部队提供足够的战术支援，当无人机位于地面交战区内部提供战术支援时，会根据给予一个正奖励。为了引导无人机向地面交战区前进，会在无人机处于地面交战区外部时给予一个负奖励，R_{ground} 定义如下：

$$R_{\text{ground}}=\begin{cases} r_{\text{g}}, & \text{if 位于地面交战区内部} \\ -k_{\text{g}}*d_{\text{u,g}}, & \text{otherwise} \end{cases} \tag{5.13}$$

中国知网　https://www.cnki.net

其中 k_{g} 是战术支援奖励调解系数，$d_{\mathrm{u,g}}$ 是当前时刻无人机距离最近的地面交战区圆心的距离。

5.3 基于 CLA-MATD3-SP 算法的无人机集群博弈对抗算法设计

5.3.1 算法框架结构

本章为了解决复杂环境下大规模无人机集群博弈对抗的问题，对前两章使用的 MADDPG 算法框架进行了改进，引入了 MATD3 算法框架用以解决价值网络 Q 值估计问题。由于本章设计的仿真环境中无人机集群规模仍然会达到较大的量级，因此，本章设计的算法保留了课程学习思想，保证训练的无人机集群可以由易到难的学习到优异的博弈对抗策略。

算法 5.1 基于 CLA-MATD3-SP 的大规模无人机集群对抗训练算法

初始化价值网络参数 θ^1、θ^2 和策略网络参数 φ，经验缓冲区 D，叶子节点优先级 p_1
初始化课程学习更新阈值 η_{w}，课程评估窗口 W，自博弈轮数 ROUND
for 回合 $episode = 1$ to MAX_EPISODE **do**
  每 W 轮计算平均对抗胜率，更新课程等级
  重置环境，获取联合观测 $O_t = [O_t^1, O_t^2, \ldots, O_t^N]$
  for 时间步 $t = 1$ to EPISODE_LENGTH **do**
    集群中每架无人机 i 执行动作 $A_t^i = \{\mu_i(O_t^i)\}_{i=1}^N$，根据奖励函数计算奖励 R_t^i
    环境更新，得到下一时刻局部观测 O_{t+1}^i，获取终止标志 $done$ 及奖励 R_t
    存储经验 $(O_t, A_t, R_t, O_{t+1}, p_t)$ 至缓冲区 D
    if 缓冲区样本数 $D > N_m$ **then**
      按优先级采样 N_m 组经验 $\{(O_k, A_k, R_k, O_{k+1}, p_k)\}_{k=1}^{N_m}$
      计算 TD 误差并更新优先级
      更新两个价值网络参数和策略网络参数
      目标网络软更新
    end if
  end for
end for
将收敛后的红方无人机集群策略 π_1 载入蓝方无人机集群的策略集合中
for 轮数 $r = 1$ to ROUND **do**
  从策略集合中选择策略作为对手给蓝方无人机集群使用
  重置课程等级，重复第 3 到 30 行训练过程，并将收敛策略的 π_r 载入蓝方无人机集群的策略集合中
end for

中国知网 https://www.cnki.net

在前两章的模型训练过程中，针对敌方无人机集群采用的都是基于规则的固定策略，无人机集群能够获得基础协同机制与战术范式。但在本章的复杂城市环境下，这种简化设置训练出的决策模型难以适应复杂场景下的策略博弈需求，具体表现为敌方战术多样性不足以及策略演化停滞等问题。为此，本章引入基于自博弈对抗的协同进化训练框架，提出了融合课程学习和注意力机制的多智能体双延迟深度确定性策略梯度自博弈算法 (Curriculum Learning and Attention Multi-Agent Twin Delayed Deep Deterministic Policy Gradient with Self-Play, CLA-MATD3-SP)，突破传统单方面策略优化的瓶颈，提升无人机集群的对抗强度，进而得到战力更强的无人机集群博弈对抗模型。CLA-MATD3-SP 算法保留了注意力机制，因为将注意力机制应用在价值网络的信息输入前可以有效解决课程学习导致的输入信息维度变化较大的问题。另外，由于本章的博弈对抗任务更为复杂，因此，本章中设计内容导向的多头注意力机制，将价值网络输入的每个无人机观测-动作对分成无人机动作、无人机自身位置信息、无人机雷达探测的障碍物信息和雷达探测到的敌方无人机信息四部分，从而训练出更精细的协同决策。

在算法 5.1 中给出了算法的完整训练流程。算法首先初始化课程学习参数及神经网络参数，每完成指定回合数后评估胜率，若达标则提升课程等级，并提高集群规模、对抗环境边界和障碍物数量等环境信息以增加对抗环境复杂度。在每个时刻中，无人机基于局部观测执行动作，获取奖励和下一时刻的联合观测，并将这些经验信息存储至优先级经验池。当经验积累到一定程度时，从经验池中采样一批数据，通过重要性采样更新经验优先级以强化关键样本学习，并更新策略网络和价值网络参数。在第一次训练收敛后，引入自博弈机制，将训练达到收敛的策略存入策略集合。随后，从策略集合中选取历史策略作为对手进行多轮对抗训练，促使策略在动态竞争中持续进化。该算法融合课程学习的渐进性、多头注意力机制的高效性以及自博弈的对抗性，有效提升了大规模无人机集群在复杂场景下的协同作战能力。

5.3.2　MATD3 算法框架

本章提出一种基于改进 MATD3 算法的无人机集群博弈对抗方法。MATD3 作为 MADDPG 框架的优化延伸，针对性解决了传统 MADDPG 算法中价值函数估计偏差导致的收敛性问题。尽管 MADDPG 在连续动作空间与部分可观测环境的协作 / 竞争场景中表现优异，但其单 Q 值网络的状态-动作价值评估机制存在系统性高估风险，即迭代过程中 Q 值函数对真实价值的持续高估会引发时序决策误差累积，导致策略网络参数更新偏离最优方向，进而造成学习过程震荡和收敛性能退化。

MATD3 算法通过引入双重价值网络架构与延迟更新机制提升稳定性：在保留 Actor-Critic 框架的基础上，为每个智能体配置独立的在线策略网络及两个并行的在线价值网络。其中双重价值网络采用最小值截断策略抑制高估偏差，即在计算目标值时选取两个价值网络输出的较小值作为基准，有效缓解了单网络估计偏差的累积效应，使价值函数逼近过程更贴近真实回报分布，从根本上改善了算法在复杂博弈环境中的收敛效率与策

中国知网　https://www.cnki.net

略优化质量。

MATD3 算法的结构如图 5-3 所示，智能体组成的联合观测空间定义为 $O=[O^1,O^2,\ldots,O^n]$；联合动作空间定义为 $A=[A^1,A^2,\ldots,A^n]$；每个智能体的在线策略网络根据当前时刻 t 的状态 O_t^i 输出其确定性策略，而在线价值网络则通过智能体的联合观测以及联合动作来评估联合观测-动作对的价值。此外，MATD3 算法同样采用经验重放技术，智能体在每一次与环境互动过程中都会将得到的相关信息保存至经验池 D 内，其中储存了每个智能体的四元组数据$O_t^i,A_t^i,R_t^i,O_{t+1}^i$，分别代表当前 t 时刻下的状态、动作、奖励和下个时刻的状态。

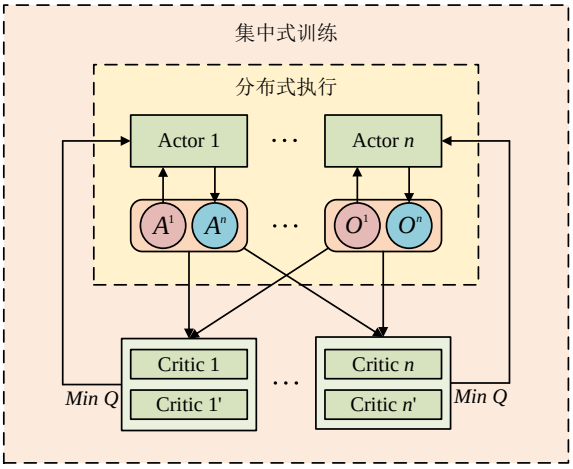


图 5-3 MATD3 算法结构图

每个价值网络通过两个具有独立参数的神经网络来计算 Q 值，并且这两个参数在训练过程中各自进行更新。两个在线价值网络的目标 Q 值分别为：

$$\begin{cases} y_1^i = R^i + \gamma Q_i^{\theta_1'}(O^i,A^i)|_{A^{i'}=\mu_i'(O^i)} \\ y_2^i = R^i + \gamma Q_i^{\theta_2'}(O^i,A^i)|_{A^{i'}=\mu_i'(O^i)} \end{cases} \tag{5.14}$$

在使用两个价值网络来近似动作选择和动作评估时，选用较小的 Q 值作为目标 Q 值，以解决 Q 值过估计问题，从而增强算法的收敛性，价值网络的目标函数为：

$$y^i = R^i + \gamma min_{(m=1,2)} Q_i^{\theta_m'}(O^i,A^i)|_{A^{i'}=\mu_i'(O^i)} \tag{5.15}$$

式中，θ_1'、θ_2' 分别表示为当前智能体的两个目标价值网络的参数，y^i 表示第 i 个无人机的目标值，R^i 表示产生的瞬时奖励，$A^{i'}$ 表示下一步长下智能体采取的动作。在线价值网络由公式 (5.16) 更新：

$$L(\theta) = E_{(O,A,R,O')}\left[\left(y^i - Q_i^{\theta_m}(O,A)\right)^2\right], m=1,2 \tag{5.16}$$

同时通过公式 (5.17) 更新在线策略网络的参数。

$$\nabla_\theta J = E_{O\sim D, A\sim\mu}\left[\nabla_\theta \mu_i(O^i)\cdot\nabla_{A^i}Q_i^{\theta_m}(O,A)\Big|_{A^i=\mu_i(O^i)}\right] \tag{5.17}$$

中国知网 https://www.cnki.net

对于目标网络的更新，引入了阶段性异步更新机制，即目标价值网络更新频率低于目标策略网络，确保价值函数评估的稳定性，以防止算法陷入局部最优。

5.3.3　自博弈训练框架

自博弈方法通过让智能体与自身历史版本进行对抗训练，不断提升策略水平。该方法使智能体能够通过自我探索和迭代掌握更高级的对抗策略。由于自博弈将智能体的历史版本作为对手进行强化训练，智能体在不断战胜更强的历史版本过程中，策略逐渐优化。在缺乏专家数据或难以构建强大对手时，自博弈方法在智能体对抗策略训练中表现出显著优势。

自博弈框架通过智能体与自身历史策略的动态对抗实现策略迭代优化，使智能体在闭环式训练过程中渐进式掌握高阶对抗策略。该方法将智能体的历史策略版本作为训练对手，通过持续击败更强的历史策略驱动自身策略进化，尤其在缺乏专家数据或难以构建外部对手的场景中，展现出独特的训练优势。该框架通过自我探索与迭代更新的闭环机制，有效规避了依赖外部对手的局限性，为智能体对抗策略的自主演化提供了高效解决方案。

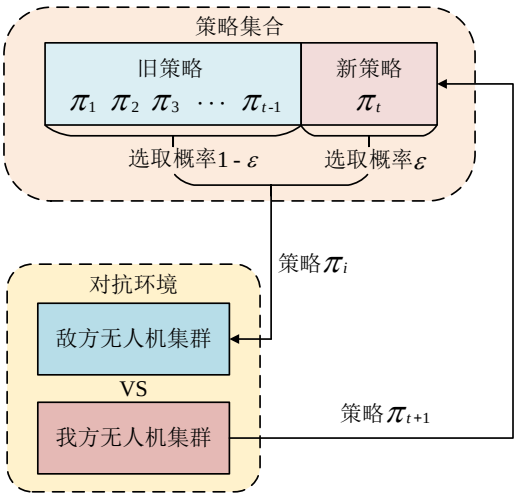


图 5-4 自博弈训练框架

本章使用的自博弈训练架构如图 5-4 所示，训练初始阶段，蓝方无人机集群采用固定规则策略，而红方无人机集群的多智能体系统则在此阶段进行策略学习，该阶段被称为初始学习阶段。当红方无人机集群模型在初始学习阶段收敛后，所学策略模型被应用于蓝方无人机集群并保持不变。随后，红方无人机集群继续与蓝方对抗训练。每次在训练收敛时，红方无人机集群的最新策略均被纳入策略集合。通过不断迭代这一过程，红方无人机集群的策略得以不断优化与强化。

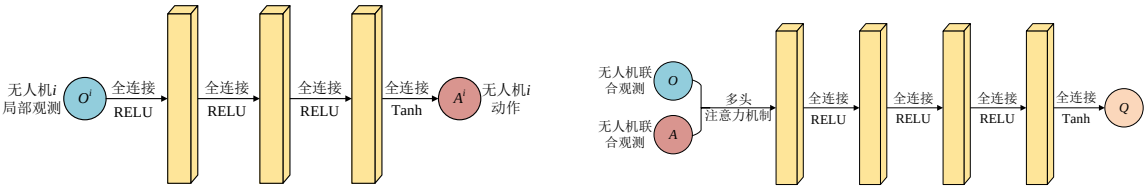
为了避免在复杂博弈情形中仅和最新的策略对战容易陷入局部最优解的问题，本章在进行自博弈训练时，以 ε 的概率选择最新策略作为对抗的蓝方无人机集群策略，以

中国知网　https://www.cnki.net

$1-\varepsilon$ 概率均匀选择策略集合中的旧策略作为对手给蓝方无人机集群使用。通过这种方式，红方无人机集群策略在不断迭代训练中得以优化，从而有效提升其机动决策水平和对抗能力。

5.3.4 神经网络结构

MATD3 算法仍然采用 MADDPG 算法中的 Actor-Critic 框架，与之不同的是每个智能体的决策网络有一个在线策略网络、两个在线价值网络以及与之对应的目标网络，共有 6 个网络，每个网络均采用深度神经网络来实现函数逼近。在该算法的决策网络设计时，策略网络和价值网络的输入和输出有所不同，除此之外的所有结构都完全相同。本章采用的改进 MATD3 算法的网络结构如图 5-5 所示。



(a) 策略网络图　　(b) 价值网络图

图 5-5 算法神经网络结构图

图 5-5 (a) 所示的策略网络以无人机局部观测为输入，经四层全连接层处理（每两个隐藏层间采用 RELU 作为激活函数）后输出动作。各无人机通过该网络在环境状态中学习策略并选择动作，驱动与环境的交互过程。图 5-5 (b) 所示了价值网络的结构，该网络结构中的注意力模块采用多头注意力机制，将无人机的观测-动作对 (O^i, A^i) 分解为四个异构特征子空间：动作信息特征 A^i、自身状态信息特征 O_1^i、雷达探测障碍物信息特征 O_2^i 和雷达探测敌机信息特征 O_3^i。各注意力头通过独立参数化的投影矩阵构建并行通道，分别聚焦不同特征组合，从多视角提取信息以增强表达能力。具体而言，每个头先计算不同特征下无人机对友机的注意力权重，再结合自身观测-动作对生成头输出，并将各头输出的向量拼接融合为复合信息，作为价值网络的输入。最终同样经过四层全连接层处理得到当前时刻的观测-动作价值函数预估值。相对应的目标网络结构与对应的原网络完全相同，通过这种设计，能够更有效地训练无人机集群，提高其在复杂环境中模型训练的稳定性。

5.4 仿真实验结果

5.4.1 仿真实验环境

训练环境为基于 python 构建的一个二维仿真环境，水平向右方向为 X 轴的正方向，垂直向上方向为 Y 轴的正方向，如图 5-6 所示。其中灰色实体圆代表障碍物，红色等腰

中国知网 https://www.cnki.net

三角形为红方无人机，蓝色等腰三角形为蓝方无人机，三角形的顶角定义为无人机的飞行朝向，黄色虚线包裹的圆形为地面交战区。

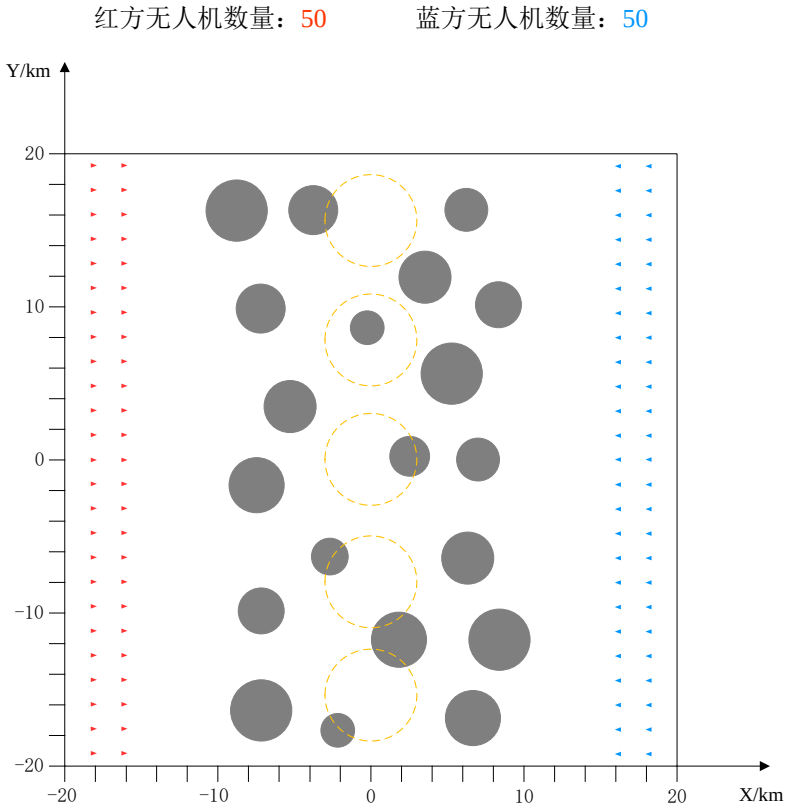


图 5-6 复杂环境仿真初始图

环境中双方最终对战的无人机集群规模 N 是 2 到 50，且环境设定正方形对抗区域的范围大小与无人机集群成正比，本章中选用以 800m 为边长的正方形作为集群规模最小时的对抗环境，20km 为边长的正方形作为集群规模最大时的对抗环境。每个地面交战区的面积被 $x=0$ 的直线均分到两个半区，半径 $R_{\mathrm{g}}=\sqrt{\lceil N/10\rceil}$km，地面交战区的个数为 $k(k=\lceil N/10\rceil)$。障碍物的半径 r_{obs} 范围大小是 500m 至 1500m，障碍物的数量为 N_{obs} 个 $(N_{\mathrm{obs}}=4*\lceil N/10\rceil)$ 。其余环境参数和无人机参数与前两章设置相同。

每个回合初始化时红方无人机集群 X 轴坐标范围是 $x\in[-x_{\max},-0.8x_{\max}]$，蓝方无人机集群 X 轴坐标范围是 $x\in[0.8x_{\max},x_{\max}]$，双方无人机集群在初始化时均采用固定位置分布进行部署，以确保无人机之间不会出现重合，且初始阶段集群不会混乱；高楼障碍物将在 $x\in[-0.6x_{\max},0.6x_{\max}]$ 范围内的矩形中按照泊松分布生成。

5.4.2　训练结果与测试评估

（1）模型训练与对比分析

仿真平台的运行环境采用的硬件配置是 Ubuntu18.04 操作系统，CPU 是 Intel core i7-

中国知网　https://www.cnki.net

12700H，GPU 是 NVIDIA GeForce 3080，运行内存是 32G。仿真环境使用 Python 语言搭建，训练代码所使用的神经网络基于 Pytorch 构建，使用 Adam 优化器优化算法参数。为了验证所提出算法的有效性，分别基于所提出的算法 (CLA-MATD3-SP)、CLA-MADDPG 算法、PER-MADDPG 算法以及未改进的 MADDPG 算法构建训练模型，CLA-MADDP 算法为第四章提出的算法，PER-MADDPG 算法是第三章提出的算法。所有算法运行在相同环境下，并且使用相同的算法超参数训练模型，算法超参数如表 5-1 所示。

表 5-1 算法相关参数

参数符号	参数含义	参数值
γ	奖励折扣因子	0.99
lr_θ	策略网络学习率	0.0005
lr_φ	价值网络学习率	0.0005
D	经验回放池容量	500 * N
MAX_EPISODES	最大训练轮数	5000 * N
EPISODE_LENGTH	单轮最大执行步数	100 * N
W	课程学习评估窗口	5 * N
η_{w}	课程学习等级更新阈值	0.8
BATCH_SIZE	采样批次大小	128

在训练过程中，每个训练回合在指定区域内按照课程等级随机初始化双方无人机集群和障碍物位置，最大训练回合设置为和每个训练回合最大执行步数为根据环境中集群规模调整。当无人机集群在运行过程中达到终止状态时会结束当前回合，终止状态的判定依据有两种情况：一是任意一方的无人机全部被击毁；二是达到每个回合设定的最大执行步数。对抗的结果判断与 5.2.1 节中胜负判定规则设定保持一致。

本章在对比实验中设计了四种仿真对抗环境，分别对应的集群规模是 20、30、40 和 50 时的环境。在这些环境中，分别使用本章提出的 CLA-MATD3-SP 算法与前两章提出的两种算法以及未改进的 MADDPG 算法训练模型。CLA-MATD3-SP 算法和 CLA-MADDPG 采用了课程学习思想，设定的课程等级是从 1 到 5，对应的环境中无人机集群规模是从 $N/5$ 到 N。模型从课程等级 1 的环境开始训练，最终到达课程等级 5 的环境。其他两种算法直接在集群规模为 N 的环境中进行模型训练。为了确保在算法胜率对比分析中能够排除其他外部因素的干扰，本文将敌方无人机的空战行为策略设定为固定的规则策略，此时的 CLA-MATD3-SP 算法为自博弈训练的初始阶段。本章设定的无人机集群对地支援固定规则策略同样分为三个阶段：

（1）避障阶段：在对战开始后，集群中无人机会分散朝着与自身距离最近的地面作战区前进，在经过城市中的高楼障碍物时会采用人工势场法避开障碍物。

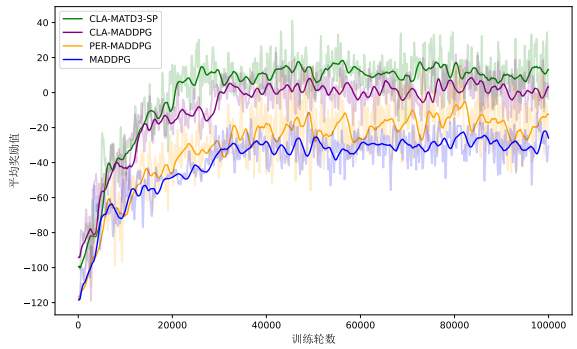
（2）支援阶段：集群在地面作战区中与敌方无人机集群展开对抗并为己方地面部队提供战术支援，对抗时同样采用与友机合作的联合攻击模式。

（3）逃逸阶段：无人机的导弹已经全部发射，且当前地面作战区内没有友机，则无

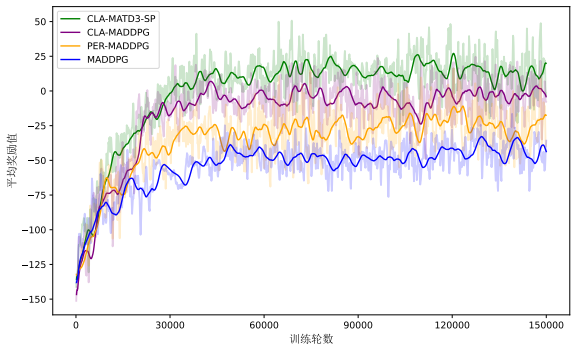
中国知网 https://www.cnki.net

人机直接向着最近的友机位置进行逃逸。

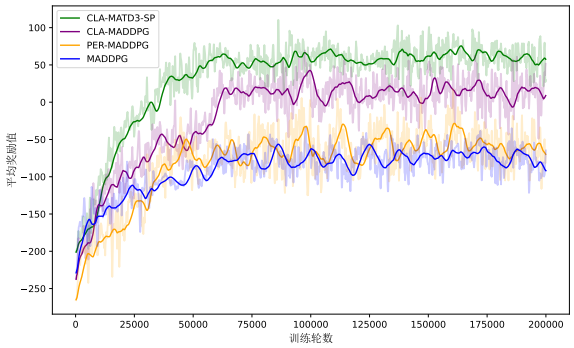
训练过程四种算法在四种对抗环境中的平均奖励曲线变化情况如图 5-7 所示。四种算法的曲线分别用四种颜色区分。



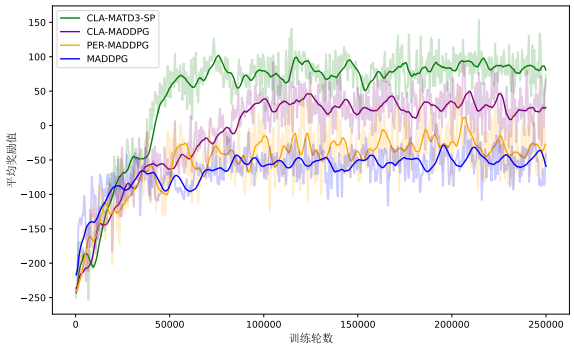
(a) 无人机集群规模为 20



(b) 无人机集群规模为 30



(c) 无人机集群规模为 40



(d) 无人机集群规模为 50

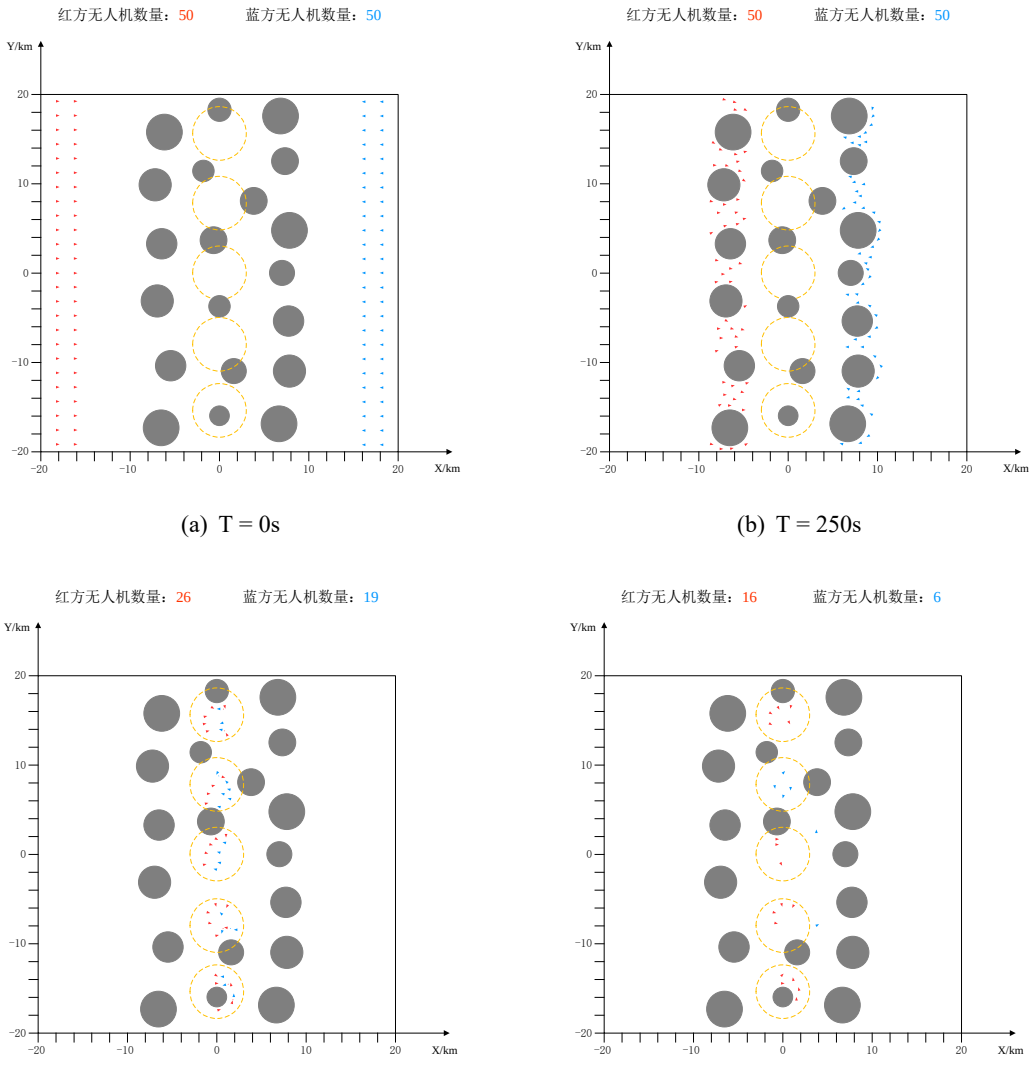
图 5-7 不同环境下各算法奖励变化曲线

从图 5-7(a) 可以看出 CLA-MATD3-SP 算法在训练过程中能够快速收敛，并且可以获得最大的平均奖励。CLA-MATD3-SP 算法和 CLA-MADDPG 算法收敛后的平均奖励明显优于另外两种算法，但是相较于 CLA-MADDPG 算法，CLA-MATD3-SP 算法的收敛速率更快且平均奖励略高。因此，在最大课程等级为 2 的环境中，本章提出的改进算法仍具有一定优势。

继续分析图 5-7(b) 至图 5-7(d) 可以看出，随着无人机集群规模的增加，CLA-MATD3-SP 算法展现出相较于 PER-MADDPG、MADDPG 和 CLA-MADDPG 算法的显著优势。未采用课程学习的 PER-MADDPG 和 MADDPG 算法在环境复杂度较高时面临平均奖励收敛困难的问题。即使勉强收敛，奖励值也较低且波动较大。基于课程学习的 CLA-MADDPG 虽然在收敛速度上与 CLA-MATD3-SP 相近，但随着环境复杂度的提升，其平均奖励的最大值逐渐落后，稳定性也有所下降。这一差异主要源于 CLA-MATD3-SP 算法在多维度上的协同优化，双延迟价值网络与针对价值网络的多头注意力机制相结合，有效抑制了高维动作空间中的 Q 值高估问题，同时提升了对抗策略的精细性。综合奖励函数曲线变化图可知，本章提出的算法在处理复杂环境下大规模无人机集群博弈对抗

中国知网　https://www.cnki.net

问题上具有更优异的表现。



(a) T = 0s　　(b) T = 250s

(c) T = 500s　　(d) T = 750s

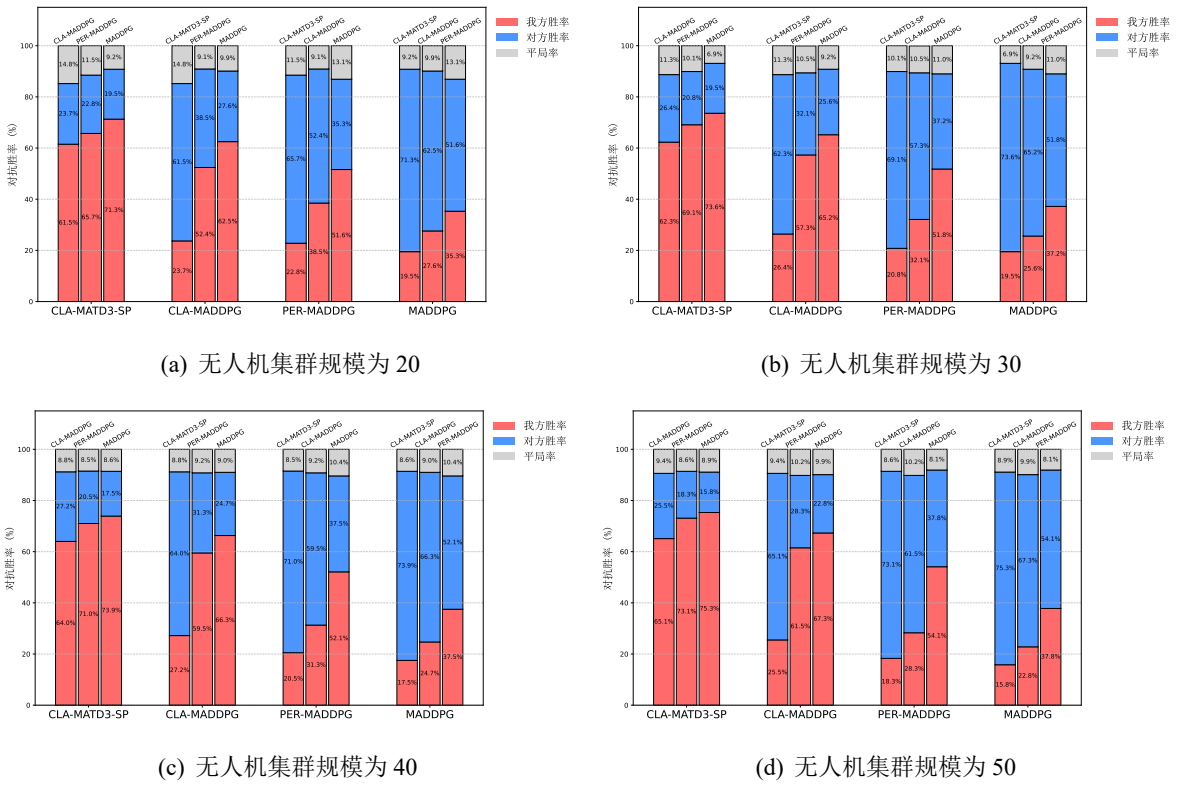
图 5-8 不同场景下各算法两两对抗胜对比图

为了更直观地观察算法策略控制的无人机集群在对地支援任务中具体的机动决策行为，本节选取了无人机规模为 50 时的对抗过程进行分析。图 5-8 为不同时刻无人机集群对抗的过程，T = 0s 时，双方无人机集群分布在对抗环境两侧的设定区域后，准备开始前往地面交战区提供战术支援；T = 250s 时，双方无人机集群正在城市高楼区域内进行避障，即将到达地面交战区；T = 500s 时，双方无人机集群在地面交战区内协同对抗并为地面部队提供支援，可以明显看出红方无人机在数量上已经取得了一定的优势；最终，T = 750s 时，到达任务设定时长，红方无人机集群在地面交战区中的数量明显高于蓝方无人机集群，对抗结束，红方无人机集群获得胜利。

中国知网 https://www.cnki.net

（2）对抗胜率分析

无人机集群对抗任务最关键的性能指标就是胜率，在对抗结果中胜率更高的那一方足够说明其具备更强的集群对抗机动策略。实验同样构建四组对比环境，分别对应集群规模是 20、30、40 和 50 时的环境。为确保评估的公平性，对抗双方均采用对应算法在相同环境参数下独立训练收敛后的最优模型参与测试，从而排除训练过程中动态参数变化对评估结果的潜在干扰。在五种对比场景中，四种算法各自对抗 1000 局计算对抗胜率，对抗结果如图 5-9 所示。



(a) 无人机集群规模为 20　　(b) 无人机集群规模为 30

(c) 无人机集群规模为 40　　(d) 无人机集群规模为 50

图 5-9 不同环境下各算法两两对抗胜对比图

图中 X 轴的分组表示红方使用的算法，小组内每一个柱形代表蓝方使用的一个算法，每个柱形自下而上三段分别表示千回合对抗中的红方胜率、蓝方胜率和平局率。图 a）到图 d）分别对应四种环境下的对抗胜率。从图中可以直观看出 CLA-MADDPG-SP 算法在与三个对比算法的对抗中胜率均占优，且环境越复杂的情况下本章提出的算法优势越明显。

（3）自博弈测试结果分析

前面已经对的 CLA-MATD3-SP 算法进行了有效性验证和性能对比分析，结果表明 CLA-MADDPG-SP 算法与对比算法在经过与固定策略蓝方无人机集群对抗的训练后，学习到的对抗策略更强。下面需要对 CLA-MATD3-SP 算法的自博弈训练阶段进行验证和分析，验证选用集群规模是 50 时的环境。

首先将 CLA-MATD3-SP 算法在初始学习阶段得到的策略模型参数交给蓝方无人机

中国知网　https://www.cnki.net

集群使用，仅使用此策略控制蓝方无人机进行机动决策，蓝方不继续训练。红方在此模型基础上继续训练，红蓝对抗以设定的仿真轮次为自博弈训练的一轮，每完成一轮自博弈训练后将红方策略模型放入蓝方策略集合中，下一轮蓝方根据概率从策略集合中采用最新策略或者历史策略，继续训练红方无人机集群。本节共进行了 10 轮自博弈训练，每轮自博弈训练完成后保存最新的策略模型参数。在每轮训练结束时都对最新的策略模型进行测试：使用最新的策略分别与每一个历史版本的旧策略对抗 100 局，认为 100 局对抗中胜率更高的一方为更优的策略，并记录最新策略优于的历史版本策略个数。测试结果如图 5-10 所示。

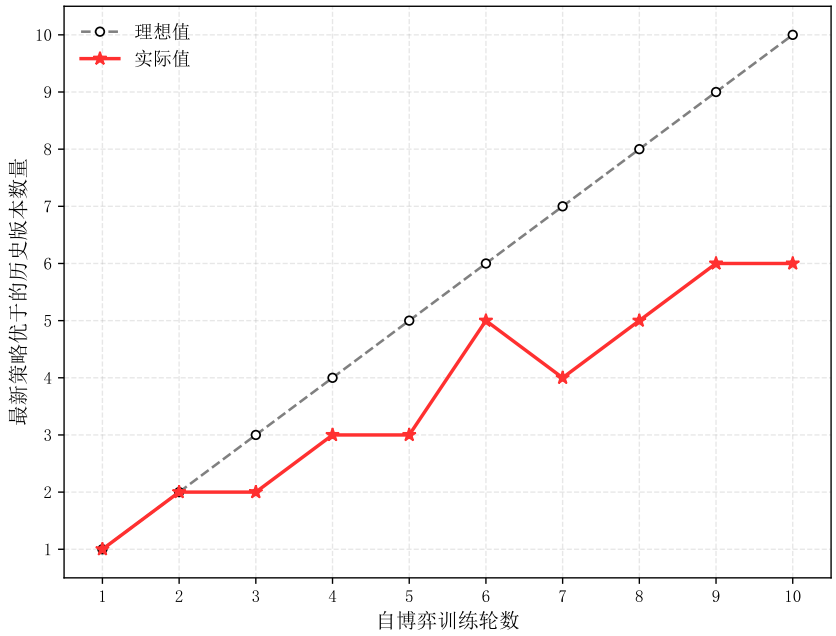


图 5-10 自博弈对抗结果

从结果图可以看出，最新策略并不一定优于所有历史策略，这主要源于非传递博弈(non-transitive game) 的存在，即若策略 A 优于策略 B，策略 B 优于策略 C，并不能推导出策略 A 一定优于策略 C，在自博弈训练中，每次随机选择一种历史策略来训练新策略，因此训练出的新策略并不一定能优于所有历史策略。为了缓解非传递博弈的问题，对 10 轮自博弈训练中得到的 10 个策略进行策略重用，以提高决策方法的多样性：即把 10 个策略作为一个集合，以其中每个策略能够击败的集合内其他策略数量作为权重。在每次选择动作时按照权重概率从集合中随机抽取一个策略来生成动作。这个策略集合作为自博弈训练阶段最终产生的 CLA-MATD3-SP 策略模型。

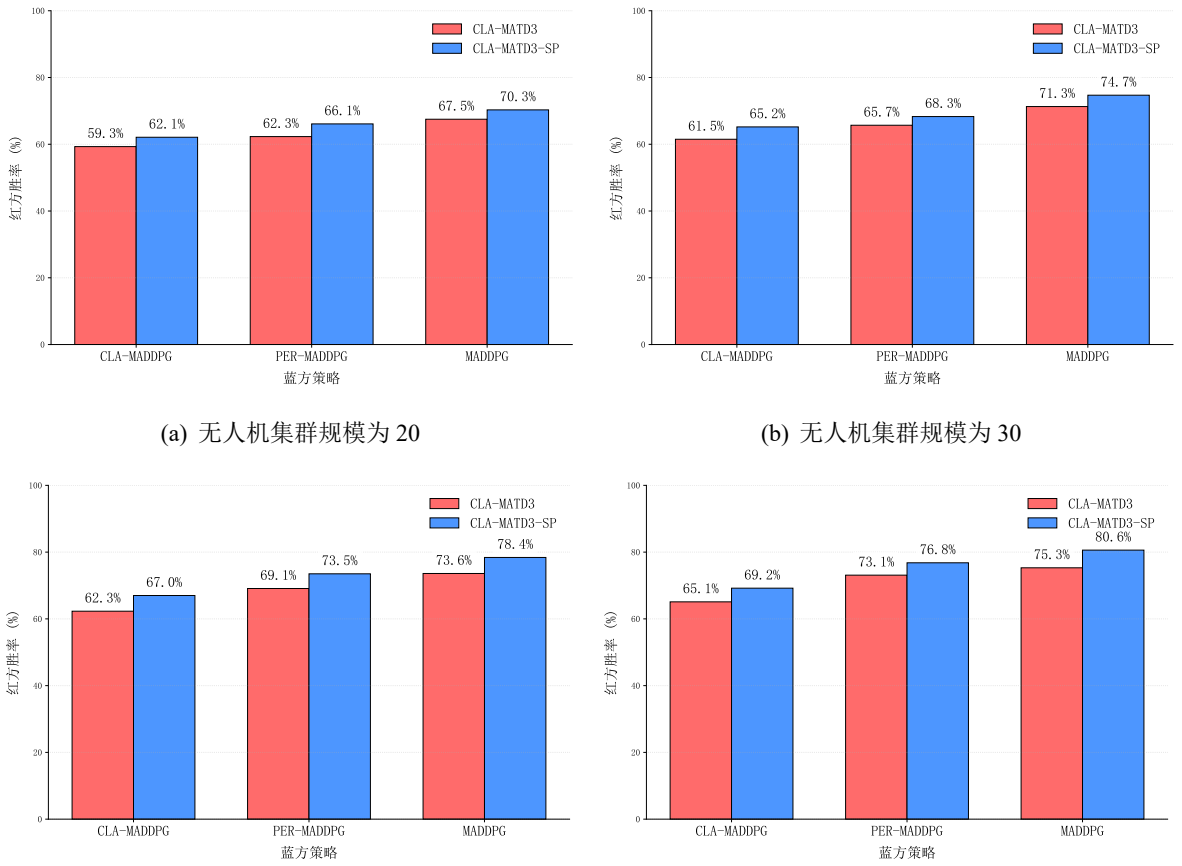
随后同样构建四组对抗场景，分别对应集群规模是 20、30、40 和 50 时的环境，将 CLA-MATD3-SP 算法在初始学习阶段得到的策略作为蓝方，10 轮自博弈训练后得到的新策略集合作为红方，进行 1000 轮次对抗测试，得到的对抗结果如表 5-2 所示。从表中可以看出，在四种对抗场景中，自博弈训练后策略模型对抗自博弈训练前的模型胜率均呈现出明显优势，因此证明自博弈训练对无人机集群机动策略的对抗水平有所提高。

中国知网 https://www.cnki.net

表 5-2 自博弈前后算法直接对抗结果

无人机集群规模	CLA-MATD3-SP 算法对抗胜率 (%)	CLA-MATD3 算法对抗胜率 (%)	平局率 (%)
20	61.4	30.5	8.1
30	60.5	30.3	9.2
40	61.2	28.9	9.9
50	59.8	32.3	7.9

另外，为了验证自博弈训练对集群对抗水平的提升是否对不同的对手都有效，本章分别将 CLA-MATD3-SP 算法在初始学习得到的模型和经过自博弈训练后得到的策略集合模型与其他算法训练完成的模型进行了 1000 轮次对抗测试。测试也是集群规模是 20、30、40 和 50 时的四种环境中进行，胜率统计如图 5-11 所示。图中 CLA-MATD3 代表自博弈训练前的模型，CLA-MATD3-SP 代表自博弈训练后的模型。经过对比分析，在不同对抗场景下，针对不同策略的对手，自博弈训练后 CLA-MATD3-SP 的策略相较于自博弈前的策略对抗胜率均有提升，证明自博弈训练对集群对抗水平的提升具有普适性。



(a) 无人机集群规模为 20

(b) 无人机集群规模为 30

(c) 无人机集群规模为 40

(d) 无人机集群规模为 50

图 5-11 不同环境下自博弈前后算法对比验证结果

中国知网　https://www.cnki.net

5.5 本章小结

本章针对复杂环境下无人机集群对地支援任务进行研究，在第四章大规模无人机集群空域争夺任务研究的基础上，提出了改进的多智能体深度强化学习算法 CLA-MATD3-SP。算法以 MATD3 算法为基础框架，引入课程学习思想和多头注意力机制，提升训练速率以及复杂环境下无人机集群对抗模型的策略有效性。此外，算法训练过程使用了自博弈训练方法来提升无人机集群对抗策略的复杂性。通过对比不同算法在复杂环境下无人机集群对抗问题中的表现，证明了提出算法的有效性。最后，在仿真环境中进行自博弈训练前后的算法策略对比，结果验证了自博弈训练框架的普适性。

中国知网 https://www.cnki.net

第六章 总结与展望

6.1 工作总结

本文在现有研究的基础上，聚焦于无人机集群空战问题、大规模无人机集群空域争夺问题与复杂环境下无人机集群对地支援问题。针对这些关键问题提出了基于多智能体强化学习算法的解决方案，本文的主要工作内容总结如下：

（1）针对无人机集群空战问题，本文提出了一种基于 MADDPG 算法的无人机集群博弈对抗方法。首先以无人机集群空战任务为背景，将对应的问题转化为马尔可夫决策过程，并且设计了对应的奖励函数。其次，将 MADDPG 算法与优先经验回放机制相结合，提出了一种改进的多智能体强化学习算法 PER-MADDPG，该算法能够通过优先经验回放机制，提升关键经验样本的利用率。最后，在无人机空战的仿真环境中，基于所提出的算法训练模型，并对训练后的模型进行测试。测试结果验证了所提出的算法对于解决无人机集群空战问题的有效性以及算法的泛化性。

（2）针对大规模无人机集群空域争夺问题，本文提出了一种基于课程强化学习算法的无人机博弈对抗方法。考虑到大规模条件下无人机集群博弈对抗模型中存在的策略震荡和收敛困难等问题，提出融合课程学习思想和注意力机制的 CLA-MADDPG 算法。通过建立渐进式训练范式和分层难度提升策略，配合注意力机制优化价值网络估计值，实现了从中小规模到大规模集群的平稳过渡。最后，仿真实验数据表明，相较于传统方法，该改进算法展现出更快的收敛速度和更高的平均奖励收益，同时在不同对抗环境中均表现出优异的泛化性。

（3）针对复杂环境下无人机集群对地支援问题，本文提出了一种基于自博弈强化学习算法的无人机集群博弈对抗方法。为应对复杂环境下的大规模集群对抗挑战，保留课程学习思想，并将注意力机制扩展为多头注意力机制，使得训练的无人机集群可以关注任务中的不同细节，同时将自博弈训练框架与 MATD3 算法相结合，提出了 CLA-MATD3-SP 算法。通过在课程学习基础上引入多头注意力机制，显著提升了算法在复杂环境中的适应能力。实验分析表明，改进算法相较于对比算法不仅收敛速度更快、奖励收益更高，其对抗胜率也得到明显提升，而自博弈测试也进一步验证了自博弈训练框架的对于无人机集群对抗能力提升的高效性与普适性。

6.2 研究展望

本文在基于多智能体强化学习的无人机集群空战、大规模无人机集群空域争夺与复杂战场环境下无人机集群对地支援问题中取得一定的成果，但仍然存在许多不足和需要改进之处：

中国知网 https://www.cnki.net

（1）在无人机集群空战问题中，本文采用了优先经验回放机制，但是当前优先级采样基于固定时序差分误差，并没有探索动态权重分配策略，如设计基于 KL 散度的自适应阈值调节器，引入元学习框架自动优化优先级计算公式中的超参数，后续将进一步探索优先经验回放机制在解决无人机博弈对抗问题中的应用。

（2）在大规模无人机集群空域争夺问题中，本文没有充分发挥大规模集群作战的统筹性，如采用无人机编队作战，主机僚机作战等，但在实际的空战对抗中可能会涉及这些特殊的作战策略，后续也将关注在采用这些特殊策略情况下的无人机集群对抗问题。

（3）在复杂城市环境下无人机集群对地支援问题中，本文分析了静态障碍物对无人机集群对抗决策的影响。然而在实际对抗场景中，可能会存在大量的动态障碍物。后续将在本文研究的基础上，加入更多的动态障碍物，以研究动态障碍物环境中无人机集群对抗问题。

（4）本文所提出的算法的验证环境局限于二维数字仿真平台，尚未开展物理实体场景下的工程化验证。真实战场部署需克服传感器误差累积、通信链路的时变干扰特性以及动态损耗补偿等多种可能的约束。后续研究拟通过半实物仿真迭代逐步确定算法在实际应用场景中需要面临的限制。

中国知网 https://www.cnki.net

参考文献

[1] Xiong F, Li A, Wang H,et al. An SDN-MQTT based communication system for battlefield UAV swarms[J]. IEEE Communications Magazine, 2019, 57(8): 41-47.

[2] 何志辉, 高万林, 何雄奎, 等. 纵列式无人直升机飞行控制系统设计[J]. 江苏大学学报(自然科学版), 2023, 44(01): 37-44.

[3] Fu L, Xie F, Wang D,et al. The overview for UAV air-combat decision method[C]. In: The 26th Chinese Control and Decision Conference (2014 CCDC). Changsha, China. IEEE. 2014. 3380-3384.

[4] Wang Z, Guo Y, Li N,et al. Autonomous confrontation strategy learning evolution mechanism of unmanned system group under actual combat in the loop[J]. Computer Communications, 2023, 209: 283-301.

[5] 费陈, 郑晗, 赵亮. 无人机集群控制技术研究[J]. 弹箭与制导学报, 2023, 43(03): 45-55.

[6] Xiang L, Xie T. Research on UAV swarm confrontation task based on MADDPG algorithm[C]. In: 2020 5th International Conference on Mechanical, Control and Computer Engineering (ICMCCE). Haerbin, China. IEEE. 2020. 1513-1518.

[7] 李圆方, 张胜光, 陈阳. 人工智能赋能军事技术举措和发展趋势分析[J]. 弹箭与制导学报, 2024, 44(04): 94-98+104.

[8] Shrestha R, Bajracharya R, Kim S. 6G enabled unmanned aerial vehicle traffic management: a perspective[J]. IEEE Access, 2021, 9: 91119-91136.

[9] Pan Z, Niu J, Kang M,et al. Research on sea-air unmanned systems collaboration for amphibious assault[C]. In: Chinese Conference on Swarm Intelligence and Cooperative Control (CCSICC). Singapore. Springer. 2023. 175-187.

[10] Puente-Castro A, Rivero D, Pazos A,et al. UAV swarm path planning with reinforcement learning for field prospecting[J]. Applied Intelligence, 2022, 52(12): 14101-14118.

[11] Wang B, Li S, Gao X,et al. UAV swarm confrontation using hierarchical multiagent reinforcement learning[J]. International Journal of Aerospace Engineering, 2021, 2021(1): 3360116.

[12] 孙智孝, 杨晟琦, 朴海音, 等. 未来智能空战发展综述[J]. 航空学报, 2021, 42(08): 35-49.

[13] 罗德林, 徐扬, 张金鹏. 无人机集群对抗技术新进展[J]. 科技导报, 2017, 35(7): 26-31.

中国知网 https://www.cnki.net

[14] 张洲, 梁军, 张致豪, 等. 基于 AIMM-PF 的多机动目标协同跟踪[J]. 江苏大学学报 (自然科学版), 2024, 45(04): 434-440.

[15] 秦云, 张成成. 无人作业船自动导航控制系统的优化[J]. 江苏大学学报 (自然科学版), 2024, 45(04): 417-425.

[16] Dietz M, Haun P. Tactical air power and the vietnam war: explaining effectiveness in modern air warfare[J]. Naval War College Review, 2024, 77(2): 12.

[17] 赵振宇, 卢广山. 无人机协同空战中的目标威胁评估和目标分配算法[J]. 火力与指挥控制, 2011, 36(12): 60-63+71.

[18] 王晓光, 章卫国, 陈伟. 无人机编队超视距空战决策及作战仿真[J]. 控制与决策, 2015, 30(02): 328-334.

[19] Duan H, Li P, Yu Y. A predator-prey particle swarm optimization approach to multiple UCAV air combat modeled by dynamic game theory[J]. IEEE/CAA Journal of Automatica Sinica, 2015, 2(1): 11-18.

[20] 肖亮, 黄俊, 徐钟书. 基于神经网络的超视距空战协同攻击决策[J]. 沈阳工业大学学报, 2013(3): 338-344.

[21] Javed S, Hassan A, Ahmad R,et al. State-of-the-art and future research challenges in uav swarms[J]. IEEE Internet of Things Journal, 2024, 11(11): 19023-19045.

[22] Xia C, Yongtai L, Liyuan Y,et al. Cooperative task assignment and track planning for multi-UAV attack mobile targets[J]. Journal of Intelligent & Robotic Systems, 2020, 100(3): 1383-1400.

[23] Wang W, Wen C, Huang J. Distributed adaptive asymptotically consensus tracking control of nonlinear multi-agent systems with unknown parameters and uncertain disturbances[J]. Automatica, 2017, 77: 133-142.

[24] Garcia E, Casbeer D W, Pachter M. Active target defence differential game: fast defender case[J]. IET Control Theory & Applications, 2017, 11(17): 2985-2993.

[25] Chen F, Ren W. A connection between dynamic region-following formation control and distributed average tracking[J]. IEEE Transactions on Cybernetics, 2017, 48(6): 1760-1772.

[26] Kang S, Wang J, Li G,et al. Optimal cooperative guidance law for salvo attack: an MPC-based consensus perspective[J]. IEEE Transactions on Aerospace and Electronic Systems, 2018, 54(5): 2397-2410.

[27] Su A, Hou F, Hong Y. Heterogeneous policy network reinforcement learning for UAV swarm confrontation[C]. In: 2024 China Automation Congress (CAC). Qingdao, China. IEEE. 2024. 722-727.

中国知网 https://www.cnki.net

[28] Hong C, Yu N, He N,et al. UAV swarm confrontation with adaptive attacking strategy[J]. Unmanned Systems, 2024: 1-16.

[29] Thrun S, Littman M L. Reinforcement learning: an introduction[J]. AI Magazine, 2000, 21(1): 103-103.

[30] Shakya A K, Pillai G, Chakrabarty S. Reinforcement learning algorithms: a brief survey [J]. Expert Systems with Applications, 2023, 231: 120495.

[31] Singh B, Kumar R, Singh V P. Reinforcement learning in robotic applications: a comprehensive survey[J]. Artificial Intelligence Review, 2022, 55(2): 945-990.

[32] Watkins C J, Dayan P. Q-learning[J]. Machine Learning, 1992, 8: 279-292.

[33] Grondman I, Busoniu L, Lopes G A,et al. A survey of actor-critic reinforcement learning: standard and natural policy gradients[J]. IEEE Transactions on Systems, Man, and Cybernetics, part C (applications and reviews), 2012, 42(6): 1291-1307.

[34] Wang X, Wang S, Liang X,et al. Deep reinforcement learning: a survey[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 35(4): 5064-5078.

[35] Mnih V, Kavukcuoglu K, Silver D,et al. Playing atari with deep reinforcement learning [J]. arXiv preprint arXiv:1312.5602, 2013.

[36] Van H, Guez A, Silver D. Deep reinforcement learning with double Q-learning[C]. In: Proceedings of the AAAI Conference on Artificial Intelligence (AAAI). Phoenix, Arizona, USA. IEEE. 2016. 25-36.

[37] Ladosz P, Weng L, Kim M,et al. Exploration in deep reinforcement learning: a survey[J]. Information Fusion, 2022, 85: 1-22.

[38] Lillicrap T P, Hunt J J, Pritzel A,et al. Continuous control with deep reinforcement learning [J]. arXiv preprint arXiv:1509.02971, 2015.

[39] Fujimoto S, Hoof H, Meger D. Addressing function approximation error in actor-critic methods[C]. In: International Conference on Machine Learning (ICML). Stockholm, Sweden. ACM. 2018. 1587-1596.

[40] Sumiea E H, Abdulkadir S J, Alhussian H S,et al. Deep deterministic policy gradient algorithm: a systematic review[J]. Heliyon, 2024, 4: 30-42.

[41] Ning Z, Xie L. A survey on multi-agent reinforcement learning and its application[J]. Journal of Automation and Intelligence, 2024, 3(2): 73-91.

[42] Tampuu A, Matiisen T, Kodelja D,et al. Multiagent cooperation and competition with deep reinforcement learning[J]. PloS One, 2017, 12(4): e0172395.

中国知网 https://www.cnki.net

[43] Sunehag P, Lever G, Gruslys A,et al. Value-decomposition networks for cooperative multi-agent learning[J]. arXiv preprint arXiv:1706.05296, 2017.

[44] Rashid T, Samvelyan M, De Witt C S,et al. Monotonic value function factorisation for deep multi-agent reinforcement learning[J]. Journal of Machine Learning Research, 2020, 21(178): 1-51.

[45] Lowe R, Wu Y I, Tamar A,et al. Multi-agent actor-critic for mixed cooperative-competitive environments[J]. Advances in Neural Information Processing Systems, 2017, 30: 74-85.

[46] Foerster J, Farquhar G, Afouras T,et al. Counterfactual multi-agent policy gradients[C]. In: Proceedings of the AAAI Conference on Artificial Intelligence (AAAI). New Orleans, Louisiana, USA. IEEE. 2018. 2974-2982.

[47] Hou Z, Zhang K, Wan Y,et al. Off-policy maximum entropy reinforcement learning: Soft actor-critic with advantage weighted mixture policy (sac-awmp)[J]. arXiv preprint arXiv:2002.02829, 2020.

[48] Xing X, Zhou Z, Li Y,et al. Multi-UAV adaptive cooperative formation trajectory planning based on an improved MATD3 algorithm of deep reinforcement learning[J]. IEEE Transactions on Vehicular Technology, 2024, 73(9): 12484-12499.

[49] Iqbal S, Sha F. Actor-attention-critic for multi-agent reinforcement learning[C]. In: International Conference on Machine Learning (ICML). Long Beach, California, USA. ACM. 2019. 2961-2970.

[50] Wang W, Yang T, Liu Y,et al. From few to more: large-scale dynamic multiagent curriculum learning[C]. In: Proceedings of the AAAI Conference on Artificial Intelligence (AAAI). New York City, NY, USA. IEEE. 2020. 7293-7300.

[51] Yang Y, Luo R, Li M,et al. Mean field multi-agent reinforcement learning[C]. In: International Conference on Machine Learning (ICML). Stockholm, Sweden. ACM. 2018. 5571-5580.

[52] 施伟, 冯旸赫, 程光权, 等. 基于深度强化学习的多机协同空战方法研究[J]. 自动化学报, 2021, 47(07): 1610-1623.

[53] Chi P, Wei J, Wu K,et al. A bio-inspired decision-making method of UAV swarm for attack-defense confrontation via multi-agent reinforcement learning[J]. Biomimetics, 2023, 8(2): 222.

[54] Wang Z, Guo Y, Li N,et al. Autonomous confrontation strategy learning evolution mechanism of unmanned system group under actual combat in the loop[J]. Computer Communications, 2023, 209: 283-301.

中国知网 https://www.cnki.net

[55] Zhang C, Wu Z, Li Z,et al. Multi-agent reinforcement learning-based UAV swarm confrontation: integrating QMIX algorithm with artificial potential field method[C]. In: 2024 IEEE International Conference on Systems, Man, and Cybernetics (SMC). Sarawak, Malaysia. IEEE. 2024. 161-166.

[56] Wang B, Li S, Gao X,et al. Weighted mean field reinforcement learning for large-scale UAV swarm confrontation[J]. Applied Intelligence, 2023, 53(5): 5274-5289.

[57] Nian X, Li M, Wang H,et al. Large-scale UAV swarm confrontation based on hierarchical attention actor-critic algorithm[J]. Applied Intelligence, 2024, 54(4): 3279-3294.

[58] Liu H, Wu K, Huang K,et al. Optimization of large-scale UAV cluster confrontation game based on integrated evolution strategy[J]. Cluster Computing, 2024, 27(1): 515-529.

[59] Hu C, Li J, Yang Y,et al. A Large-scale UAV swarm confrontation method based on fuzzy reinforcement learning[J]. International Journal of Fuzzy Systems, 2025, 2(3): 1-12.

[60] Rummery G A, Niranjan M. On-line Q-learning using connectionist systems: vol. 37[M]. University of Cambridge, Department of Engineering Cambridge, UK, 1994. 1-14.

[61] Mnih V, Badia A P, Mirza M,et al. Asynchronous methods for deep reinforcement learning[C]. In: International Conference on Machine Learning (ICML). Lille, France. ACM. 2016. 1928-1937.

[62] Schulman J, Levine S, Abbeel P,et al. Trust region policy optimization[C]. In: International Conference on Machine Learning (ICML). New York City, NY, USA. ACM. 2015. 1889-1897.

[63] Schulman J, Wolski F, Dhariwal P,et al. Proximal policy optimization algorithms[J]. arXiv preprint arXiv:1707.06347, 2017.

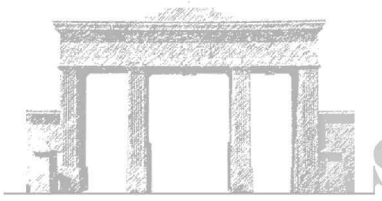
中国知网 https://www.cnki.net

毕业/学位论文答辩委员会名单

毕业/学位论文题目		基于多智能体强化学习的大规模无人机集群博弈对抗研究		
作　者		孙世彬		
专　业		控制科学与工程		
研究方向		多智能体强化学习		
导　师		王庆领		
答辩委员会组成	姓　名	职　称	学科专业	工作单位
	翟军勇 （主席）	教授	控制科学与工程	东南大学 自动化学院
	陆科林	副教授	控制科学与工程	东南大学 自动化学院
	潘芳	正高级工程师	控制科学与工程	江苏省铁路 集团有限公司
	王腾	副教授	控制科学与工程	东南大学 自动化学院
	王远大 （秘书）	助理研究员	控制科学与工程	东南大学 自动化学院

备注：
1、本表格适用于所有研究生。
2、本表格排版在终版毕业/学位论文中，附在毕业/学位论文的最后。

中国知网　https://www.cnki.net



SOUTHEAST UNIVERSITY

中国知网 https://www.cnki.net